

Problématique (rappel, ajustée au format "Comment/En quoi") :

Comment la comparaison de différentes approches de Machine Learning et de Big Data, appliquées aux données historiques de matières premières industrielles, permet-elle d'optimiser la prédiction des quantités et dates de réapprovisionnement pour réduire les ruptures de stock et les coûts de stockage ?

PLAN DU MÉMOIRE

INTRODUCTION (min. 1 page)

Présentation du sujet : l'importance croissante de la data dans la supply chain industrielle. Pourquoi la gestion de stock des matières premières est un enjeu critique. Annonce de la problématique et du plan.

PARTIE 1 — CONTEXTE

1.1 — Le secteur industriel et les enjeux de la supply chain Le contexte du manufacturing : chaînes d'approvisionnement complexes, coûts liés au surstockage et aux ruptures, impact financier direct sur la production. Chiffres clés du secteur.

1.2 — L'apport de la Data et de l'IA dans la gestion des stocks Pourquoi les méthodes traditionnelles (seuils fixes, MRP classique) montrent leurs limites. Comment le Machine Learning et le Big Data transforment la prédiction de la demande. État de l'art rapide.

1.3 — Genèse de la problématique Ce qui t'a amené à ce sujet : le constat que les entreprises industrielles peinent à anticiper les besoins en matières premières. Présentation du jeu de données choisi (+10 000 entrées), des outils et technos utilisés (Python, Spark, Kafka, Power BI).

PARTIE 2 — CHOIX DES APPROCHES TECHNOLOGIQUES ET MÉTHODOLOGIQUES POUR LA PRÉDICTION DES RÉAPPROVISIONNEMENTS

2.1 — Analyse des besoins fonctionnels d'un système intelligent de gestion de stock

- Identification des objectifs métier : prédire les quantités à commander et les dates de réapprovisionnement
- Contraintes de la supply chain industrielle : ruptures, surstockage, délais fournisseurs, variabilité de la demande

- Critères de sélection des approches : précision, interprétabilité, scalabilité, intégration métier

2.2 — Étude des approches technologiques compatibles avec la prédiction des stocks

2.2.1 — Approches statistiques et séries temporelles

- ARIMA, SARIMA, Prophet, Holt-Winters
- Intérêt pour la prévision de consommation historique
- Avantages, limites et rôle comme baseline

2.2.2 — Approches de Machine Learning supervisé orientées variables métier

- Random Forest, XGBoost, LightGBM
- Intégration des variables supply chain : lead time, saisonnalité, stock de sécurité, fréquence de consommation
- Justification de leur pertinence pour la prédiction de réapprovisionnement

2.2.3 — Approches Deep Learning et infrastructures Big Data

- LSTM / GRU pour séquences complexes
- Spark / PySpark pour le traitement distribué
- Kafka comme perspective de flux temps réel
- Power BI pour la restitution décisionnelle
- Positionnement comme architecture cible ou extension du prototype

2.3 — Choix méthodologique provisoire du prototype et justification

- Sélection prioritaire d'une approche ML supervisée pour le prototype initial
- Utilisation d'une baseline en séries temporelles pour comparaison
- Intégration progressive d'outils Big Data selon les besoins de volumétrie et d'industrialisation
- Justification du choix au regard de la problématique métier

PARTIE 3 — ANALYSE

3.1.1 — Comparaison des résultats Tableau comparatif de tous les modèles (MAE, RMSE, temps de calcul, scalabilité). Quel modèle ou quelle combinaison répond le mieux à la problématique.

3.1.1 — Impact métier simulé Simulation avant/après : réduction estimée du taux de rupture, économies sur les coûts de stockage. Dashboard Power BI de restitution avec alertes de réapprovisionnement.

3.3 — Limites et axes d'amélioration Limites des données, biais potentiels, difficultés rencontrées. Pistes d'amélioration (données temps réel, intégration ERP, renforcement learning).

4 avis perso

CONCLUSION (min. 1 page)

Synthèse des résultats. Réponse à la problématique. Ouverture : vers une supply chain autonome pilotée par l'IA ?