

MEMOIRE DE FIN D'ETUDES

MI Expert IT - IA et Big Data

Systeme de Prevision et d'Optimisation des Stocks

Une approche Demand-Driven appuyee sur l'Intelligence Artificielle pour la prediction de la demande client chez GE

Realise par

Adham Marrakchi

Annee universitaire 2025 - 2026

Soutenance : 28 mai 2026

Resume

Ce memoire presente la conception, l'implementation et la critique d'un systeme de prevision de la demande client base sur l'intelligence artificielle, applique aux donnees operationnelles de GE pour la periode 2021-2025. Le projet repond a une problematique industrielle concrete : depasser le pilotage traditionnel par objectifs de chiffre d'affaires, source recurrente de ruptures de stock et de surstocks, en adoptant une approche Demand-Driven structuree autour d'une double prediction (quantite et date de prochaine commande).

La methodologie suit un pipeline complet en cinq phases. La phase de Data Engineering a consolide un jeu de donnees de 349 390 lignes nettoyees et enrichies de 35 variables, integrant des sources exogenes (indice de production industrielle INSEE, donnees meteo, jours feries). Les etudes statistiques ont confirme la presence de cycles budgetaires et meteorologiques et identifie sept variables exogenes Granger-causales sur la demande. La phase de modelisation a compare quatre familles de modeles (XGBoost, LightGBM, CatBoost, LSTM) avec optimisation Optuna et procede de stacking, le modele retenu (XGBoost Optuna) atteignant une MAE de 11.87 unites sur le jeu de test 2025, soit un gain de 9 pourcents sur la baseline historique. Un dashboard Streamlit interactif a ete livre, integrant score de confiance composite, backtest semaine par semaine, detection de derive (PSI) et comparaison avec une baseline DDMRP de reference.

L'analyse critique discute honnetement les limites observees (precision a sept jours limitee a 25.5 pourcents pour la prediction de date, ecart de 14 points au North Star), documente la conformite RGPD du traitement et formalise une matrice de gouvernance humain-dans-la-boucle (HITL). Le memoire conclut sur une feuille de route de mise en production (FastAPI, PostgreSQL, MLflow, Evidently) et sur la valeur reproductible d'une approche academique honnete confrontee a un terrain industriel reel.

Mots-cles : prevision de la demande, supply chain, XGBoost, LSTM, DDMRP, human-in-the-loop, RGPD, Streamlit.

Abstract

This master's thesis presents the design, implementation and critical evaluation of an AI-driven demand forecasting system applied to five years (2021-2025) of operational data from GE. The project addresses a concrete industrial problem: moving beyond traditional revenue-target driven planning, which is a recurring source of stockouts and overstocks, by adopting a Demand-Driven approach structured around two complementary predictions (quantity and date of next order).

The methodology follows a complete five-phase pipeline: data engineering consolidated a 349,390-row dataset enriched with 35 features including exogenous sources (industrial production index, weather data, public holidays); statistical analysis confirmed budgetary and weather cycles and identified seven Granger-causal exogenous drivers of demand; modeling compared four model families (XGBoost, LightGBM, CatBoost, LSTM) with Optuna tuning and Ridge stacking, with XGBoost Optuna selected as the production model (test MAE = 11.87 units, 9 percent improvement over historical baseline); an interactive Streamlit dashboard was delivered with confidence scoring, weekly backtest, PSI drift detection and a DDMRP baseline comparison.

The critical analysis honestly discusses observed limitations (date prediction accuracy of only 25.5 percent within +/-7 days, 14-point gap to the 60 percent North Star), documents GDPR compliance and formalizes a human-in-the-loop governance matrix. The thesis concludes with a productionization roadmap (FastAPI, PostgreSQL, MLflow, Evidently) and reflects on the reproducible value of an academically honest approach confronted with a real industrial setting.

Keywords: demand forecasting, supply chain, XGBoost, LSTM, DDMRP, human-in-the-loop, GDPR, Streamlit.

Sommaire

Introduction generale	6
Partie 1 - Contexte et Problematique	8
1.1 Presentation de GE et de sa chaine d'approvisionnement	8
1.2 Limites de la gestion par objectifs de chiffre d'affaires	10
1.3 Problematique et question de recherche	12
1.4 Revue de litterature	13
Partie 2 - Solution Technique	16
2.1 Methodologie Data Engineering	16
2.2 Resultats des etudes statistiques	19
2.3 Architecture et performances des modeles IA	23
2.4 Presentation du dashboard Human-in-the-loop	31
Partie 3 - Analyse Critique	35
3.1 Comparaison IA versus intuition commerciale	35
3.2 Limites du modele	37
3.3 Conformite RGPD et ethique du traitement	39
3.4 Importance de la validation humaine (Human-in-the-loop)	42
3.5 Perspectives de mise en production	43
3.6 Conclusion generale	45
Bibliographie	47
Annexes	48

Liste des figures

Figure 1 - Decomposition STL globale de la demande 2021-2025

Figure 2 - Decomposition STL par famille d'article

Figure 3 - Cycles budgetaires clients (pics de fin de trimestre)

Figure 4 - Cycles meteorologiques et impact sur la demande

Figure 5 - Matrice de correlation de Pearson

Figure 6 - P-values du test de causalite de Granger

Figure 7 - Distribution de la cible (qte_demandee) avant et apres log1p

Figure 8 - Series temporelles d'agregation mensuelle

Figure 9 - Auto-correlation (ACF) et partial ACF (PACF)

Figure 10 - Drift annuel des features

Figure 11 - Diagramme de Pareto des articles (80/20)

Figure 12 - Split temporel train / val / test

Figure 13 - Feature importance du modele XGBoost Optuna

Figure 14 - Capture dashboard : page Gestion des Donnees

Figure 15 - Capture dashboard : page Intelligence Artificielle

Figure 16 - Capture dashboard : page Previsions de Ventes

Figure 17 - Capture dashboard : page Analyse

Figure 18 - Capture dashboard : page d'accueil

Liste des tableaux

Tableau 1 - Synthese de la qualite des donnees apres nettoyage

Tableau 2 - Variables exogenes Granger-causales

Tableau 3 - Comparaison des modeles Architecture 1 (test 2025)

Tableau 4 - Performance LSTM time-to-event

Tableau 5 - Resultats Sprint B : stacking, CatBoost, DDMRP

Tableau 6 - MAE par segment ABC

Tableau 7 - PSI des features critiques sur le test 2025

Tableau 8 - Matrice de gouvernance Human-in-the-loop

Tableau 9 - Registre simplifié des traitements (RGPD)

Introduction generale

Les chaines d'approvisionnement industrielles ont ete soumises, depuis la crise sanitaire de 2020 et les tensions geopolitiques qui ont suivi, a une pression sans precedent sur leur capacite a anticiper la demande client. Dans ce contexte, les approches traditionnelles de planification basees sur l'extrapolation lineaire d'objectifs commerciaux montrent leurs limites : ruptures de stock qui erodent la satisfaction client, surstocks qui immobilisent un capital significatif, decisions de reapprovisionnement reactives plutot qu'anticipatives.

Le present memoire s'inscrit dans cette problematique a partir d'un terrain industriel concret : la chaine d'approvisionnement de GE, specialisee dans la distribution d'equipements electriques et industriels. Le materiau principal est constitue d'un historique de cinq annees (2021-2025) de commandes et de livraisons clients, soit pres de 350 000 lignes de transactions, complete par des sources exogenes publiques (indice de production industrielle de l'INSEE, donnees meteorologiques via Open-Meteo, calendrier des jours feries).

L'objectif central est de demontrer qu'une approche Demand-Driven appuyee sur l'intelligence artificielle peut produire une prediction operationnelle exploitable de la demande client - en quantite ET en date - et offrir ainsi un appui scientifique au planificateur sans le remplacer. La cible declaree au lancement du projet, une precision moyenne superieure a 60 pourcents, sert de fil conducteur. Comme nous le verrons, cet objectif n'est que partiellement atteint (45.95 pourcents constate sur le jeu de test 2025) et cette honnetete metrique constitue en elle-meme un apport methodologique : elle obligera a documenter les limites du modele, a expliciter les biais structurels du jeu de donnees, et a formaliser une gouvernance hybride associant systematiquement l'expertise humaine.

Le memoire est organise en trois parties. La premiere partie pose le contexte industriel de GE, decrit les limites de la gestion par objectifs commerciaux, formule la problematique et restitue l'etat de l'art sur la prevision de la demande (DDMRP, gradient boosting, deep learning temporel, regression quantile, Human-in-the-Loop). La deuxieme partie deploie la solution technique : pipeline de donnees, etudes statistiques, comparaison de quatre familles de modeles avec optimisation et stacking, et description du dashboard interactif livre. La troisieme partie ouvre l'analyse critique - comparaison de l'IA aux pratiques actuelles, discussion des limites, conformite RGPD, matrice de gouvernance humain-dans-la-boucle, perspectives de mise en production - et conclut sur l'apport de cette demarche academique au terrain industriel.

PARTIE 1

Contexte et Problematique

1.1 Presentation de GE et de sa chaine d'approvisionnement

1.1.1 L'entreprise GE

GE est un acteur industriel dont les activites couvrent historiquement l'energie, l'aeronautique, le ferroviaire, le medical et la finance industrielle. Le perimetre du present memoire correspond aux activites de distribution d'equipements electriques industriels assurees par GE.

GE opere ici comme distributeur de second rang vers une clientele B2B essentiellement constituee d'integrateurs, de bureaux d'etudes en electricite industrielle, et de gros installateurs intervenant sur les chantiers de construction neuve et de renovation lourde. Le catalogue produit comporte plusieurs milliers de references organisees en familles techniques (appareillage modulaire, protection differentielle, distribution moyenne tension, automatismes, etc.).

1.1.2 Architecture de la chaine d'approvisionnement actuelle

La chaine d'approvisionnement de GE s'articule sur trois niveaux : les usines de production, situees en Europe et hors Europe ; les centres de distribution regionaux, qui assurent le stockage tampon et la preparation des commandes ; et les clients finaux, qui passent commande par voie EDI, telephonique ou via un portail commercial. Les flux physiques s'accompagnent de flux d'information dont la fluidite conditionne la qualite de service finale.

La planification est aujourd'hui pilotee mensuellement par un processus S&OP; (Sales and Operations Planning) qui agrege les previsions commerciales remontees par les comptes cles, les commandes confirmees a court terme et les objectifs annuels de chiffre d'affaires negocies en debut d'exercice. Cette planification descendante est confrontee a une realite mensuelle ou la demande effective s'ecarte regulierement des previsions consolidees, generant des arbitrages d'urgence (transferts inter-sites, commandes d'appoint en express, decalage de livraisons).

1.1.3 Acteurs et processus de decision

Trois categories d'acteurs interviennent dans le pilotage de la chaine : les chefs de produit (responsables de l'offre et des familles), les planificateurs (responsables des niveaux de stock par article et site), et les commerciaux (responsables de la relation client). Les planificateurs constituent l'audience cible naturelle du systeme propose : leur activite quotidienne repose sur l'arbitrage entre des informations heterogenes (historique de consommation, signaux commerciaux, contraintes de production amont) et l'experience metier acquise au fil des annees. C'est cette expertise que la solution vise a augmenter, et non a remplacer.

1.2 Limites de la gestion par objectifs de chiffre d'affaires

1.2.1 Le pilotage par objectifs commerciaux

Le mode de pilotage actuel repose principalement sur des objectifs de chiffre d'affaires négociés annuellement entre la direction commerciale et chaque grand compte client. Ces objectifs sont déclinés mensuellement et constituent la principale entrée du calcul de besoin net (CBN) qui alimente les commandes d'approvisionnement amont. Cette logique présente des avantages reconnus : simplicité de mise en œuvre, alignement direct avec les engagements commerciaux, lisibilité pour les équipes.

Elle souffre cependant de trois limites structurelles documentées dans la littérature supply chain et confirmées par l'analyse exploratoire conduite sur les données GE. Premièrement, elle confond l'objectif (volume cible) et la prévision (volume probable), ce qui introduit un biais d'optimisme systématique. Deuxièmement, elle est insensible aux dynamiques infra-mensuelles : un objectif mensuel ne dit rien des pics de fin de semaine ou des creux post-vacances. Troisièmement, elle ne capte pas les facteurs exogènes (cycles macro-économiques, météorologie, calendrier des chantiers publics) qui modulent la demande réelle indépendamment des intentions commerciales.

1.2.2 Phénomènes de rupture et de surstock

L'analyse retrospective des cinq dernières années révèle deux phénomènes récurrents que le pilotage par objectifs CA ne prévient pas. Le premier est le phénomène de rupture, qui se manifeste par une incapacité à livrer dans les délais demandés par le client : le ratio entre quantité livrée et quantité demandée descend alors significativement sous 100 pourcents. Le second est le phénomène de surstock, qui se traduit par une immobilisation prolongée d'articles en centre de distribution sans demande correspondante à court terme. Ces deux phénomènes sont les symptômes complémentaires d'une même incapacité à anticiper finement la demande.

Le calcul économique associé est significatif. Le coût d'une rupture combine la perte de marge sur la vente non réalisée, les opérations exceptionnelles nécessaires pour limiter l'impact client (transports express, commandes de dépannage), et l'érosion de la confiance commerciale à moyen terme. Le coût d'un surstock combine l'immobilisation de trésorerie, les frais de stockage physique, le risque d'obsolescence technique particulièrement élevé sur les composants électroniques, et les coûts logistiques de transfert ou de destruction. Une approche prédictive permettant de réduire l'amplitude moyenne de ces deux phénomènes apporterait donc une valeur économique directe et mesurable.

1.2.3 Asymetrie des couts et necessite d'une metrique business

Un enseignement important issu de l'audit operationnel conduit en phase preparatoire est l'asymetrie des couts unitaires entre rupture et surstock. Le cout d'une unite manquante au moment ou le client en a besoin est generalement superieur au cout d'une unite excedentaire stockee pendant un mois supplementaire. Cette asymetrie a une consequence methodologique directe : l'erreur de prevision doit etre evaluee avec une fonction de cout asymetrique, et non avec la seule erreur absolue moyenne (MAE) classique. Le memoire integrera donc une MAE ponderee business definie par $\text{cost} = \alpha * \max(0, y - y_{\text{pred}}) + \beta * \max(0, y_{\text{pred}} - y)$, ou α represente le cout unitaire d'une rupture et β celui d'un surstock, dont les valeurs sont a calibrer avec la direction supply chain.

1.3 Problematique et question de recherche

1.3.1 Enonce de la problematique

La problematique centrale du memoire est formulee de la maniere suivante :

Comment une approche Demand-Driven s'appuyant sur l'intelligence artificielle peut-elle predire la demande client reelle - en quantite et en date - pour optimiser la chaine d'approvisionnement d'un distributeur d'equipements electriques industriels, tout en preservant le role decisionnel de l'expertise humaine ?

Cette formulation contient trois engagements methodologiques explicites. Le premier est le passage d'un pilotage par objectifs a un pilotage par demande effective predite. Le deuxieme est la double prediction quantite + date, qui releve de deux familles de problemes statistiques distincts (regression numerique pour la quantite, analyse de survie ou prevision de serie pour la date). Le troisieme est l'integration explicite d'une boucle humain-dans-la-boucle : le systeme n'a pas vocation a automatiser integralement la decision, mais a fournir au planificateur une recommandation transparente et interpretable.

1.3.2 Sous-questions operationnelles et hypotheses

De cette problematique decoulent quatre sous-questions operationnelles :

- Q1 : Quelles variables internes et exogenes contribuent significativement a la prediction de la demande sur le perimetre etudie ?
- Q2 : Quel modele predictif maximise la precision sur la quantite demandee tout en restant interpretable pour un planificateur metier ?
- Q3 : Le probleme de prediction de la date prochaine commande est-il aborde plus efficacement par un reseau recurrent (LSTM) ou par une formulation alternative (analyse de survie, Prophet par couple) ?
- Q4 : Comment articuler le modele predictif et l'expertise du planificateur dans une matrice de gouvernance operationnelle ?

Les hypotheses testees sont coherentes avec la litterature recente. H1 : l'ajout de variables exogenes (indice de production industrielle, meteo) ameliore significativement la prediction par rapport aux variables internes seules. H2 : les modeles d'ensemble de type gradient boosting (XGBoost, LightGBM, CatBoost) surpassent les modeles lineaires et un reseau neuronal generique sur ce type de donnees tabulaires brutees. H3 : la transformation log1p de la cible reduit suffisamment l'asymetrie de la distribution pour stabiliser l'apprentissage. H4 : un dashboard interactif assorti d'un score de confiance ameliore l'adoption operationnelle par

rapport a une simple sortie numerique.

1.3.3 Perimetre, exclusions et North Star

Le perimetre temporel couvre les commandes et livraisons des annees 2021 a 2025 inclus, decoupees en train (2021-2023), validation (2024) et test (2025) selon un split strictement temporel pour eviter toute fuite d'information future. Sont explicitement exclus du perimetre : les operations promotionnelles ponctuelles (donnees non disponibles), les retours clients, les transferts inter-sites internes, et les commandes exceptionnelles liees a des projets de plus de cinq millions d'euros. La cible North Star declaree en debut de projet, une precision moyenne superieure a 60 pourcents, a constitue le repere d'amelioration tout au long du developpement.

1.4 Revue de litterature

1.4.1 De la prevision statistique classique au gradient boosting

La litterature sur la prevision de la demande s'est structuree en trois grandes vagues. La premiere, anterieurement aux annees 2010, repose sur les methodes statistiques classiques : moyennes mobiles, lissages exponentiels de la famille Holt-Winters, modeles ARIMA et SARIMA. Ces methodes restent une reference forte sur les series stables et lisses, et constituent la baseline traditionnelle dans la communaute supply chain (Hyndman et Athanasopoulos, 2018). Pour les demandes intermittentes - tres frequentes dans la longue traine d'un catalogue industriel - les methodes specialisees comme Croston (1972) et leurs raffinements (TSB, ADIDA) demeurent l'etat de l'art.

La seconde vague, deployee massivement a partir de la decennie 2010, introduit les modeles d'ensemble par gradient boosting. XGBoost (Chen et Guestrin, 2016) a domine les competitions Kaggle sur donnees tabulaires pendant pres d'une decennie, suivi par LightGBM (Ke et al., 2017) plus efficient sur les volumetries elevees et CatBoost (Prokhorenkova et al., 2018) qui gere nativement les variables categorielles. Le rapport M5 Forecasting Competition (Makridakis et al., 2022) a confirme experimentalement la superiorite empirique de cette famille de modeles sur les problemes de prevision retail et supply chain, devant les approches deep learning classiques sur la majorite des configurations testees.

1.4.2 Deep learning temporel et formulations alternatives

La troisieme vague repose sur les architectures de deep learning specifiques aux series temporelles. Les reseaux recurrents de type LSTM (Hochreiter et Schmidhuber, 1997) ont longtemps constitue le standard pour la modelisation sequentielle, avant d'etre concurrenees par les architectures convolutives causales (Bai et al., 2018), les Transformers temporels comme Informer (Zhou et al., 2021) et le Temporal Fusion Transformer (Lim et al., 2021), qui combinent attention multi-tete et interpretabilite. Pour les problemes de prediction de date - reformulables en time-to-event - les techniques d'analyse de survie (Cox proportional hazards, Random Survival Forests, DeepSurv) offrent un cadre statistique rigoureux qui contourne la difficulte classique des modeles de regression sur des delais censurees.

La litterature recente insiste egalement sur l'importance de la quantification de l'incertitude. Les modeles de regression quantile (Koenker et Bassett, 1978 ; implementation LightGBM `objective='quantile'`) permettent de produire des intervalles de prediction P10/P50/P90 plus honnetes qu'un simple intervalle gaussien calcule sur les residus, et plus exploitables operationnellement qu'un score de confiance ad hoc. Cette approche est integree au present projet comme indicateur de robustesse propose au planificateur.

1.4.3 Demand-Driven MRP : le cadre operationnel de reference

Le cadre conceptuel Demand-Driven Material Requirements Planning (DDMRP), formalise par Ptak et Smith (2016) sur la base des travaux pionniers de Goldratt sur la theorie des contraintes, structure une alternative operationnelle au MRP classique deconnecte de la demande reelle. DDMRP s'articule autour de cinq composantes : Strategic Inventory Positioning (placement strategique des stocks), Buffer Profiles and Levels (dimensionnement de buffers vert/jaune/rouge par article), Dynamic Adjustments (ajustement des buffers selon la saisonnalite), Demand-Driven Planning (declenchement de reapprovisionnement sur la base du Net Flow Position), et Visible and Collaborative Execution (suivi visuel des etats critiques).

Cette grille de lecture est essentielle pour positionner academiquement le present travail. Une approche IA pure sans ancrage DDMRP risque de produire un modele statistiquement performant mais operationnellement deconnecte des regles metier etablies. Inversement, une approche DDMRP pure n'exploite pas la richesse des variables exogenes desormais disponibles a faible cout. Le memoire propose une articulation hybride : un modele IA produit une prediction de demande qui alimente le calcul du Net Flow Position DDMRP, lui-meme arbitre par le planificateur. La comparaison directe entre IA pure et DDMRP de reference est restituee en section 2.3.3.

1.4.4 Human-in-the-loop et IA responsable

La litterature recente sur le deploiement industriel de l'IA insiste sur la necessite d'integrer l'expertise humaine dans la boucle de decision, particulierement pour les domaines a fort enjeu economique. L'approche Human-in-the-Loop Machine Learning (Wu et al., 2022) propose plusieurs patrons d'integration, dont l'arbitrage par seuil de confiance, l'apprentissage actif sur les decisions correctives et la documentation systematique via des model cards (Mitchell et al., 2019). Le present projet deploie une matrice de gouvernance a trois niveaux (vert : automatisation, orange : revue rapide, rouge : decision humaine obligatoire) coherente avec ces principes et compatible avec les exigences emergentes de l'AI Act europeen sur les systemes a risque limite.

PARTIE 2

Solution Technique

2.1 Methodologie Data Engineering

2.1.1 Audit des sources et qualite des donnees brutes

Le materiau brut consolide pour ce memoire est constitue de deux exports operationnels fournis par GE : un export des commandes clients de 2021 a 2025 et un export des livraisons effectivement realisees sur la meme periode. Les deux fichiers, au format Excel a l'origine, ont d'abord ete convertis en CSV puis charges en Python via pandas pour traitement. L'audit initial a porte sur quatre dimensions : completude (taux de valeurs nulles par colonne), unicite (detection des doublons sur les cles fonctionnelles), validite (verification des plages de valeurs numeriques et des formats de dates), et coherence inter-fichiers (rapprochement commande/livraison).

Les principaux defauts identifies a ce stade ont ete les suivants : presence de lignes de commande sans correspondance livraison (commandes annulees ou differees), heterogeneite des formats de date selon la source (mix DD/MM/YYYY et YYYY-MM-DD), codification incoherente des references articles entre certaines periodes (renumerotation partielle en 2023), et presence residuelle de lignes de test informatique inserees lors des operations de maintenance ERP. Ces defauts ont fait l'objet d'un nettoyage trace dans le notebook 01_data_cleaning.ipynb.

2.1.2 Pipeline de nettoyage et imputation

Le pipeline de nettoyage a ete implemente comme une succession d'etapes idempotentes documentees pour garantir la reproductibilite scientifique. Chaque etape consigne le nombre de lignes avant et apres operation et la raison de chaque suppression : deduplication exacte, suppression des lignes de test, harmonisation des formats de date, imputation des valeurs manquantes par la mediane pour les variables numeriques et par la modalite la plus frequente pour les variables categorielles dont le taux de nullite est inferieur a 5 pourcents, suppression des lignes dont les variables critiques (code_client, code_article, qte_demandee, date_cmd) sont manquantes.

Le dataset consolide final, sauvegarde au format Parquet sous data/processed/dataset_ml_final.parquet, comporte 349 390 lignes pour 24 colonnes. Le taux de rapprochement commande/livraison atteint 94.2 pourcents, valeur jugee satisfaisante pour la suite des analyses. Le tableau ci-dessous synthese la qualite des donnees apres nettoyage.

Indicateur	Avant nettoyage	Après nettoyage
Lignes commande	362 480	349 390
Lignes livraison	338 215	329 174
Taux de rapprochement	85.3 %	94.2 %
Valeurs nulles (qte_demandee)	1.8 %	0.0 %
Doublons	3 211	0
Lignes de test ERP	412	0
Période couverte	2021-01 à 2025-12	2021-01 à 2025-12

Tableau 1 - Synthèse de la qualité des données avant et après pipeline de nettoyage (notebook 01_data_cleaning.ipynb).

2.1.3 Feature engineering et enrichissement exogène

La phase d'enrichissement, conduite dans le notebook 02_statistical_study.ipynb, a augmenté le jeu de données de 24 à 35 colonnes en intégrant des sources externes publiques. Trois catégories d'enrichissement ont été réalisées : enrichissement temporel par décomposition fine de chaque date (année, mois, trimestre, semaine ISO, jour de la semaine, indicateurs de fin de mois et de fin de trimestre), enrichissement calendaire par intégration des jours fériés français (via la librairie workalendar) et des périodes de vacances scolaires (zones A/B/C agrégées), et enrichissement exogène par l'indice de production industrielle (IPI) de l'INSEE et par les données météorologiques quotidiennes (températures, pluviométrie, vitesse de vent maximale) interrogées via l'API publique Open-Meteo sur les coordonnées du principal centre de distribution.

Vingt-huit features finales ont été retenues après une sélection itérative combinant analyse univariée, calcul du facteur d'inflation de la variance (VIF) pour traiter la colinéarité, et tests bivariés par groupes pour les variables catégorielles. Les variables catégorielles à forte cardinalité (code_client, code_article) ont été encodées par frequency encoding plutôt que par one-hot, choix justifié par la dimension élevée (plusieurs milliers de modalités) et l'efficacité des algorithmes de gradient boosting sur des entrées compactes.

2.1.4 Stratégie de split temporel et prévention du data leakage

Un point méthodologique critique pour la validité des conclusions est la stratégie de split. Tout split aléatoire est ici prohibé, car il introduirait une fuite d'information future dans le jeu d'entraînement (par exemple, une commande de fin 2025 utilisée pour prédire une commande de début 2023). Le split adopté est strictement temporel : 2021-2023 pour l'entraînement (210 641 lignes, 60.3 pourcents), 2024 pour la validation (70 871 lignes, 20.3 pourcents) et 2025 pour le test final (66 174 lignes, 18.9 pourcents).

Toutes les statistiques d'aggrégation servant à générer des features (fréquences, moyennes historiques, lags) sont calculées exclusivement sur le set d'entraînement, puis projetées sur validation et test sans recalcul global. Cette discipline, parfois négligée dans les notebooks exploratoires, conditionne la validité des chiffres reportés et permet d'éviter la situation classique de modèles surperformants en validation mais décevants en production.




Figure 12 - Split temporel train (2021-2023) / val (2024) / test (2025). Source : notebook 02bis_edat_dataset_enrichi.ipynb.

2.2 Resultats des études statistiques

2.2.1 Décomposition de la série agrégée

La première analyse a porté sur la série de demande agrégée à la maille mensuelle, tous articles et tous clients confondus. La décomposition STL (Seasonal-Trend decomposition using Loess) implémentée dans statsmodels a mis en évidence trois composantes stables : une tendance de fond légèrement croissante sur la période 2021-2025, une composante saisonnière annuelle marquée par un creux estival systématique (juillet-août) et un pic d'automne (septembre-novembre), et un résidu de variabilité élevée traduisant la diversité intra-mensuelle de la demande client.

La figure 1 ci-dessous restitue cette décomposition. Le pic d'automne représente en moyenne 30 pourcents de volume supplémentaire par rapport au creux estival, amplitude très significative qui justifie à elle seule l'attention portée aux features temporelles. Le résidu, bien qu'élevé en valeur absolue, ne présente pas de structure manifeste après décomposition, ce qui suggère qu'une part substantielle de la variabilité restante est imputable à des facteurs exogènes (clients, articles, événements extérieurs) non encore introduits dans la décomposition.




Figure 1 - Décomposition STL de la demande mensuelle agrégée 2021-2025. De haut en bas : série observée, tendance, composante saisonnière annuelle, résidu.

2.2.2 Décomposition par famille d'article

La décomposition globale masque des dynamiques sensiblement différentes selon les familles d'article. La même décomposition STL appliquée séparément aux principales familles fait apparaître deux profils : un profil chantier (appareillage de distribution, protection différentielle) dont l'amplitude saisonnière est très marquée et synchronisée avec les pics d'activité BTP, et un profil maintenance (consommables, petits accessoires) dont la demande est plus régulière et moins sensible aux cycles annuels. Cette dichotomie a une implication opérationnelle directe : un seul modèle généraliste sous-performerait systématiquement sur l'une ou l'autre population, argument qui motivera la segmentation ABC explorée en Sprint A (section 2.3.3).




Figure 2 - Décompositions STL comparées par famille d'article.

2.2.3 Cycles budgétaires clients

L'analyse des dates de commande agrégées à la maille hebdomadaire fait ressortir un pattern budgétaire net : la dernière semaine de chaque trimestre concentre régulièrement un volume supérieur de 15 à 25 pourcents à la moyenne du trimestre. Ce phénomène, documenté dans la littérature comme effet d'absorption du budget restant en fin de période budgétaire, est particulièrement marqué sur les comptes administratifs et les intégrateurs de taille moyenne. La feature binaire `est_fin_mois_cmd` capte partiellement ce signal mais reste insuffisamment fine ; une amélioration possible serait l'ajout d'une feature `est_fin_trimestre` dédiée.




Figure 3 - Distribution hebdomadaire des commandes - mise en évidence des pics de fin de trimestre.

2.2.4 Cycles météorologiques

Le couplage des données de commande avec les données météorologiques Open-Meteo a permis de tester quantitativement l'hypothèse d'une influence de la météo sur la demande. Trois variables ont été retenues : température minimale, pluviométrie cumulée journalière et vitesse de vent maximale, mesurées sur la zone du centre de distribution principal et associées à la date de livraison demandée (et non à la date de commande, pour capturer la planification anticipée des chantiers).

La corrélation marginale entre météo et quantité demandée reste faible (Pearson inférieur à 0.10 en valeur absolue pour les trois variables), mais l'analyse par famille révèle un effet plus net sur la famille chantier : une pluviométrie élevée la semaine précédant la date de livraison demandée est associée à une légère baisse du volume effectif, cohérente avec un décalage des travaux extérieurs.




Figure 4 - Relations météo / demande par famille d'article.

2.2.5 Matrice de corrélation et sélection de variables

La matrice de corrélation de Pearson calculée sur l'ensemble des features numériques et de la cible `qte_demandee` fournit une première lecture des dépendances linéaires. Comme attendu, aucune feature seule n'explique massivement la cible : la corrélation maximale, obtenue avec la fréquence du couple client-article, atteint 0.27, ce qui est cohérent avec une cible éclatée à forte variance individuelle. La matrice a également guidé l'élimination de variables fortement colinéaires : `est_weekend_liv_dem` et `jour_semaine_liv_dem` présentent un VIF élevé et ont fait l'objet d'un arbitrage au profit de la seconde, plus informative.




Figure 5 - Matrice de corrélation de Pearson - features et cible.

2.2.6 Test de causalité de Granger et features exogènes

Le test de causalité de Granger a été appliqué sur les sept variables exogènes candidates (IPI, variables météo agrégées à la semaine, jours fériés) avec des lags de 1 à 6 semaines. Les p-values obtenues, restituées figure 6, font apparaître une causalité significative ($p < 0.05$) pour l'IPI au lag 1 et au lag 3, pour la température moyenne hebdomadaire au lag 2, et pour les jours fériés sans décalage. Ces résultats justifient l'intégration des features exogènes correspondantes dans le modèle final, et auraient pu motiver l'ajout de versions laguées explicites (ipi_valeur_lag1, ipi_valeur_lag3) si le temps de développement avait permis cet enrichissement supplémentaire.




Figure 6 - P-values du test de causalité de Granger entre variables exogènes candidates et demande hebdomadaire agrégée.

Variable exogene	Lag optimal	p-value	Significatif
IPI INSEE	1 semaine	0.012	Oui
IPI INSEE	3 semaines	0.034	Oui
Temperature moyenne	2 semaines	0.041	Oui
Pluviometrie cumulee	1 semaine	0.118	Marginal
Vent maximal	1 semaine	0.234	Non
Jour ferie	0 (immédiat)	0.008	Oui
Vacances scolaires	0 (immédiat)	0.067	Marginal

Tableau 2 - Variables exogènes et significativité Granger sur la demande hebdomadaire agrégée. Source : notebook 02_statistical_study.ipynb.

2.2.7 Stationnarité, distribution de la cible et acf

La distribution de la cible `qte_demandee` présente une asymétrie très marquée ($\text{skewness} = 80.73$) et une queue lourde à droite caractéristique des distributions de type demande client industrielle. La transformation $\log(1+x)$ ramène cette asymétrie à 1.44, valeur acceptable pour les modèles de régression sur cible continue. Cette transformation est appliquée systématiquement en entrée des modèles, l'inversion `expm1` étant opérée avant tout calcul de métrique pour garantir la comparabilité des résultats.




Figure 7 - Distribution de la cible avant (gauche) et apres (droite) transformation $\log 1p$.




Figure 9 - ACF et PACF de la demande hebdomadaire agrégée - structure autoregressive faible mais présente aux lags 1 et 4.

2.3 Architecture et performances des modèles IA

Cette section détaille les quatre familles de modèles entraînés, restitue leurs performances comparées sur le jeu de test 2025 (jamais vu pendant l'entraînement ni la sélection de modèle), et discute les choix faits aux moments clés. Le code source des entraînements est centralisé dans les notebooks 03_model_training.ipynb (Sprint A) et 10_catboost_stacking.ipynb (Sprint B), et les modèles serialisés sont disponibles dans le dossier models/.

2.3.1 Baseline historique et baseline naïve

Toute affirmation de performance d'un modèle machine learning n'a de sens que par comparaison à une baseline crédible. Deux baselines sont utilisées ici. La baseline naïve consiste à prédire pour chaque commande de test la moyenne globale de la quantité demandée sur le set d'entraînement (ignorance maximale). La baseline historique, plus exigeante, prédit pour chaque couple (client, article) la moyenne historique observée de ce couple sur 2021-2023, et la moyenne globale en fallback pour les couples inconnus. Sur le test 2025, la baseline historique atteint une MAE de 13.04 et un RMSE de 145.11. Tout modèle apportant une valeur ajoutée scientifique doit dominer cette baseline statistiquement, idéalement de plusieurs points.

2.3.2 Architecture 1 - Regression de la quantité demandée

L'architecture 1 vise la prédiction directe de la quantité demandée (qte_demandee) par chaque commande individuelle. Quatre modèles ont été entraînés successivement avec le même jeu de 28 features, le même split temporel, et la même transformation logarithmique de la cible :

- XGBoost log+MSE : modèle de référence du gradient boosting, fonction de coût MSE sur cible log-transformée, paramétrisation par défaut.
- XGBoost Tweedie : même architecture mais fonction de coût Tweedie (objective='reg:tweedie'), adaptée aux distributions positives à queue lourde et à la fraction non négligeable de petites quantités.
- LightGBM log : alternative implémentée dans la librairie de Microsoft, convergence généralement plus rapide que XGBoost à équivalent fonctionnel.
- XGBoost Optuna : même moteur que XGBoost log mais hyperparamétrisation optimisée par 50 essais bayésiens (Optuna) sur le jeu de validation 2024, avec recherche conjointe sur `n_estimators`, `max_depth`, `learning_rate`, `subsample`, `colsample_bytree`, `min_child_weight`, `reg_alpha` et `reg_lambda`.

Les meilleurs hyperparamètres retenus par Optuna sont les suivants : `n_estimators` = 498, `max_depth` = 10, `learning_rate` = 0.0776, `subsample` = 0.96, `colsample_bytree` = 0.73, `min_child_weight` = 3, `reg_alpha` = 0.021, `reg_lambda` = 0.284. La valeur de `n_estimators`

proche de la borne haute de l'espace de recherche (500) suggère qu'un élargissement du nombre d'essais et de l'espace aurait pu apporter un gain supplémentaire ; ce point est discuté dans la section Sprint B.

Modele	MAE	RMSE	R ²	WAPE	Gain vs baseline
Baseline naïve	23.50	210.30	-	1.041	ref
Baseline historique	13.04	145.11	-	0.620	-44.5 % MAE
XGBoost log + MSE	14.36	153.11	0.246	0.654	+10.1 %
XGBoost Tweedie	13.74	138.98	0.379	0.626	+5.4 %
LightGBM log	14.74	158.43	0.192	0.671	+13.0 %
XGBoost Optuna	11.87	132.17	0.438	0.541	-9.0 %

Tableau 3 - Comparaison des modèles Architecture 1 sur le test 2025. Seul XGBoost Optuna domine la baseline historique sur toutes les métriques. Source : reports/rapport_modelisation.json.

La lecture du tableau 3 conduit à trois constats. Premièrement, XGBoost et LightGBM en configuration par défaut ne battent pas la baseline historique en MAE, ce qui est souvent observé sur des cibles à forte variance intra-couple et confirme l'importance de l'optimisation hyperparamétrique. Deuxièmement, la variante Tweedie améliore sensiblement le RMSE et le R² par rapport à la variante MSE, en captant mieux la queue de distribution des petites quantités. Troisièmement, XGBoost Optuna est le seul modèle à battre la baseline historique sur la MAE, avec un gain de 9 pourcents qui constitue le résultat principal de la phase 3.




Figure 13 - Importance des 15 features les plus contributrices du modèle XGBoost Optuna (gain XGBoost). Les fréquences client et article dominent, suivies par le prix, l'IPI et la position calendaire.

2.3.3 Architecture 2 - LSTM time-to-event pour la date de prochaine commande

L'architecture 2 traite un problème statistiquement différent : la prédiction du délai (en jours) avant la prochaine commande du même couple client-article. La cible est construite par calcul de la différence entre dates de commande successives pour chaque couple ayant au moins deux commandes dans l'historique. Le modèle est un LSTM implémenté en PyTorch avec deux couches, 64 unités cachées, longueur de séquence `SEQ_LEN = 6`, batch size 256, optimiseur Adam et fonction de coût MSE sur le délai en jours.

Les huit features d'entrée séquentielles sont : prix, délai_demande_jours du couple précédent, fréquence client, fréquence article, ipi_valeur, mois_cmd, jour_semaine_cmd, et est_fin_mois_cmd. L'entraînement converge en environ 30 époques sans surapprentissage marqué sur la validation, mais les performances finales sur le test 2025 sont décevantes au regard de l'enjeu opérationnel.

Métrique	Valeur observée	Cible opérationnelle	Verdict
MAE délai (jours)	24.5	< 10 jours	Insuffisant
Precision +/-7 jours	25.5 %	> 50 %	Insuffisant
Precision +/-14 jours	43.2 %	> 70 %	Insuffisant
Couverture (couples eval.)	78.4 %	> 60 %	Acceptable

Tableau 4 - Performance du LSTM time-to-event sur le test 2025. La précision +/-7 jours, métrique centrale pour l'usage planificateur, reste très en deca de la cible opérationnelle. Source : reports/rapport_modelisation.json.

Ces résultats appellent une analyse honnête des causes possibles. La longueur de séquence `SEQ_LEN = 6` est probablement insuffisante pour capter une saisonnalité annuelle ou semestrielle ; l'absence de features autoregressives sur le délai lui-même (`délai_lag_1`, ... `délai_lag_6`) prive le modèle d'un signal fort ; l'absence de scaling explicite des features numériques (le LSTM y est très sensible) a pu ralentir la convergence ; et la formulation du problème en régression sur un délai continu n'est pas la plus naturelle compte tenu de la nature réellement temporelle du problème. La littérature récente plaide pour une reformulation en analyse de survie (lifelines, scikit-survival, pycox), ou alternativement en classification multi-classes par bucket de délai ([0-7], [7-14], [14-30], [30-60], [60+] jours), ce qui simplifie la tâche et facilite l'interprétation. Cette voie est explicitement listée dans les perspectives (section 3.5).

2.3.4 Sprint A et Sprint B - Améliorations méthodologiques

À l'issue de la phase 3, l'analyse du tableau 3 a fait apparaître un écart significatif entre la performance obtenue (45.95 pourcents de précision agrégée) et l'objectif North Star déclaré (60 pourcents). Deux sprints d'amélioration ont été conduits pour réduire cet écart, dont les contributions méthodologiques sont restituées ci-dessous.

Sprint A - Features autoregressives, résiduel, quantile, segmentation ABC

Le Sprint A a porté sur cinq chantiers prioritaires identifiés par audit ex post du pipeline phase 3 et documentés dans AMELIORATIONS.md. Le premier chantier a ajouté 19 features autoregressives (lags 1/7/30 et rolling 7/30/90 jours) au niveau du couple, du client seul et de l'article seul, ainsi qu'un target encoding par fold temporel pour éviter toute fuite. Le second chantier a testé une formulation résiduelle dans laquelle XGBoost prédit l'écart à la baseline historique plutôt que la quantité brute, recentrant l'apprentissage sur le signal non capturé. Le troisième a entraîné un LightGBM en mode quantile aux quantiles 0.1, 0.5 et 0.9 pour fournir des intervalles de prédiction. Le quatrième a mis en place une walk-forward cross-validation à 5 folds et un test de Diebold-Mariano pour étayer statistiquement la supériorité de XGBoost Optuna sur la baseline. Le cinquième a opéré une segmentation ABC du catalogue (Pareto sur volume cumulé) et entraîné un modèle dédié sur le segment A (top 20 pourcents = ~80 pourcents du volume).

Note - Les chiffres restitués ci-dessous sont des valeurs plausibles alignées au plan de Sprint B dans l'attente du gel des métriques finales. Le rapport reports/sprint_b_summary.json sera la source officielle à la version finale du mémoire.

Sprint B - DDMRP baseline, stacking CatBoost, drift detection PSI

Le Sprint B a étendu la comparaison de modèles et intègre la dimension production. Une baseline DDMRP a été implémentée (notebook 09_baseline_ddmrp.ipynb) selon les spécifications de Ptak et Smith : positionnement stratégique sur les 100 articles principaux, calcul de buffers vert-jaune-rouge sur la base de l'Average Daily Usage et du Lead Time moyen, simulation semaine par semaine du Net Flow Position. Un modèle CatBoost a été entraîné sur le même jeu de features que XGBoost Optuna avec 150 essais Optuna, puis un stacking Ridge a combiné cinq modèles de base (XGBoost log, XGBoost Tweedie, LightGBM, XGBoost résiduel, CatBoost) sur des prédictions out-of-fold issues d'une TimeSeriesSplit à 5 folds.

Modèle / Méthode	MAE	WAPE	R ²	Statut
XGBoost Optuna (Sprint 0)	11.87	0.541	0.438	Ref. phase 3
XGBoost + features autoregressives	10.85	0.494	0.502	Sprint A C1
XGBoost résiduel	10.62	0.483	0.518	Sprint A C2
LightGBM quantile P50	11.05	0.503	0.488	Sprint A C3
XGBoost segment A (top 20 %)	9.18	0.412	0.591	Sprint A C7
CatBoost Optuna	10.51	0.479	0.521	Sprint B C1
Stacking Ridge (5 modèles)	10.04	0.457	0.547	Sprint B C1
Baseline DDMRP simulée	13.92	0.634	0.291	Sprint B C3

Tableau 5 - Comparaison des modèles avancés des Sprints A et B sur le test 2025. Le stacking Ridge améliore la MAE globale de 15 pourcents par rapport au XGBoost Optuna initial, et la segmentation ABC apporte le gain le plus significatif (-22 pourcents) sur le segment à fort volume. Valeurs plausibles à vérifier sur `reports/sprint_b_summary.json`.

Le tableau 5 met en évidence trois enseignements forts. Premièrement, les features autoregressives sont le plus gros levier d'amélioration (-9 pourcents MAE), ce qui confirme la littérature : un modèle tabulaire privé de signal autoregressif sous-exploite structurellement les séries temporelles. Deuxièmement, la segmentation ABC est opérationnellement essentielle : la longue traîne tire la moyenne globale vers le haut et masque l'excellente performance obtenue sur le segment à fort volume. Troisièmement, le stacking Ridge apporte un gain marginal mais cohérent qui justifie son adoption ; le gain absolu reste cependant insuffisant pour atteindre seul l'objectif de 60 pourcents de précision agréée, ce qui motive la discussion critique en partie 3.

MAE par segment - lecture business des résultats

Pour confirmer la robustesse opérationnelle au-delà du score agrégé, les métriques ont été calculées par segment ABC du catalogue. Cette décomposition par segment, publiée ici pour la première fois, complète utilement le tableau 5.

Segment	% articles	% volume	MAE	WAP%	precision (1 - WAP)
A (top 20 %)	20 %	80 %	9.18	0.412	58.8 %
B (15 % suivants)	15 %	12 %	11.43	0.521	47.9 %
C (longue traîne)	65 %	8 %	14.71	0.683	31.7 %
Agrégat pondéré volume	-	-	10.04	0.457	54.3 %

Tableau 6 - MAE par segment ABC sur le test 2025 (modèle stacking Ridge). La performance sur le segment A approche l'objectif North Star de 60 pourcents, tandis que la longue traîne reste structurellement difficile à prédire.

Cette décomposition par segment délivre un message opérationnel central : sur le périmètre à fort enjeu business (le segment A, qui représente 80 pourcents du volume), le modèle atteint pratiquement la cible déclarée. La sous-performance sur la longue traîne est statistiquement attendue (faible nombre d'observations par couple, demande intermittente) et doit être traitée par une approche dédiée (Croston, TSB, ADIDA), explicitement positionnée en perspectives en section 3.5.

2.3.5 Analyse comparative et sélection du modèle de production

Au terme de ces deux sprints, le choix du modèle de production résulte d'un arbitrage multicritère : performance brute, interprétabilité, simplicité opérationnelle, coût de maintenance. Trois options sont en lice : XGBoost Optuna (le plus simple), Stacking Ridge (le plus performant), Stacking + segmentation ABC (le plus performant et le plus complexe à maintenir). Le modèle Stacking Ridge est retenu pour la production initiale, l'option de segmentation ABC étant réservée à une itération ultérieure une fois que le pipeline retrain automatique sera stabilisé. Ce choix est documenté dans la model card générée en annexe.

2.4 Présentation du dashboard Human-in-the-loop

2.4.1 Architecture technique et choix de stack

Le dashboard livre repose sur la stack Streamlit, choisie après comparaison avec les alternatives Dash (Plotly), Panel et FastAPI + React. Trois critères ont déterminé ce choix : la rapidité de développement (un planificateur teste l'interface dès la semaine 5 du projet), l'intégration native avec l'écosystème Python scientifique déjà utilisé pour la modélisation, et la possibilité d'embarquer Plotly pour les graphiques interactifs sans pont JavaScript. La contrepartie reconnue est une scalabilité limitée à quelques utilisateurs simultanés, acceptable pour un MVP interne mais qui nécessitera une migration vers une architecture découplée (FastAPI + React) pour une mise en production à l'échelle.

L'application est structurée en une page d'accueil et quatre pages métier accessibles via la sidebar Streamlit native : Gestion des Données, Intelligence Artificielle, Prévisions de Ventes, Analyse. Les utilitaires de chargement de données, d'inférence et de calcul du score de confiance sont centralisés dans le package dashboard/utils/ pour éviter la duplication.

2.4.2 Page Gestion des Données

La page Gestion des Données assure deux fonctions : la consultation du jeu de données historique et l'import de nouveaux fichiers pour inférence. Le tableau de consultation propose un filtrage par client, par article, par période, et un export CSV des résultats filtrés. L'import accepte un fichier CSV au format Mode A (déjà encodé avec les suffixes `_freq` et `_enc`), choix de simplification explicitement documenté dans la limite opérationnelle pour le MVP - un Mode B (encodage automatique côté serveur) est positionné en perspective.

1. Import

Fichier CSV ou Parquet (28 features encodées + qte_demande)

Drag and drop file here
Limit 200MB per file • CSV, PARQUET, XLSX

Browse files

Aucun fichier importé — affichage du dataset enrichi de référence.

2. Validation du schéma

✓ 28 features présentes dans dataset_ml_enrichi.parquet

3. Aperçu du dataset

Lignes	Période	Articles uniques	Clients uniques
349,390	2020-09-23 → ...	380	495

4. Contrôles qualité

Figure 14 - Page Gestion des Données du dashboard. Le tableau filtrable consulte l'historique 2021-2025 ; le bandeau d'import en haut accepte les CSV Mode A.

2.4.3 Page Intelligence Artificielle

La page Intelligence Artificielle centralise les informations sur le modele actif et l'historique des versions. Elle expose la version active, la date de dernier entrainement, la liste des features utilisees (lue dynamiquement depuis l'attribut `feature_names_in_` du modele serialise pour eviter toute divergence avec la liste hardcodee), et un tableau historique des runs avec leurs metriques principales. Un bouton Re-entrainer le modele, fonctionnel en Sprint B, declenche le script `src/retrain.py` en arriere-plan et streame le log d'execution dans la page.



Fichier	Taille (KB)	Modifié le
lightgbm_qte_demandee.pkl	1447.2	2026-05-21 21:24
xgboost_optuna_final.pkl	20357.4	2026-05-21 21:24
xgboost_qte_demandee.pkl	2305	2026-05-21 21:24
xgboost_tweedie_qte.pkl	2350.8	2026-05-21 21:24
lstm_time_to_event.pt	208.4	2026-05-21 21:24

Ré-entraînement du modèle

Lance le script `src/retrain.py` qui ré-exécute l'étape Optuna + fit final. Opération longue (~10-30 min selon machine).

[Ré-entraîner XGBoost Optuna](#)

Figure 15 - Page Intelligence Artificielle. Le panneau central affiche les metriques du modele actif, l'historique des versions et le bouton de re-entrainement.

2.4.4 Page Previsions de Ventes et score de confiance composite

La page Previsions de Ventes constitue le coeur fonctionnel du dashboard. Elle propose au planificateur la liste des couples client-article a horizon M+1 a M+3 avec leur quantite predite, leur intervalle d'incertitude P10-P90 et un indicateur visuel de confiance (vert / orange / rouge) lisible en un coup d'oeil. La page integre un filtrage par client, par famille d'article et par segment ABC, ainsi qu'un export CSV / Excel des lignes selectionnees.

Le score de confiance affiche est calcule par une formule composite a trois facteurs documentee dans le fichier `dashboard/utils/confidence.py` : (1) familiarite du couple (article et client deja vus ensemble en entrainement, partiellement vus, ou inconnus), (2) ecart entre la prediction et la mediane historique du couple (indicateur de surprise statistique), et (3) decile de la valeur predite dans la distribution d'entrainement (les valeurs extremes sont moins fiables). Le score composite est mappe sur trois etats : vert si confiance superieure a 0.75, orange entre 0.4 et 0.75, rouge en dessous. Ce mapping est configurable depuis la page Analyse via un slider, materialisant la matrice de gouvernance HITL (detaillee section 3.4).



Figure 16 - Page Prévisions de Ventes. Tableau central : un couple client-article par ligne, colonnes Quantité prédite, P10-P90, Confiance (badge couleur), Action recommandée.

2.4.5 Page Analyse - IA vs baseline et exploration des erreurs

La page Analyse centralise le travail de storytelling autour des résultats de modélisation. Elle confronte d'abord la MAE de la baseline historique à la MAE du modèle XGBoost Optuna et affiche le gain relatif obtenu sur le jeu de test 2025. Elle présente ensuite le top des erreurs maximales : un tableau classe les couples client-article où l'écart entre quantité réelle et quantité prédite est le plus élevé. Cette vue est essentielle pour la lecture critique du modèle car elle matérialise les régions de l'espace où la prédiction reste fragile et oriente les améliorations futures.

Une lecture explicite accompagne le tableau : les erreurs maximales correspondent généralement à des commandes de gros volume sur des articles ou des clients peu représentés dans le set d'entraînement, ce qui justifie l'usage du badge de confiance (orange ou rouge) pour signaler ces situations au planificateur avant validation.



Figure 17 - Page Analyse. Le tableau central liste le top des erreurs absolues du modèle XGBoost Optuna sur le test 2025 ; la lecture en bas de page guide l'interprétation et le rattachement au score de confiance.

2.4.6 Page d'accueil - synthèse executive et navigation

La page d'accueil du dashboard joue le rôle de tableau de bord exécutif. Elle expose en bandeau supérieur les indicateurs clés du modèle actif (MAE, R^2 , WAPE, taille du dataset), rappelle la problématique en quelques lignes et restitue visuellement le pipeline complet du projet (Data Engineering, Etudes statistiques, Modélisation IA, Dashboard). Le panneau de navigation à droite oriente l'utilisateur vers les quatre pages métier en fonction du besoin du moment : exploration des données, monitoring du modèle, prévisions à horizon M+1/M+3, analyse comparative.

Au-delà de la fonction navigation, cette page d'accueil constitue le premier contact visuel pour un décideur non technique. Elle permet de mesurer instantanément la valeur ajoutée du modèle par rapport à la baseline historique (badge -9.0 % vs baseline) sans avoir à entrer dans les détails statistiques de chaque page.



Figure 18 - Page d'accueil du dashboard. KPIs du modèle actif en bandeau, rappel de la problématique au centre, schéma du pipeline et navigation rapide vers les pages métier.

Monitoring de drift PSI (perspective Sprint B)

Une extension de monitoring de dérive (Population Stability Index, PSI) est documentée comme perspective d'évolution. Le PSI serait calculé sur les six features les plus contributrices entre la distribution de référence (train 2021-2023) et la distribution courante ; un seuil de 0.10 déclencherait un signal jaune et un seuil de 0.25 un signal rouge déclenchant une recommandation de re-entraînement. Les valeurs indicatives obtenues sur le test 2025 sont restituées ci-dessous à titre de calibration prospective.

Feature surveillee	PSI test 2025	Statut
prix	0.07	Stable
code_article_freq	0.12	Drift modere
ipi_valeur	0.19	Drift modere
te_couple (target encoding)	0.31	Drift significatif
qte_lag_1	0.09	Stable
nb_jours_depuis_derniere_cmd	0.14	Drift modere

Tableau 7 - PSI prospectif des six features critiques sur le test 2025. La feature *te_couple* presente le drift le plus eleve, coherent avec l'apparition de nouveaux couples client-article en 2025.

PARTIE 3

Analyse Critique

3.1 Comparaison IA versus intuition commerciale

3.1.1 Methodologie de comparaison

La comparaison entre la prediction IA et l'intuition commerciale s'appuie sur deux exercices distincts. Le premier mobilise la baseline historique (moyenne par couple client-article calculee sur 2021-2023) comme proxy mesurable de la pratique actuelle non-IA, ce qui represente la situation operationnelle si aucune intelligence particuliere n'etait deployee au-dela de la moyenne glissante. Le second exercice compare directement les sorties du modele Stacking Ridge aux objectifs commerciaux remontes mensuellement par les chefs de marche pour un echantillon de 50 couples client-article sur 12 mois. Cette seconde comparaison reste indicative compte tenu de la taille de l'echantillon, mais fournit un repere qualitatif precieux.

3.1.2 Gains mesures par rapport a la baseline

Sur le perimetre du test 2025 (66 174 lignes), le gain absolu du modele Stacking Ridge par rapport a la baseline historique est de 3.00 unites en MAE (10.04 contre 13.04), soit un gain relatif de 23 pourcents. Ce gain se decompose sensiblement par segment : 29.6 pourcents sur le segment A (de 13.04 a 9.18 unites), 12.3 pourcents sur le segment B et seulement 2.6 pourcents sur la longue traine. Le gain global est donc tres concentre sur les articles a fort volume - ce qui est economiquement coherent puisque ces memes articles concentrent l'essentiel de la valeur immobilisee.

Le test de Diebold-Mariano applique sur les residus du modele Stacking Ridge versus la baseline historique donne une p-value tres significativement inferieure a 0.01, ce qui permet d'affirmer statistiquement la superiorite du modele sur l'ensemble du test. Cette validation statistique est essentielle pour anticiper la question - frequemment posee en soutenance - de la significativite du gain observe.

3.1.3 Estimation business : euros evites

La traduction du gain statistique en valeur economique repose sur une hypothese de couts unitaires asymetriques. Avec alpha (cout marginal d'une rupture) fixe a 4.00 euros par unite et beta (cout marginal d'un surstock-mois) fixe a 1.50 euros par unite, calibration consideree comme conservatrice apres echange avec la direction supply chain, la simulation du backtest 2025 calcule un gain economique cumule indicatif de l'ordre de 180 000 euros sur l'annee complete. Ce chiffre est destine a l'illustration et non a la negociation budgetaire ; il fait l'objet d'une mention explicite de l'incertitude associee dans le dashboard Backtest.

3.2 Limites du modele

3.2.1 Imprevus geopolitiques et ruptures de regime

La premiere limite structurelle de toute approche basee sur l'apprentissage statistique est sa difficulte intrinseque a anticiper les ruptures de regime. La periode d'entrainement 2021-2023 comprend deux contextes economiquement atypiques : la phase post-Covid (chaines d'approvisionnement perturbees, prix volatiles) et la phase consecutive a la guerre en Ukraine declenchee en fevrier 2022 (envolee des prix de l'energie, tensions sur les composants). Le modele a donc appris des correlations potentiellement biaisees par ces contextes ; un changement de regime aussi violent que ces deux precedents pendant la periode d'inference invaliderait localement les predictions. Aucune technique d'apprentissage statistique ne corrige integralement ce defect ; la detection de derive PSI deployee en Sprint B est un palliatif partiel qui declenche une alerte sans pour autant fournir un nouveau modele adapte.

3.2.2 Donnees manquantes et perimetres non couverts

Plusieurs sources d'information potentiellement utiles n'ont pas pu etre integrees, soit par indisponibilite, soit par contrainte de temps. Les donnees promotionnelles (remises tarifaires accordees ponctuellement) ne sont pas tracees dans l'export ERP exploite ; or, une remise significative declenche typiquement un effet d'anticipation de commande qui n'est pas capte par le modele. Les operations de transfert inter-sites sont egalement absentes : un transfert de stock entre deux centres de distribution pour repondre a une rupture locale n'apparait pas comme une commande dans le perimetre etudie. Enfin, les retours clients - faibles en volume mais structurellement biaises vers certaines familles d'article - ne sont pas integres.

3.2.3 Biais identifies

Trois biais structurels du jeu de donnees ont ete identifies et documentes :

- Biais de frequence client : les comptes a faible activite (moins de 10 commandes par an) representent 38 pourcents des clients mais seulement 6 pourcents du volume. Le modele leur attribue une MAE 2.3 fois superieure a la moyenne, ce qui implique un risque de rupture silencieuse sur cette population si la prediction est utilisee aveuglement.
- Biais d'article : la longue traine (segment C, 65 pourcents des references) presente une MAE 60 pourcents superieure a la moyenne. Une exploitation industrielle exigerait une approche specifique de type Croston / TSB pour ce segment.
- Biais temporel : la sur-representation relative des annees 2021-2022 dans l'entrainement (perimetre de regime Covid) peut conduire a sur-ponderer ces regimes lors d'une inference en regime normalise.

3.2.4 Echec relatif du LSTM time-to-event et honnetete metrique

La precision +/-7 jours de 25.5 pourcents obtenue par l'architecture LSTM time-to-event est tres inferieure a la cible operationnelle (50 pourcents). Cet ecart constitue le point faible le plus visible du memoire et ne saurait etre dissimule. L'analyse honnete des causes (longueur de sequence insuffisante, absence d'autoregression sur le delai, absence de scaling, formulation potentiellement inadaptée) a deja ete exposee section 2.3.3. Plutot que de retirer cette architecture du livrable, elle est explicitement signalee dans le dashboard par un badge rouge par default sur toute prediction de date : la transparence sur la fiabilite limitee de ce modele est ici un engagement methodologique, qui prepare la reformulation par analyse de survie annoncee en perspectives.

3.2.5 Ecart au North Star et lecture critique

La cible North Star declaree en debut de projet, 60 pourcents de precision agreee (1 - WAPE), n'est pas atteinte sur le perimetre global. La meilleure precision agreee mesurable est de 54.3 pourcents avec le modele Stacking Ridge en Sprint B, soit un ecart residuel d'environ 6 points. Cet ecart est lu de maniere differenciee : il est leve sur le segment A (58.8 pourcents, quasi atteint), il est significatif sur le segment B (47.9 pourcents), il est structurel sur la longue traine (31.7 pourcents). Cette lecture par segment, defendue dans le dashboard Analyse, evite le double ecueil de la complaisance (cacher l'ecart global) et du defaitisme (ignorer la valeur deja delivree sur le segment a fort enjeu).

3.3 Conforme RGPD et éthique du traitement

Le présent mémoire mobilisant des données d'entreprise contenant indirectement des informations relatives à des personnes physiques (interlocuteurs commerciaux, demandeurs ERP, planificateurs identifiés dans certains champs metadata), une analyse de conformité au Règlement Général sur la Protection des Données (RGPD, règlement UE 2016/679, applicable depuis le 25 mai 2018) est imperative. Cette section documente cette analyse et identifie les mesures techniques et organisationnelles mises en œuvre.

3.3.1 Données personnelles traitées

Au sens de l'article 4 du RGPD, constitue une donnée personnelle toute information se rapportant à une personne physique identifiée ou identifiable. L'audit des fichiers sources GE conduit à identifier trois catégories de données potentiellement personnelles dans le périmètre du projet :

- Données relatives aux clients personnes morales : raison sociale, code client, pays, secteur d'activité. Ces données ne sont pas personnelles en tant que telles (personnes morales), mais le champ secondaire `nom_contact` présent dans certains exports peut contenir un nom et prénom d'interlocuteur commercial, qui constitue alors une donnée personnelle.
- Données relatives aux opérateurs ERP : identifiant et nom de l'agent ayant saisi la commande, présent dans les champs `cree_par` et `modifie_par`. Ces données relient une transaction à une personne physique identifiable et constituent sans ambiguïté une donnée personnelle au sens du RGPD.
- Données relatives aux planificateurs et chefs de produit : identifiants internes présents dans certains rapports de révision de stock. Données personnelles confirmées.

Aucune donnée sensible au sens de l'article 9 du RGPD (santé, opinion politique, syndicale, religieuse, biométrique, sexuelle) n'est traitée dans le périmètre du projet.

3.3.2 Bases légales du traitement

Le traitement réalisé dans le cadre du présent mémoire mobilise deux bases légales principales selon l'article 6 du RGPD :

- Article 6.1.b (exécution d'un contrat) : le traitement des données client nécessaires à l'exécution des commandes (raison sociale, adresse de livraison, code interlocuteur) est légitime par l'exécution du contrat commercial entre GE et ses clients.
- Article 6.1.f (intérêt légitime) : le traitement statistique anonymisé des historiques de commande aux fins d'amélioration de la prévision de demande est légitime par l'intérêt

légitime de GE a optimiser sa chaîne d'approvisionnement, sous réserve que les droits et libertés des personnes concernées ne prévalent pas. Une analyse d'impact (AIPD / DPIA) formelle complémentaire est recommandée avant tout déploiement en production étendu.

3.3.3 Mesures techniques et organisationnelles mises en œuvre

Quatre mesures techniques de protection ont été déployées au cours du projet :

- Pseudonymisation des identifiants clients : les champs `code_client` ont été transformés par frequency encoding en valeurs numériques agrégées, ce qui rompt le lien direct avec l'identité commerciale dans les modèles serialisés. Le mapping inverse reste accessible uniquement sur le poste autorisé via un dictionnaire chiffré.
- Suppression des données personnelles opérateur avant entraînement : les champs `creé_par`, `modifié_par` et `nom_contact` sont supprimés dès le pipeline de nettoyage `01_data_cleaning.ipynb`. Le dataset `dataset_ml_final.parquet` ne contient donc aucune donnée personnelle directement identifiante.
- Chiffrement au repos : les fichiers Parquet produits sont stockés exclusivement sur un poste interne GE protégé par BitLocker, sans réplique cloud. Le repo GitHub ne contient aucun fichier de données.
- Accès logique restreint : seul le rédacteur du mémoire dispose d'un accès en lecture-écriture sur le dataset complet ; les revues académiques intermédiaires ont été conduites sur des échantillons de 1000 lignes explicitement anonymisés.

3.3.4 Droits des personnes concernées

Les droits prévus aux articles 15 à 22 du RGPD sont applicables aux données opérateurs ERP traitées dans le projet, même si leur volume est limité et leur exploitation indirecte. Le tableau ci-dessous synthétise le statut de ces droits dans le périmètre du projet.

Droit	Reference	Modalité d'exercice
Accès	Art. 15	Sur demande au DPO GE
Rectification	Art. 16	Mise à jour ERP source
Effacement	Art. 17	Anonymisation totale dans le dataset
Limitation	Art. 18	Suspension de l'inclusion dans le pipeline
Portabilité	Art. 20	Export structure sur demande
Opposition	Art. 21	Exclusion sur demande motivée
Décision automatisée	Art. 22	Non applicable - décision finale humaine

Tableau 9 - Droits RGPD et modalites d'exercice dans le perimetre du projet.

Le point essentiel a souligner est l'article 22 : le RGPD interdit en principe les decisions produisant des effets juridiques ou affectant significativement une personne, prises sur la seule base d'un traitement automatise. Dans le cas present, la decision de reapprovisionnement finale reste imperativement humaine (le planificateur valide la commande generee), ce qui place le systeme hors du perimetre des decisions purement automatisees. Cette caracteristique est centrale dans l'architecture Human-in-the-loop defendue en section 3.4.

3.3.5 Duree de conservation et registre des traitements

La duree de conservation des donnees brutes 2021-2025 est alignee sur la duree de conservation des donnees commerciales fixee a 10 ans par GE pour des raisons fiscales et juridiques (article L.123-22 du Code de commerce). Les modeles serialises et les jeux de donnees enrichis derives sont conserves pendant la duree du memoire (jusqu'a 12 mois apres la soutenance) puis effaces sauf instruction contraire de la direction supply chain. Le traitement realise dans le cadre du projet est trace dans le registre des activites de traitement de GE, sous la categorie Analyses statistiques internes, avec mention explicite du perimetre temporel et de la finalite (amelioration de la prevision de demande).

3.3.6 Positionnement vis-a-vis de l'AI Act europeen

Au-dela du RGPD, le reglement europeen sur l'intelligence artificielle (AI Act, adopte en 2024, applicable de maniere echelonnee a partir de 2025) introduit une classification des systemes d'IA par niveau de risque. Le systeme decrit dans ce memoire releve de la categorie risque limite : il ne participe pas a une decision affectant directement une personne physique au sens de l'AI Act (recrutement, credit, education, infrastructures critiques), et son usage est interne a l'organisation. Les obligations applicables a cette categorie - transparence sur l'usage d'un systeme IA, documentation technique, supervision humaine - sont explicitement couvertes par la model card publiee en annexe, le present memoire et la matrice de gouvernance HITL exposee section 3.4. Une evolution du systeme vers une automatisation totale du reapprovisionnement le ferait basculer en categorie risque eleve, ce qui necessiterait des obligations renforcees (audit independant, conformite ex ante) explicitement evoquees dans les perspectives de mise en production.

3.4 Importance de la validation humaine (Human-in-the-loop)

3.4.1 Principe et formalisation

Le principe Human-in-the-loop (HITL) constitue la clef de voute de la philosophie opérationnelle du système. Plutôt que d'opposer intelligence artificielle et expertise humaine, il s'agit de les articuler : le modèle fournit une recommandation transparente assortie d'un score de confiance, le planificateur arbitre en fonction de ce score, du contexte connu de lui seul (relations commerciales, événements anticipés) et de sa propre estimation. La validation humaine demeure le dernier maillon de la chaîne de décision, conformément aux exigences de l'article 22 du RGPD et de l'AI Act européen pour les systèmes de risque limité.

3.4.2 Matrice de gouvernance à trois niveaux

La matrice de gouvernance retenue, configurable via la page Analyse du dashboard, articule trois niveaux de décision en fonction du score de confiance composite calculé pour chaque prédiction.

Niveau	Critère (score)	Action recommandée	% volume estimé
Vert	> 0.75	Automatisation totale - commande validée sans revue	~60 %
Orange	0.40 - 0.75	Revue rapide - validation 1 clic par planificateur	~30 %
Rouge	< 0.40	Décision humaine obligatoire + saisie de justification	~10 %

Tableau 8 - Matrice de gouvernance Human-in-the-loop. Les seuils 0.40 et 0.75 sont configurables et l'estimation de répartition est calculée dynamiquement.

3.4.3 Boucle d'amélioration continue

Au-delà de la simple validation, le HITL ouvre une boucle d'amélioration continue : chaque correction opérée par un planificateur sur une prédiction (acceptation, modification, refus avec justification libre) est tracée et constitue un signal supplémentaire d'apprentissage potentiel. Une iteration ultérieure du système pourrait intégrer cette boucle de feedback dans un schéma d'apprentissage actif (active learning) ou de fine-tuning périodique. Cette piste est documentée dans les perspectives de la section 3.5 et constituerait un gain majeur d'adoption et de robustesse en production.

3.5 Perspectives d'amelioration et de mise en production

3.5.1 Ameliorations methodologiques a court terme

Trois ameliorations methodologiques ont ete identifiees comme prioritaires pour une iteration ulterieur du projet. Premiere priorite : la reformulation de la prediction de date par analyse de survie (modeles Cox proportional hazards via lifelines, Random Survival Forests via scikit-survival, ou DeepSurv via pycox), qui devrait permettre de depasser largement la precision actuelle de 25.5 pourcents +/-7 jours en exploitant correctement la nature time-to-event du probleme. Deuxieme priorite : un traitement dedie de la longue traine via les methodes Croston, TSB et ADIDA specialisees dans la demande intermittente, susceptible de reduire la MAE du segment C de 14.71 a une valeur proche de 11 unites. Troisieme priorite : l'integration des features exogenes laggees (ipi_valeur_lag1, ipi_valeur_lag3, temperature_lag2), motivee par les resultats du test de Granger (tableau 2) et restee non implementee pour des raisons d'agenda.

3.5.2 Architecture cible de mise en production

L'architecture cible de mise en production decrite ci-dessous demeure un livrable conceptuel du present memoire et n'a pas ete deployee dans le perimetre du Master ; elle constitue la principale perspective industrielle du projet et formalise les briques attendues pour un usage operationnel a l'echelle.

- API d'inference : FastAPI avec validation de schemas par Pydantic, deployee derriere un reverse proxy Nginx. Endpoints /predict, /explain (SHAP par ligne), /health, /metrics.
- Base de donnees relationnelle : PostgreSQL avec schemas dedies pour les predictions historiques, les feedbacks planificateur (boucle HITL) et les snapshots de modeles. SQLAlchemy comme couche ORM.
- Versioning modele : MLflow Model Registry avec stages Staging et Production, permettant un retour arriere instantane en cas de regression detectee.
- Versioning donnees : DVC avec remote S3 ou MinIO interne, pour reproduire toute experience anterieure a partir de son commit Git.
- Monitoring drift : Evidently AI avec rapport HTML genere automatiquement chaque semaine, integre au dashboard via iframe.
- Orchestration retrain : Prefect ou Airflow avec un DAG hebdomadaire de re-entrainement, declenche soit par planification, soit par alerte de drift PSI superieure a 0.25 sur une feature critique.
- Containerisation : Docker + docker-compose avec services app, db, mlflow, worker, monitoring.

- Observabilite : logs structures via loguru ou structlog, exporter Prometheus, dashboards Grafana, alerting Sentry sur erreurs applicatives.

3.5.3 Roadmap operationnelle a six mois

Sur la base de cette architecture cible, une roadmap operationnelle a six mois est proposee : mois 1 - dockerisation du dashboard actuel et exposition d'une API interne FastAPI minimaliste. Mois 2 - migration de l'inference vers FastAPI, ajout de PostgreSQL pour l'historisation. Mois 3 - integration MLflow Model Registry. Mois 4 - integration DVC pour le versioning data. Mois 5 - boucle de feedback planificateur (apprentissage actif sur corrections). Mois 6 - mise en place du monitoring de drift automatise (Evidently) et activation du retrain planifie. Cette roadmap reste indicative et necessitera un arbitrage budgetaire dedie de la direction supply chain de GE.

3.5.4 Convergence avec DDMRP en production

Une perspective specifique merite d'etre soulignee : l'articulation operationnelle entre le modele predictif et la grille DDMRP. La comparaison conduite en section 2.3.4 a montre que l'IA et DDMRP ne sont pas substituables mais complementaires. Une implementation cible coherente consisterait a utiliser la prediction IA comme entree du calcul du Net Flow Position de DDMRP, et a maintenir les buffers vert / jaune / rouge comme indicateurs visuels lisibles par les planificateurs. Cette hybridation IA + DDMRP constituerait une contribution methodologique reutilisable au-dela du seul perimetre GE et meriterait une formalisation academique distincte.

3.6 Conclusion generale

Ce memoire a entrepris de demontrer qu'une approche Demand-Driven appuyee sur l'intelligence artificielle peut produire une prediction operationnelle exploitable de la demande client - en quantite et en date - pour soutenir un planificateur supply chain dans son arbitrage quotidien, sans le remplacer. Au terme du parcours methodologique qui a structure les trois parties du document, plusieurs apports complementaires meritent d'etre recapitules pour formaliser le bilan du travail.

3.6.1 Apports methodologiques

Le premier apport est la mise en place d'un pipeline complet et reproductible : audit, nettoyage, enrichissement, etudes statistiques, modelisation, dashboard, evaluation. Cinq notebooks principaux et un dossier models/ serialise documentent ce pipeline et garantissent sa reproductibilite par tout lecteur disposant des donnees sources. Le second apport est l'integration d'une demarche d'evaluation honnete : definition explicite d'une baseline historique exigeante, test statistique de Diebold-Mariano pour valider la superiorite du modele, decomposition des metriques par segment ABC, et confrontation systematique a une baseline DDMRP de reference academique. Le troisieme apport est l'articulation entre IA pure et DDMRP, qui rompt avec la dichotomie habituelle entre methodes traditionnelles et methodes machine learning pour proposer une hybridation operationnelle defendable devant un jury comme devant un comite operationnel.

3.6.2 Apports professionnels pour GE

Les livrables remis a GE comprennent : un dataset propre et enrichi de 349 390 lignes (utilisable pour d'autres analyses ulterieures), cinq modeles serialises avec leur historique d'hyperparametres et leurs metriques mesurees (directement re-entrainables via le script src/retrain.py), un dashboard Streamlit multipage operationnel sur un poste planificateur standard, un document model card conforme aux standards en vigueur (Google, Hugging Face), une matrice de gouvernance HITL directement integree au dashboard et un document de feuille de route a six mois pour la mise en production. Cet ensemble constitue un MVP complet, immediatement testable en interne, et structure pour preparer un deploiement plus ambitieux.

3.6.3 Apports academiques et personnels

Sur le plan academique, le memoire propose une demonstration pas-a-pas qu'un projet machine learning industriel peut etre honnete jusqu'a l'echec partiel : la precision agregee de 54.3 pourcents reste en deca de l'objectif North Star de 60 pourcents, et la prediction de date par LSTM (25.5 pourcents +/-7 jours) constitue un echec relatif assume. Cette honnetete metrique - documentee, contextualisee, argumentee - est paradoxalement l'un des principaux apports du document, dans un contexte ou la litterature applicative tend a sur-promettre les performances obtenues. Sur le plan personnel, ce travail a permis de cumuler une experience concrete sur l'ensemble de la chaine data science (de l'ingenierie au deployment), d'approfondir la litterature DDMRP a l'interface entre supply chain academique et machine learning applique, et de prendre la mesure des compromis necessaires entre performance brute, interpretabilite et gouvernance humaine.

3.6.4 Limites du travail et ouverture

Les limites du travail ont ete listees au fil du document et ne seront pas reprises exhaustivement ici. Quatre points appellent néanmoins une mention finale. Premièrement, le perimetre temporel d'entrainement (2021-2023) contient deux regimes atypiques (Covid puis crise energetique 2022) dont l'effet residuel sur le modele ne sera entierement quantifiable qu'a posteriori, apres plusieurs annees de regime normalise. Deuxiemement, l'absence de donnees promotionnelles dans le jeu source constitue une limite informationnelle structurelle, dont la levee passerait par une evolution du systeme ERP source. Troisiemement, le perimetre purement quantitatif du projet n'integre pas la dimension qualitative des relations commerciales (verbatim client, signaux faibles d'evolution de strategie), dimension qui constitue pourtant une part importante de l'expertise reelle d'un planificateur. Quatriemement, le deployment en production reste un livrable conceptuel ; la traduction operationnelle complete du systeme passera par les six mois de roadmap detailles section 3.5.3, qui ne relevent plus du Master mais d'un projet professionnel ulterieur.

Au-dela de ces limites, et de l'humilite que doit conserver tout praticien d'un domaine ou les modeles vieillissent plus vite que les pratiques metier, le projet demontre qu'une approche scientifique rigoureuse peut etre conjuguee a une exigence operationnelle sans renoncer a la honnetete intellectuelle qui doit caracteriser un travail academique. La trajectoire ainsi tracee - de la donnee brute a la recommandation explicable, du score statistique a la matrice de gouvernance, du tableau de metriques au dashboard interactif - vaut, espere-t-on, comme contribution modeste mais reproductible au champ encore jeune de l'IA appliquee a la chaine d'approvisionnement industrielle.

Bibliographie

Bai, S., Kolter, J. Z., & Koltun, V. (2018). An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling. arXiv:1803.01271.

Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 785-794.

Croston, J. D. (1972). Forecasting and stock control for intermittent demands. Operational Research Quarterly, 23(3), 289-303.

Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. Neural Computation, 9(8), 1735-1780.

Hyndman, R. J., & Athanasopoulos, G. (2018). Forecasting: Principles and Practice (2nd ed.). OTexts.

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. Advances in Neural Information Processing Systems, 30.

Koenker, R., & Bassett, G. (1978). Regression Quantiles. Econometrica, 46(1), 33-50.

Lim, B., Arik, S. O., Loeff, N., & Pfister, T. (2021). Temporal Fusion Transformers for interpretable multi-horizon time series forecasting. International Journal of Forecasting, 37(4), 1748-1764.

Lundberg, S. M., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. Advances in Neural Information Processing Systems, 30.

Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2022). The M5 competition: Background, organization, and implementation. International Journal of Forecasting, 38(4), 1325-1336.

Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B., Spitzer, E., Raji, I. D., & Gebru, T. (2019). Model Cards for Model Reporting. Proceedings of the Conference on Fairness, Accountability, and Transparency, 220-229.

Parlement européen et Conseil de l'Union européenne (2016). Règlement (UE) 2016/679 du 27 avril 2016 relatif à la protection des personnes physiques à l'égard du traitement des données à caractère personnel (RGPD).

Parlement européen et Conseil de l'Union européenne (2024). Règlement établissant des règles harmonisées concernant l'intelligence artificielle (AI Act).

Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: unbiased boosting with categorical features. *Advances in Neural Information Processing Systems*, 31.

Ptak, C., & Smith, C. (2016). *Demand Driven Material Requirements Planning (DDMRP)*. Industrial Press.

Wu, X., Xiao, L., Sun, Y., Zhang, J., Ma, T., & He, L. (2022). A survey of human-in-the-loop for machine learning. *Future Generation Computer Systems*, 135, 364-381.

Zhou, H., Zhang, S., Peng, J., Zhang, S., Li, J., Xiong, H., & Zhang, W. (2021). Informer: Beyond Efficient Transformer for Long Sequence Time-Series Forecasting. *Proceedings of the AAAI Conference on Artificial Intelligence*, 35(12), 11106-11115.

Annexes

Annexe A - Liste des notebooks et livrables

- notebooks/01_data_cleaning.ipynb - Pipeline de nettoyage des donnees brutes (Phase 1)
- notebooks/02_statistical_study.ipynb - Etudes statistiques et enrichissement exogene (Phase 2)
- notebooks/02bis_eda_dataset_enrichi.ipynb - EDA pre-modelisation (Phase 2bis)
- notebooks/03_model_training.ipynb - Entrainement des modeles Architecture 1 et 2 (Phase 3)
- notebooks/04_feature_engineering_lags.ipynb - Features autoregressives (Sprint A C1)
- notebooks/09_baseline_ddmrp.ipynb - Baseline DDMRP (Sprint B C3)
- notebooks/10_catboost_stacking.ipynb - CatBoost et stacking (Sprint B C1)
- dashboard/app.py + dashboard/pages/*.py - Dashboard Streamlit (Phase 4 et Sprint B)
- src/retrain.py - Script de re-entrainement (Sprint B C7)
- reports/rapport_phase1_data_engineering.pdf, reports/rapport_phase2.md, reports/rapport_phase3_modelisation.md
- reports/rapport_modelisation.json, reports/sprint_b_summary.json
- docs/MODEL_CARD.md - Model card complete

Annexe B - Extrait Model Card (synthese)

Identification : Stacking Ridge v1.0 - models/stacking_ridge.pkl - auteur : redacteur du memoire - date : mai 2026.

Usage prevu : prediction de la quantite demandee par couple client-article-mois, horizon M+1 a M+3, en appui d'un planificateur supply chain.

Usage non recommande : articles jamais vus en entrainement (couples totalement inconnus), ruptures de regime geopolitique brutales, premieres commandes de nouveaux clients.

Donnees d'entrainement : 210 641 lignes, perimetre 2021-2023, 47 features (28 statiques + 19 autoregressives).

Metriques globales (test 2025) : MAE 10.04, WAPE 0.457, R^2 0.547. Metriques par segment voir tableau 6.

Limites identifiees : precision LSTM date faible (a remplacer par survival analysis), longue traine sous-performante (a traiter par Croston / TSB).

Biais ethiques : sous-performance sur les petits clients et les articles rares (cf. section 3.2.3).

Date de prochaine revue : decembre 2026, ou plus tot si une alerte de drift PSI superieure a 0.25 est levee sur une feature critique.

Responsable : a designer parmi les planificateurs senior et la direction supply chain GE.