



MEMOIRE DE FIN D'ETUDES

École 89 - Deep Tech

M1 Expert IT - IA et Big Data

Système de Prévission et d'Optimisation des Stocks

*Une approche Demand-Driven appuyee sur l'Intelligence Artificielle pour la
prédiction de la demande client chez GE*

Realise par

Adham Marrakchi

Sous la direction de

Najib AL AWAR

Année universitaire 2025 - 2026

Résumé

Ce mémoire présente la conception, l'implémentation et la critique d'un système de prévision de la demande client basé sur l'intelligence artificielle, appliqué aux données opérationnelles de GE pour la période 2021-2025. Le projet répond à une problématique industrielle concrète : dépasser le pilotage traditionnel par objectifs de chiffre d'affaires, source récurrente de ruptures de stock et de surstocks, en adoptant une approche Demand-Driven structurée autour d'une double prédiction (quantité et date de prochaine commande).

La méthodologie articule un pipeline complet couvrant la consolidation des données, l'analyse statistique, la modélisation et la mise en service opérationnelle. La consolidation a produit un jeu de données de 349 390 lignes nettoyées et enrichies de 35 colonnes incluant des sources exogènes (indice de production industrielle INSEE, données météo, jours fériés, calendrier scolaire), portées à 47 features modèle après ingénierie autorégressive. Les études statistiques ont confirmé la présence de cycles budgétaires et météorologiques et identifient sept variables exogènes Granger-causales sur la demande. Quatre familles de modèles ont été confrontées (XGBoost, LightGBM, CatBoost, LSTM) avec optimisation Optuna et stacking Ridge. Le modèle XGBoost v2 (47 features, 300 essais Optuna) atteint une MAE de 8.42 unités sur le test 2025 ($1 - \text{WAPE} = 61.7$ pourcents), dépassant la cible North Star de 60 pourcents. L'architecture Stacking Ridge (XGBoost + LightGBM Quantile + CatBoost) améliore le RMSE et le R^2 (97.55 et 0.694), tandis qu'une baseline DDMRP académique sert de point de comparaison métier. Un dashboard Streamlit multipage a été livré, intégrant score de confiance composite, simulation what-if, backtest semaine par semaine et détection de dérive (Population Stability Index).

L'analyse critique discute honnêtement les limites observées (précision à sept jours limitée à 25.5 pourcents pour la prédiction de date, sous-performance sur la longue traîne), documente la conformité RGPD du traitement et formalise une matrice de gouvernance humain-dans-la-boucle (HITL). Le mémoire conclut sur une feuille de route de mise en production (FastAPI, PostgreSQL, MLflow, Evidently) et sur la valeur reproductible d'une approche académique honnête confrontée à un terrain industriel réel.

Mots-clés : prévision de la demande, supply chain, XGBoost, LightGBM, CatBoost, stacking, régression quantile, LSTM, DDMRP, drift PSI, human-in-the-loop, RGPD, Streamlit.

Abstract

This master's thesis presents the design, implémentation and critical évaluation of an AI-driven demand forecasting system applied to five years (2021-2025) of operational data from GE. The project addresses a concrète industrial problem: moving beyond traditional revenue-target driven planning, which is a recurring source of stockouts and overstocks, by adopting a Demand-Driven approach structured around two complementary prédictions (quantity and date of next order).

The methodology articulates an end-to-end pipeline spanning data consolidation, statistical analysis, modeling and operational deployment. The consolidation produced a 349,390-row cleaned dataset enriched with 35 columns including exogenous sources (industrial production index, weather data, public holidays, school calendar), expanded to 47 model features after autorégressive feature engineering. Statistical studies confirmed budgetary and weather cycles and identified seven Granger-causal exogenous drivers of demand. Four model families (XGBoost, LightGBM, CatBoost, LSTM) were compared with Optuna tuning and Ridge stacking. The XGBoost v2 model (47 features, 300 Optuna trials) reaches a test MAE of 8.42 units on 2025 ($1 - \text{WAPE} = 61.7$ percent), exceeding the 60 percent North Star target. A Stacking Ridge architecture (XGBoost + LightGBM Quantile + CatBoost) improves RMSE and R-squared (97.55 and 0.694), while a DDMRP academic baseline serves as a domain référence. An interactive Streamlit multipage dashboard was delivered with composite confidence scoring, what-if simulation, weekly backtest and Population Stability Index drift détection.

The critical analysis honestly discusses observed limitations (date prédiction accuracy of only 25.5 percent within ± 7 days, underperformance on the long tail), documents GDPR compliance and formalizes a human-in-the-loop governance matrix. The thesis concludes with a productionization roadmap (FastAPI, PostgreSQL, MLflow, Evidently) and reflects on the reproducible value of an academically honest approach confronted with a real industrial setting.

Keywords: demand forecasting, supply chain, XGBoost, LightGBM, CatBoost, stacking, quantile régression, LSTM, DDMRP, PSI drift, human-in-the-loop, GDPR, Streamlit.

Sommaire

Introduction générale	7
Partie 1 - Contexte et Problématique	9
1.1 Présentation de GE et perimetre du mémoire	9
1.2 Limites de la gestion par objectifs de chiffre d'affaires	11
1.3 Problématique et question de recherche	13
1.4 Revue de littérature	15
Partie 2 - Solution Technique	18
2.1 Méthodologie Data Engineering	18
2.2 Résultats des études statistiques	21
2.3 Architecture et performances des modèles IA	28
2.4 Présentation du dashboard Human-in-the-loop	35
Partie 3 - Analyse Critique	43
3.1 Comparaison IA versus intuition commerciale	43
3.2 Limites du modèle	44
3.3 Conformité RGPD et éthique du traitement	46
3.4 Importance de la validation humaine (Human-in-the-loop)	49
3.5 Perspectives d'amélioration et de mise en production	50
3.6 Conclusion générale	52
Bibliographie	54
Annexes	56

Liste des figures

Figure 1 - Décomposition STL globale de la demande 2021-2025

Figure 2 - Décomposition STL par famille d'article

Figure 3 - Cycles budgétaires clients (pics de fin de trimestre)

Figure 4 - Cycles météorologiques et impact sur la demande

Figure 5 - Matrice de corrélation de Pearson

Figure 6 - P-values du test de causalité de Granger

Figure 7 - Distribution de la cible (qte_demandee) avant et après log1p

Figure 8 - Auto-correlation (ACF) et partial ACF (PACF)

Figure 9 - Split temporel train / val / test

Figure 10 - Feature importance du modèle XGBoost v2

Figure 11 - Capture dashboard : page Gestion des Données

Figure 12 - Capture dashboard : page Intelligence Artificielle

Figure 13 - Capture dashboard : page Prévisions de Ventes (tableau et badges)

Figure 14 - Capture dashboard : page Prévisions (graphique pred vs réel)

Figure 15 - Capture dashboard : page Prévisions (simulation what-if)

Figure 16 - Capture dashboard : page Analyse

Figure 17 - Capture dashboard : page Drift Détection

Figure 18 - Capture dashboard : page Backtest interactif

Figure 19 - Capture dashboard : page d'accueil

Liste des tableaux

Tableau 1 - Synthèse de la qualité des données après nettoyage

Tableau 2 - Variables exogènes Granger-causales

Tableau 3 - Comparaison des modèles de première génération (test 2025)

Tableau 4 - Performance LSTM time-to-event

Tableau 5 - Benchmark complet des architectures (XGBoost v2, LightGBM Quantile, CatBoost, Stacking Ridge, DDMRP)

Tableau 6 - Comparaison IA vs DDMRP sur articles stratégiques

Tableau 7 - PSI des features critiques sur le test 2025

Tableau 8 - Matrice de gouvernance Human-in-the-loop

Tableau 9 - Registre simplifié des traitements (RGPD)

Introduction générale

Les chaînes d'approvisionnement industrielles ont été soumises, depuis la crise sanitaire de 2020 et les tensions géopolitiques qui ont suivi, à une pression sans précédent sur leur capacité à anticiper la demande client. Dans ce contexte, les approches traditionnelles de planification basées sur l'extrapolation linéaire d'objectifs commerciaux montrent leurs limites : ruptures de stock qui erodent la satisfaction client, surstocks qui immobilisent un capital significatif, décisions de réapprovisionnement réactives plutôt qu'anticipatives.

Le présent mémoire s'inscrit dans cette problématique à partir d'un terrain industriel concret : la chaîne d'approvisionnement de l'entreprise GE, commanditaire de la mission. Le matériau principal est constitué d'un historique de cinq années (2021-2025) de commandes et de livraisons clients, soit près de 350 000 lignes de transactions, complété par des sources exogènes publiques (indice de production industrielle de l'INSEE, données météorologiques via Open-Meteo, calendrier des jours fériés).

L'objectif central est de démontrer qu'une approche Demand-Driven appuyée sur l'intelligence artificielle peut produire une prédiction opérationnelle exploitable de la demande client - en quantité ET en date - et offrir ainsi un appui scientifique au planificateur sans le remplacer. La cible déclarée au lancement du projet, une précision moyenne supérieure à 60 pourcents (mesurée par $1 - \text{WAPE}$), sert de fil conducteur. Comme nous le verrons, cet objectif est atteint sur la quantité demandée (61.7 pourcents constatés sur le jeu de test 2025 avec le modèle XGBoost v2), tandis que la prédiction de date par LSTM reste insuffisante (25.5 pourcents ± 7 jours). Cette dualité des résultats - réussite sur la quantité, échec relatif sur la date - constitue un matériau méthodologique riche : elle obligera à documenter les limites du modèle de date, à expliciter les biais structurels du jeu de données, et à formaliser une gouvernance hybride associant systématiquement l'expertise humaine.

Le mémoire est organisé en trois parties. La première partie pose le contexte industriel de GE, décrit les limites de la gestion par objectifs commerciaux, formule la problématique et restitue l'état de l'art sur la prévision de la demande (DDMRP, gradient boosting, deep learning temporel, régression quantile, Human-in-the-Loop). La deuxième partie déploie la solution technique : pipeline de données, études statistiques, comparaison de quatre familles de modèles avec optimisation et stacking, et description du dashboard interactif livré. La troisième partie ouvre l'analyse critique - comparaison de l'IA aux pratiques actuelles, discussion des limites, conformité RGPD, matrice de gouvernance humain-dans-la-boucle, perspectives de mise en production - et conclut sur l'apport de cette démarche académique au terrain industriel.

PARTIE 1

Contexte et Problématique

1.1 Présentation de GE et perimetre du mémoire

1.1.1 L'entreprise GE et la mission confiee

L'entreprise GE est le commanditaire de la mission ayant donne lieu au present mémoire. Conformément aux termes de la mission, le perimetre etudie est circonscrit à la chaîne d'approvisionnement de l'entreprise et aux données opérationnelles de commande et de livraison clients sur la période 2021-2025. Le presente document ne formule aucune affirmation supplementaire sur l'activite, le secteur, l'organisation ou la stratégie de GE au-delà de ce qui se deduit directement des données étudiées ou du cahier des charges transmis à l'étudiant.

Le constat de depart documente dans le brief de mission est clair : la gestion actuelle des stocks s'appuie sur des objectifs de chiffre d'affaires négociés, et ce mode de pilotage genere des ruptures et des surstocks récurrents. La section 1.2 du present mémoire detaillera les limites structurelles de cette approche ; la presente section se borne a decrire le matériau exploite.

1.1.2 Matériau exploite : structure du dataset

Le matériau analytique mis a disposition par GE est un export consolide des commandes et livraisons clients couvrant la période 2021 à 2025. Après consolidation et nettoyage (détail en section 2.1), le jeu final comprend 349 390 lignes de transactions. Chaque ligne represente une commande individuelle d'un client sur un article à une date donnée. Les variables exploitees, telles qu'identifiées dans le brief de mission et vérifiées dans les fichiers sources, sont les suivantes :

- Identifiants : code_article, code_client, num_commande.
- Cibles a predire : qte_demandee (quantité commandee), date_livraison_demandee (date a laquelle le client souhaite être livre).
- Variables descriptives client : famille_activite_client, pays, devise, type_activite.
- Variables descriptives article : famille_activite_article, segment, prix.
- Variables de contexte : qte_livree (utilisee pour évaluer l'écart entre demande exprimee et demande effectivement servie), statut de la commande, dates d'enregistrement et de livraison effective.

Le contenu métier spécifique des modalités (par exemple le sens precis des libelles de famille_activite_article ou des segment du catalogue) n'est pas decrit dans ce mémoire : ces informations relevent du détail opérationnel interne de GE et ne sont pas necessaires à la conduite des analyses statistiques présentées, qui reposent sur la structure du jeu de données et

non sur l'interprétation sémantique des modalités.

1.1.3 Perimetre et exclusions explicites

Le perimetre temporel couvre exclusivement les commandes et livraisons de 2021 à 2025 inclus. Sont en revanche en dehors du perimetre, par indisponibilité ou par choix méthodologique : les opérations promotionnelles, les retours clients, les transferts internes inter-sites, et toute affirmation qualitative sur les pratiques commerciales de GE qui ne se déduirait pas directement du jeu de données fourni. L'utilisateur cible du système propose est le planificateur supply chain de GE, conformément au scenario Human-in-the-loop défini dans le brief de mission (section 5 du cahier des charges).

1.2 Limites de la gestion par objectifs de chiffre d'affaires

1.2.1 Le pilotage par objectifs commerciaux

Le brief de mission communiqué par GE indique explicitement que la gestion des stocks s'appuie sur des objectifs de chiffre d'affaires, et que ce mode de pilotage genere des ruptures et des surstocks récurrents. Sans documenter ici le détail des processus internes de planification de GE, on peut identifier trois limites structurelles génériques d'une planification orientée CA, documentées dans la littérature supply chain (Hyndman et Athanasopoulos, 2018) et cohérentes avec le constat opéré par l'entreprise.

Premièrement, ce type de pilotage confond l'objectif (volume cible) et la prévision (volume probable), ce qui introduit un biais d'optimisme systématique. Deuxièmement, il est par construction insensible aux dynamiques infra-mensuelles : un objectif mensuel ne dit rien des pics de fin de semaine ou des creux post-vacances mis en évidence dans l'analyse exploratoire (sections 2.2.3 et 2.2.4). Troisièmement, il ne capte pas les facteurs exogènes (cycles macro-économiques, conditions météorologiques, calendrier des jours fériés) qui modulent la demande réelle indépendamment des intentions commerciales, comme le confirmera le test de causalité de Granger conduit en section 2.2.6.

1.2.2 Phénomènes de rupture et de surstock observables dans les données

Le brief identifie deux phénomènes récurrents que le pilotage par objectifs CA ne prévient pas : les ruptures et les surstocks. Le jeu de données fourni permet d'en objectiver le premier par comparaison directe entre la quantité demandée et la quantité livrée : lorsque le ratio livraison / demande descend sous 100 pourcents, on est en présence d'une rupture, totale ou partielle. Le surstock n'est pas directement observable dans le seul historique de commandes (il faudrait un relevé de stock que ce dataset ne contient pas), mais sa manifestation indirecte - écart entre demande anticipée et demande effective - est néanmoins mesurable à travers les biais de prédiction étudiés en section 3.1.

Au-delà de la mesure brute, ces deux phénomènes ont un coût économique reconnu dans la littérature supply chain : pour la rupture, perte de marge sur la vente non réalisée et érosion de la confiance commerciale ; pour le surstock, immobilisation de trésorerie, coûts de stockage et risque d'obsolescence. Une approche prédictive qui réduit l'amplitude moyenne de ces écarts apporte donc une valeur économique directe, dont la quantification précise relèvera de la direction supply chain de GE.

1.2.3 Asymétrie des coûts et métrique business

La littérature opérationnelle souligne que le coût d'une unité manquante au moment où le client en a besoin est généralement supérieur au coût d'une unité excédentaire stockée. Cette asymétrie a une conséquence méthodologique directe : la qualité d'une prévision doit pouvoir être évaluée avec une fonction de coût asymétrique, et non avec la seule erreur absolue moyenne (MAE) classique. Le mémoire intègre donc, dans le dashboard Backtest 2025 (section 2.4.7), une fonction de coût business configurable définie par $\text{cost} = \alpha * \max(0, y - y_{\text{pred}}) + \beta * \max(0, y_{\text{pred}} - y)$, où α et β sont paramétrables par l'utilisateur ; les valeurs effectives à retenir en production relèvent d'un arbitrage de GE et ne sont pas fixées dans le présent document.

1.3 Problématique et question de recherche

1.3.1 Énoncé de la problématique

La problématique centrale du mémoire est formulée de la manière suivante :

Comment une approche Demand-Driven s'appuyant sur l'intelligence artificielle peut-elle prédire la demande client réelle - en quantité et en date - pour optimiser la chaîne d'approvisionnement d'un distributeur d'équipements électriques industriels, tout en préservant le rôle décisionnel de l'expertise humaine ?

Cette formulation contient trois engagements méthodologiques explicites. Le premier est le passage d'un pilotage par objectifs à un pilotage par demande effective prédite. Le deuxième est la double prédiction quantité + date, qui relève de deux familles de problèmes statistiques distincts (régression numérique pour la quantité, analyse de survie ou prévision de série pour la date). Le troisième est l'intégration explicite d'une boucle humain-dans-la-boucle : le système n'a pas vocation à automatiser intégralement la décision, mais à fournir au planificateur une recommandation transparente et interprétable.

1.3.2 Sous-questions opérationnelles et hypothèses

De cette problématique découlent quatre sous-questions opérationnelles :

- Q1 : Quelles variables internes et exogènes contribuent significativement à la prédiction de la demande sur le périmètre étudié ?
- Q2 : Quel modèle prédictif maximise la précision sur la quantité demandée tout en restant interprétable pour un planificateur métier ?
- Q3 : Le problème de prédiction de la date prochaine commande est-il abordé plus efficacement par un réseau récurrent (LSTM) ou par une formulation alternative (analyse de survie, Prophet par couple) ?
- Q4 : Comment articuler le modèle prédictif et l'expertise du planificateur dans une matrice de gouvernance opérationnelle ?

Les hypothèses testées sont cohérentes avec la littérature récente. H1 : l'ajout de variables exogènes (indice de production industrielle, météo) améliore significativement la prédiction par rapport aux variables internes seules. H2 : les modèles d'ensemble de type gradient boosting (XGBoost, LightGBM, CatBoost) surpassent les modèles linéaires et un réseau neuronal générique sur ce type de données tabulaires bruitées. H3 : la transformation $\log_{1p}$ de la cible réduit suffisamment l'asymétrie de la distribution pour stabiliser l'apprentissage. H4 : un dashboard interactif assorti d'un score de confiance améliore l'adoption opérationnelle par

rapport à une simple sortie numérique.

1.3.3 Perimetre, exclusions et North Star

Le perimetre temporel couvre les commandes et livraisons des années 2021 à 2025 inclus, découpées en train (2021-2023), validation (2024) et test (2025) selon un split strictement temporel pour éviter toute fuite d'information future. Sont explicitement exclus du perimetre : les opérations promotionnelles ponctuelles (données non disponibles), les retours clients, les transferts inter-sites internes, et les commandes exceptionnelles liees a des projets de plus de cinq millions d'euros. La cible North Star declaree en debut de projet, une précision moyenne supérieure à 60 pourcents, a constitue le repere d'amélioration tout au long du développement.

1.4 Revue de littérature

1.4.1 De la prévision statistique classique au gradient boosting

La littérature sur la prévision de la demande s'est structurée en trois grandes vagues. La première, antérieurement aux années 2010, repose sur les méthodes statistiques classiques : moyennes mobiles, lissages exponentiels de la famille Holt-Winters, modèles ARIMA et SARIMA. Ces méthodes restent une référence forte sur les séries stables et lisses, et constituent la baseline traditionnelle dans la communauté supply chain (Hyndman et Athanasopoulos, 2018). Pour les demandes intermittentes - très fréquentes dans la longue traîne d'un catalogue industriel - les méthodes spécialisées comme Croston (1972) et leurs raffinements (TSB, ADIDA) demeurent l'état de l'art.

La seconde vague, déployée massivement à partir de la décennie 2010, introduit les modèles d'ensemble par gradient boosting. XGBoost (Chen et Guestrin, 2016) a dominé les compétitions Kaggle sur données tabulaires pendant près d'une décennie, suivi par LightGBM (Ke et al., 2017) plus efficace sur les volumétries élevées et CatBoost (Prokhorenkova et al., 2018) qui gère nativement les variables catégorielles. Le rapport M5 Forecasting Competition (Makridakis et al., 2022) a confirmé expérimentalement la supériorité empirique de cette famille de modèles sur les problèmes de prévision retail et supply chain, devant les approches deep learning classiques sur la majorité des configurations testées.

1.4.2 Deep learning temporel et formulations alternatives

La troisième vague repose sur les architectures de deep learning spécifiques aux séries temporelles. Les réseaux récurrents de type LSTM (Hochreiter et Schmidhuber, 1997) ont longtemps constitué le standard pour la modélisation séquentielle, avant d'être concurrencés par les architectures convolutives causales (Bai et al., 2018), les Transformers temporels comme Informer (Zhou et al., 2021) et le Temporal Fusion Transformer (Lim et al., 2021), qui combinent attention multi-tête et interprétabilité. Pour les problèmes de prédiction de date - reformulables en time-to-event - les techniques d'analyse de survie (Cox proportional hazards, Random Survival Forests, DeepSurv) offrent un cadre statistique rigoureux qui contourne la difficulté classique des modèles de régression sur des délais censurés.

La littérature récente insiste également sur l'importance de la quantification de l'incertitude. Les modèles de régression quantile (Koenker et Bassett, 1978 ; implémentation LightGBM `objective='quantile'`) permettent de produire des intervalles de prédiction P10/P50/P90 plus honnêtes qu'un simple intervalle gaussien calculé sur les résidus, et plus exploitables opérationnellement qu'un score de confiance ad hoc. Cette approche est intégrée au présent projet comme indicateur de robustesse proposé au planificateur.

1.4.3 Demand-Driven MRP : le cadre opérationnel de référence

Le cadre conceptuel Demand-Driven Material Requirements Planning (DDMRP), formalise par Ptak et Smith (2016) sur la base des travaux pionniers de Goldratt sur la théorie des contraintes, structure une alternative opérationnelle au MRP classique deconnecte de la demande réelle. DDMRP s'articule autour de cinq composantes : Strategic Inventory Positioning (placement stratégique des stocks), Buffer Profiles and Levels (dimensionnement de buffers vert/jaune/rouge par article), Dynamic Adjustments (ajustement des buffers selon la saisonnalité), Demand-Driven Planning (déclenchement de réapprovisionnement sur la base du Net Flow Position), et Visible and Collaborative Exécution (suivi visuel des états critiques).

Cette grille de lecture est essentielle pour positionner académiquement le présent travail. Une approche IA pure sans ancrage DDMRP risque de produire un modèle statistiquement performant mais opérationnellement deconnecte des règles métier établies. Inversement, une approche DDMRP pure n'exploite pas la richesse des variables exogènes désormais disponibles à faible coût. Le mémoire propose une articulation hybride : un modèle IA produit une prédiction de demande qui alimente le calcul du Net Flow Position DDMRP, lui-même arbitré par le planificateur. La comparaison directe entre IA pure et DDMRP de référence est restituée en section 2.3.3.

1.4.4 Human-in-the-loop et IA responsable

La littérature récente sur le déploiement industriel de l'IA insiste sur la nécessité d'intégrer l'expertise humaine dans la boucle de décision, particulièrement pour les domaines à fort enjeu économique. L'approche Human-in-the-Loop Machine Learning (Wu et al., 2022) propose plusieurs patrons d'intégration, dont l'arbitrage par seuil de confiance, l'apprentissage actif sur les décisions correctives et la documentation systématique via des model cards (Mitchell et al., 2019). Le présent projet déploie une matrice de gouvernance à trois niveaux (vert : automatisation, orange : revue rapide, rouge : décision humaine obligatoire) cohérente avec ces principes et compatible avec les exigences émergentes de l'AI Act européen sur les systèmes à risque limite.

PARTIE 2

Solution Technique

2.1 Méthodologie Data Engineering

2.1.1 Audit des sources et qualité des données brutes

Le matériau brut consolide pour ce mémoire est constitué de deux exports opérationnels fournis par GE : un export des commandes clients de 2021 à 2025 et un export des livraisons effectivement réalisées sur la même période. Les deux fichiers, au format Excel à l'origine, ont d'abord été convertis en CSV puis chargés en Python via pandas pour traitement. L'audit initial a porté sur quatre dimensions : complétude (taux de valeurs nulles par colonne), unicité (détection des doublons sur les clés fonctionnelles), validité (vérification des plages de valeurs numériques et des formats de dates), et cohérence inter-fichiers (rapprochement commande/livraison).

Les principaux défauts identifiés à ce stade ont été les suivants : présence de lignes de commande sans correspondance livraison (commandes annulées ou différées), hétérogénéité des formats de date selon la source (mix DD/MM/YYYY et YYYY-MM-DD), codification incohérente des références articles entre certaines périodes (renumerotation partielle en 2023), et présence résiduelle de lignes de test informatique insérées lors des opérations de maintenance ERP. Ces défauts ont fait l'objet d'un nettoyage trace dans le notebook 01_data_cleaning.ipynb.

2.1.2 Pipeline de nettoyage et imputation

Le pipeline de nettoyage a été implémenté comme une succession d'étapes idempotentes documentées pour garantir la reproductibilité scientifique. Chaque étape consigne le nombre de lignes avant et après opération et la raison de chaque suppression : deduplication exacte, suppression des lignes de test, harmonisation des formats de date, imputation des valeurs manquantes par la médiane pour les variables numériques et par la modalité la plus fréquente pour les variables catégorielles dont le taux de nullité est inférieur à 5 pourcents, suppression des lignes dont les variables critiques (code_client, code_article, qte_demandee, date_cmd) sont manquantes.

Le dataset consolidé final, sauvegardé au format Parquet sous data/processed/dataset_ml_final.parquet, comporte 349 390 lignes pour 24 colonnes. Le taux de rapprochement commande/livraison atteint 94.2 pourcents, valeur jugée satisfaisante pour la suite des analyses. Le tableau ci-dessous synthétise la qualité des données après nettoyage.

Indicateur	Avant nettoyage	Après nettoyage
Lignes commande	362 480	349 390
Lignes livraison	338 215	329 174
Taux de rapprochement	85.3 %	94.2 %
Valeurs nulles (qte_demandee)	1.8 %	0.0 %
Doublons	3 211	0
Lignes de test ERP	412	0
Période couverte	2021-01 à 2025-12	2021-01 à 2025-12

Tableau 1 - Synthèse de la qualité des données avant et après pipeline de nettoyage (notebook 01_data_cleaning.ipynb).

2.1.3 Feature engineering et enrichissement exogène

La phase d'enrichissement, conduite dans le notebook 02_statistical_study.ipynb, a augmenté le jeu de données de 24 à 35 colonnes en intégrant des sources externes publiques. Trois catégories d'enrichissement ont été réalisées : enrichissement temporel par décomposition fine de chaque date (année, mois, trimestre, semaine ISO, jour de la semaine, indicateurs de fin de mois et de fin de trimestre), enrichissement calendaire par intégration des jours fériés français (via la librairie workalendar) et des périodes de vacances scolaires (zones A/B/C agrégées), et enrichissement exogène par l'indice de production industrielle (IPI) de l'INSEE et par les données météorologiques quotidiennes (températures, pluviométrie, vitesse de vent maximale) interrogées via l'API publique Open-Meteo sur les coordonnées du principal centre de distribution.

Vingt-huit features finales ont été retenues après une sélection itérative combinant analyse univariée, calcul du facteur d'inflation de la variance (VIF) pour traiter la colinéarité, et tests bivariés par groupes pour les variables catégorielles. Les variables catégorielles à forte cardinalité (code_client, code_article) ont été encodées par frequency encoding plutôt que par one-hot, choix justifié par la dimension élevée (plusieurs milliers de modalités) et l'efficacité des algorithmes de gradient boosting sur des entrées compactes.

2.1.4 Stratégie de split temporel et prevention du data leakage

Un point méthodologique critique pour la validité des conclusions est la stratégie de split. Tout split aléatoire est ici prohibé, car il introduirait une fuite d'information future dans le jeu d'entraînement (par exemple, une commande de fin 2025 utilisée pour prédire une commande de début 2023). Le split adopté est strictement temporel : 2021-2023 pour l'entraînement (210 641 lignes, 60.3 pourcents), 2024 pour la validation (70 871 lignes, 20.3 pourcents) et 2025 pour le test final (66 174 lignes, 18.9 pourcents).

Toutes les statistiques d'agrégation servant à générer des features (fréquences, moyennes historiques, lags) sont calculées exclusivement sur le set d'entraînement, puis projetées sur validation et test sans recalcul global. Cette discipline, parfois négligée dans les notebooks exploratoires, conditionne la validité des chiffres reportés et permet d'éviter la situation classique de modèles surperformants en validation mais décevants en production.




Figure 9 - Split temporel train (2021-2023) / val (2024) / test (2025). Source : notebook 02bis_edat_dataset_enrichi.ipynb.

2.2 Résultats des études statistiques

2.2.1 Décomposition de la serie agrégée

La première analyse a porté sur la série de demande agrégée à la maille mensuelle, tous articles et tous clients confondus. La décomposition STL (Seasonal-Trend decomposition using Loess) implémentée dans statsmodels a mis en évidence trois composantes stables : une tendance de fond légèrement croissante sur la période 2021-2025, une composante saisonnière annuelle marquée par un creux estival systématique (juillet-août) et un pic d'automne (septembre-novembre), et un résidu de variabilité élevée traduisant la diversité intra-mensuelle de la demande client.

La figure 1 ci-dessous restitue cette décomposition. Le pic d'automne représente en moyenne 30 pourcents de volume supplémentaire par rapport au creux estival, amplitude très significative qui justifie à elle seule l'attention portée aux features temporelles. Le résidu, bien qu'élevé en valeur absolue, ne présente pas de structure manifeste après décomposition, ce qui suggère qu'une part substantielle de la variabilité restante est imputable à des facteurs exogènes (clients, articles, événements extérieurs) non encore introduits dans la décomposition.




Figure 1 - Décomposition STL de la demande mensuelle agrégée 2021-2025. De haut en bas : série observée, tendance, composante saisonnière annuelle, résidu.

2.2.2 Décomposition par famille d'article

La décomposition globale masque des dynamiques sensiblement différentes selon les valeurs de la variable `famille_activite_article`. La même décomposition STL appliquée séparément aux principales familles du catalogue fait apparaître deux profils contrastés : un premier profil présente une amplitude saisonnière marquée, synchrone avec un calendrier annuel net, tandis qu'un second profil présente une demande plus régulière, peu sensible aux cycles annuels. Le contenu métier spécifique des familles concernées n'est pas détaillé ici, conformément au périmètre défini en section 1.1.2 ; l'observation reste exploitable à partir de la seule structure des données. Cette dichotomie a une implication opérationnelle directe : un modèle généraliste unique sous-performerait systématiquement sur l'une ou l'autre population, argument qui motivera l'enrichissement autorégressif au niveau du couple, du client et de l'article présenté en section 2.3.4.




Figure 2 - Décompositions STL comparées par famille d'article.

2.2.3 Cycles budgétaires clients

L'analyse des dates de commande agrégées à la maille hebdomadaire fait ressortir un pattern budgétaire net : la dernière semaine de chaque trimestre concentre régulièrement un volume supérieur de 15 à 25 pourcents à la moyenne du trimestre. Ce phénomène, documenté dans la littérature comme effet d'absorption du budget restant en fin de période budgétaire, se manifeste de manière hétérogène selon les segments de clientèle identifiés dans la variable `famille_activite_client` du jeu de données, sans qu'une interprétation métier supplémentaire ne soit avancée ici. La feature binaire `est_fin_mois_cmd` capte partiellement ce signal mais reste insuffisamment fine ; une amélioration possible serait l'ajout d'une feature `est_fin_trimestre` dédiée.




Figure 3 - Distribution hebdomadaire des commandes - mise en évidence des pics de fin de trimestre.

2.2.4 Cycles météorologiques

Le couplage des données de commande avec les données météorologiques Open-Meteo a permis de tester quantitativement l'hypothèse d'une influence de la météo sur la demande. Trois variables ont été retenues : température minimale, pluviométrie cumulée journalière et vitesse de vent maximale, associées à la `date_livraison_demandee` et non à la date d'enregistrement de la commande, afin de capter l'effet météo à l'horizon d'exécution plutôt qu'à l'horizon de saisie.

La corrélation marginale entre météo et quantité demandée reste faible (Pearson inférieur à 0.10 en valeur absolue pour les trois variables), mais l'analyse décomposée par famille d'article révèle un effet légèrement plus marqué sur le profil saisonnier identifié en section

2.2.2 : une pluviométrie élevée la semaine précédant la date de livraison demandée y est associée à une légère baisse du volume effectif. Aucune interprétation métier spécifique de ce signal n'est avancée au-delà de l'observation statistique brute.




Figure 4 - Relations météo / demande par famille d'article.

2.2.5 Matrice de corrélation et sélection de variables

La matrice de corrélation de Pearson calculée sur l'ensemble des features numériques et de la cible `qte_demandee` fournit une première lecture des dépendances linéaires. Comme attendu, aucune feature seule n'explique massivement la cible : la corrélation maximale, obtenue avec la fréquence du couple client-article, atteint 0.27, ce qui est cohérent avec une cible éclatée à forte variance individuelle. La matrice a également guidé l'élimination de variables fortement colinéaires : `est_weekend_liv_dem` et `jour_semaine_liv_dem` présentent un VIF élevé et ont fait l'objet d'un arbitrage au profit de la seconde, plus informative.




Figure 5 - Matrice de corrélation de Pearson - features et cible.

2.2.6 Test de causalité de Granger et features exogènes

Le test de causalité de Granger a été appliqué sur les sept variables exogènes candidates (IPI, variables météo agrégées à la semaine, jours fériés) avec des lags de 1 à 6 semaines. Les p-values obtenues, restituées figure 6, font apparaître une causalité significative ($p < 0.05$) pour l'IPI au lag 1 et au lag 3, pour la température moyenne hebdomadaire au lag 2, et pour les jours fériés sans décalage. Ces résultats justifient l'intégration des features exogènes correspondantes dans le modèle final, et auraient pu motiver l'ajout de versions laguées explicites (ipi_valeur_lag1, ipi_valeur_lag3) si le temps de développement avait permis cet enrichissement supplémentaire.




Figure 6 - P-values du test de causalité de Granger entre variables exogènes candidates et demande hebdomadaire agrégée.

Variable exogène	Lag optimal	p-value	Significatif
IPI INSEE	1 semaine	0.012	Oui
IPI INSEE	3 semaines	0.034	Oui
Température moyenne	2 semaines	0.041	Oui
Pluviométrie cumulée	1 semaine	0.118	Marginal
Vent maximal	1 semaine	0.234	Non
Jour férié	0 (immédiat)	0.008	Oui
Vacances scolaires	0 (immédiat)	0.067	Marginal

Tableau 2 - Variables exogènes et significativité Granger sur la demande hebdomadaire agrégée. Source : notebook 02_statistical_study.ipynb.

2.2.7 Stationnarité, distribution de la cible et acf

La distribution de la cible `qte_demandee` présente une asymétrie très marquée ($\text{skewness} = 80.73$) et une queue lourde à droite caractéristique des distributions de type demande client industrielle. La transformation $\log(1+x)$ ramène cette asymétrie à 1.44, valeur acceptable pour les modèles de régression sur cible continue. Cette transformation est appliquée systématiquement en entrée des modèles, l'inversion $\exp(x)$ étant opérée avant tout calcul de métrique pour garantir la comparabilité des résultats.




Figure 7 - Distribution de la cible avant (gauche) et après (droite) transformation $\log 1p$.




Figure 8 - ACF et PACF de la demande hebdomadaire agrégée - structure autorégressive faible mais présente aux lags 1 et 4.

2.3 Architecture et performances des modèles IA

Cette section détaille les modèles entraînés, restitue leurs performances comparées sur le jeu de test 2025 (jamais vu pendant l'entraînement ni la sélection de modèle), et discute les choix faits aux moments clés. Le code source des entraînements est reparté dans les notebooks 03_model_training.ipynb (première génération de modèles), 04_feature_engineering_lags.ipynb (enrichissement autorégressif) et 10_catboost_stacking.ipynb (architectures avancées). Les modèles serialisés sont disponibles dans le dossier models/.

2.3.1 Baseline historique et baseline naïve

Toute affirmation de performance d'un modèle machine learning n'a de sens que par comparaison à une baseline crédible. Deux baselines sont utilisées ici. La baseline naïve consiste à prédire pour chaque commande de test la moyenne globale de la quantité demandée sur le set d'entraînement (ignorance maximale). La baseline historique, plus exigeante, prédit pour chaque couple (client, article) la moyenne historique observée de ce couple sur 2021-2023, et la moyenne globale en fallback pour les couples inconnus. Sur le test 2025, la baseline historique atteint une MAE de 13.04 et un RMSE de 145.11. Tout modèle apportant une valeur ajoutée scientifique doit dominer cette baseline statistiquement, idéalement de plusieurs points.

2.3.2 Première génération de modèles - Régression sur 28 features

La première génération de modèles vise la prédiction directe de la quantité demandée (qte_demandee) par chaque commande individuelle. Quatre modèles ont été entraînés successivement avec le même jeu de 28 features exogènes et statiques, le même split temporel, et la même transformation logarithmique de la cible :

- XGBoost log+MSE : modèle de référence du gradient boosting, fonction de coût MSE sur cible log-transformée, paramétrisation par défaut.
- XGBoost Tweedie : même architecture mais fonction de coût Tweedie (objective='reg:tweedie'), adaptée aux distributions positives à queue lourde et à la fraction non négligeable de petites quantités.
- LightGBM log : alternative implémentée dans la librairie de Microsoft, convergence généralement plus rapide que XGBoost à équivalent fonctionnel.
- XGBoost v1 (Optuna 50 essais) : même moteur que XGBoost log mais hyperparamétrisation optimisée par 50 essais bayésiens (Optuna) sur le jeu de validation 2024, avec recherche conjointe sur n_estimators, max_depth, learning_rate, subsample, colsample_bytree, min_child_weight, reg_alpha et reg_lambda.

Les meilleurs hyperparamètres retenus à cette étape sont : $n_estimators = 498$, $max_depth = 10$, $learning_rate = 0.0776$, $subsample = 0.96$, $colsample_bytree = 0.73$, $min_child_weight = 3$, $reg_alpha = 0.021$, $reg_lambda = 0.284$. La valeur de $n_estimators$ proche de la borne haute de l'espace de recherche (500) suggère qu'un élargissement du nombre d'essais et de l'espace de recherche apporterait un gain supplémentaire ; cette intuition motivera l'itération suivante (XGBoost v2, section 2.3.4).

Modèle	MAE	RMSE	R ²	WAPE	Gain vs baseline
Baseline naive	23.50	210.30	-	1.041	ref
Baseline historique	13.04	145.11	-	0.620	-44.5 % MAE
XGBoost log + MSE	14.36	153.11	0.246	0.654	+10.1 %
XGBoost Tweedie	13.74	138.98	0.379	0.626	+5.4 %
LightGBM log	14.74	158.43	0.192	0.671	+13.0 %
XGBoost v1 (Optuna 50)	11.87	132.17	0.438	0.541	-9.0 %

Tableau 3 - Comparaison des modèles de première génération sur le test 2025 (28 features statiques, sans variables autorégressives). Seul XGBoost v1 optimisé par Optuna domine la baseline historique sur toutes les métriques. Source : `reports/rapport_modelisation.json`.

La lecture du tableau 3 conduit à trois constats. Premièrement, XGBoost et LightGBM en configuration par défaut ne battent pas la baseline historique en MAE, ce qui est souvent observé sur des cibles à forte variance intra-couple et confirme l'importance de l'optimisation hyperparamétrique. Deuxièmement, la variante Tweedie améliore sensiblement le RMSE et le R² par rapport à la variante MSE, en captant mieux la queue de distribution des petites quantités. Troisièmement, XGBoost v1 optimisé par Optuna est le seul modèle à battre la baseline historique sur la MAE, avec un gain de 9 pourcents. Ce résultat est encourageant mais reste loin de la cible North Star (60 pourcents de précision agrégée, soit WAPE inférieur à 0.40) ; il motive l'enrichissement feature et la refonte d'hyperparamétrisation conduits dans la génération suivante.




Figure 10 - Importance des 15 features les plus contributrices du modèle XGBoost v2 (gain XGBoost). Les rolling means client et article dominant, suivies par les fréquences, le prix, l'IPI et le target encoding.

2.3.3 Architecture 2 - LSTM time-to-event pour la date de prochaine commande

L'architecture 2 traite un problème statistiquement différent : la prédiction du délai (en jours) avant la prochaine commande du même couple client-article. La cible est construite par calcul de la différence entre dates de commande successives pour chaque couple ayant au moins deux commandes dans l'historique. Le modèle est un LSTM implémenté en PyTorch avec deux couches, 64 unités cachées, longueur de séquence SEQ_LEN = 6, batch size 256, optimiseur Adam et fonction de coût MSE sur le délai en jours.

Les huit features d'entrée séquentielles sont : prix, delai_demande_jours du couple précédent, fréquence client, fréquence article, ipi_valeur, mois_cmd, jour_semaine_cmd, et est_fin_mois_cmd. L'entraînement converge en environ 30 époques sans surapprentissage marqué sur la validation, mais les performances finales sur le test 2025 sont décevantes au regard de l'enjeu opérationnel.

Métrique	Valeur observée	Cible opérationnelle	Verdict
MAE delai (jours)	24.5	< 10 jours	Insuffisant
Précision +/-7 jours	25.5 %	> 50 %	Insuffisant
Précision +/-14 jours	43.2 %	> 70 %	Insuffisant
Couverture (couples eval.)	78.4 %	> 60 %	Acceptable

Tableau 4 - Performance du LSTM time-to-event sur le test 2025. La précision +/-7 jours, métrique centrale pour l'usage planificateur, reste très en deca de la cible opérationnelle. Source : reports/rapport_modelisation.json.

Ces résultats appellent une analyse honnête des causes possibles. La longueur de séquence `SEQ_LEN = 6` est probablement insuffisante pour capter une saisonnalité annuelle ou semestrielle ; l'absence de features autorégressives sur le délai lui-même (`délai_lag_1`, ... `délai_lag_6`) prive le modèle d'un signal fort ; l'absence de scaling explicite des features numériques (le LSTM y est très sensible) a pu ralentir la convergence ; et la formulation du problème en régression sur un délai continu n'est pas la plus naturelle compte tenu de la nature réellement temporelle du problème. La littérature récente plaide pour une reformulation en analyse de survie (lifelines, scikit-survival, pycox), ou alternativement en classification multi-classes par bucket de délai ([0-7], [7-14], [14-30], [30-60], [60+] jours), ce qui simplifie la tâche et facilite l'interprétation. Cette voie est explicitement listée dans les perspectives (section 3.5).

2.3.4 Évolution méthodologique - Enrichissement feature et architectures avancées

À l'issue de la première génération de modèles, l'analyse du tableau 3 a fait apparaître un écart significatif entre la performance obtenue (précision agrégée 45.95 pourcents) et l'objectif North Star déclaré (60 pourcents). Trois axes méthodologiques ont été explorés pour réduire cet écart : l'enrichissement du signal autorégressif, l'extension du benchmark à d'autres familles d'algorithmes, et la confrontation à une baseline métier de référence (DDMRP).

Enrichissement autorégressif et XGBoost v2

Le premier axe a consisté à augmenter le jeu de 28 à 47 features par ajout de 19 variables autorégressives : lags 1/7/30 jours sur la quantité, rolling mean et std à 7/30/90 jours au niveau du couple, du client seul et de l'article seul, target encoding couple / client / article par fold temporel (pour éviter toute fuite), nombre de commandes du couple sur les 30 derniers jours, nombre de jours depuis la dernière commande, lag de prix et delta de prix. Ces variables capturent explicitement la dynamique temporelle qui restait masquée dans la première génération. Sur cette base enrichie, un modèle XGBoost v2 a été optimisé par 300 essais Optuna (contre 50 pour la version v1), avec un espace de recherche élargi (jusqu'à 1500 estimateurs, profondeur jusqu'à 14). Les meilleurs paramètres retenus sont `n_estimators = 1108`, `max_depth = 12`, `learning_rate = 0.0077`, `subsample = 0.82`, `colsample_bytree = 0.96`.

Architectures complémentaires : LightGBM Quantile, CatBoost, Stacking Ridge

Le second axe a étendu le benchmark à trois architectures complémentaires entraînées sur le même jeu de 47 features et le même split temporel : LightGBM Quantile configuré aux quantiles 0.1, 0.5 et 0.9 pour produire des intervalles de prédiction P10 / P50 / P90 directement exploitables opérationnellement ; CatBoost v2 entraîné avec 200 essais Optuna, qui exploite nativement les features catégorielles et leurs interactions ; et un meta-modèle Stacking Ridge qui combine les prédictions out-of-fold de XGBoost v2, LightGBM Quantile P50 et CatBoost via une régression Ridge régularisée (alpha optimal = 10). Le stacking est entraîné sur des prédictions issues d'une TimeSeriesSplit à 5 folds pour éviter toute fuite d'information.

Baseline DDMRP de référence

Le troisième axe a implémenté une baseline Demand-Driven Material Requirements Planning selon les spécifications de Ptak et Smith (notebook 09_baseline_ddmrp.ipynb). Le périmètre couvre les 22 articles stratégiques sélectionnés par règle de Pareto (80 pourcents du volume cumulé). Pour chaque article, trois zones de stock sont calculées - vert, jaune, rouge - à partir de l'Average Daily Usage sur 60 jours, du Lead Time moyen, et de facteurs de variabilité calibres sur la distribution historique. La simulation hebdomadaire du Net Flow Position compare ensuite les décisions de réapprovisionnement DDMRP aux prédictions du modèle IA sur la même période.

Modèle / Méthode	MAE	RMSE	R ²	WAPE	1 - WAPE
Baseline historique	13.04	145.11	-	0.620	38.0 %
XGBoost v1 (28 feat., Optuna 50)	11.87	132.17	0.438	0.541	45.9 %
LightGBM Quantile P50 (47 feat.)	8.32	121.87	0.522	0.379	62.1 %
CatBoost v2 (47 feat., Optuna 200)	8.98	120.05	0.536	0.409	59.1 %
XGBoost v2 (47 feat., Optuna 300)	8.42	101.83	0.666	0.383	61.7 %
Stacking Ridge (XGB+LGBM+CatBoost)	8.70	97.55	0.694	0.396	60.4 %

Tableau 5 - Benchmark complet des architectures testées sur le test 2025. Trois architectures dépassent l'objectif North Star de 60 pourcents (1 - WAPE) : LightGBM Quantile P50, XGBoost v2 et Stacking Ridge. XGBoost v2 domine sur la MAE, Stacking Ridge sur RMSE et R². Sources : reports/sprint_a_chantier1_metrics.json et reports/sprint_b_chantier1_stacking.json.

Le tableau 5 invite à une lecture comparative qui évite la tentation du modèle gagnant unique. Trois architectures répondent au cahier des charges global : LightGBM Quantile P50 offre la meilleure MAE pure (8.32) et fournit nativement des intervalles de prédiction ; XGBoost v2 propose le meilleur compromis MAE / WAPE / interprétabilité et constitue une base éprouvée

; Stacking Ridge domine sur les métriques de dispersion (RMSE 97.55, R^2 0.694) en corrigeant les grandes erreurs grâce à la complémentarité des composants. Le choix d'une architecture de production relève donc d'un arbitrage explicite entre critères opérationnels (coût d'inférence, simplicité de maintenance, disponibilité des intervalles d'incertitude) plutôt que d'un classement statistique unidimensionnel.

Confrontation IA vs DDMRP sur articles stratégiques

La comparaison directe entre les prédictions IA et la simulation DDMRP, restreinte au périmètre des 22 articles stratégiques sélectionnés par règle de Pareto, livre les résultats suivants sur le test 2025 agrégé en semaines.

Méthode	MAE hebdo	Biais hebdo	Lecture
IA seule (XGBoost v2)	260.1	-223.0	Très précis mais sous-estime structurel
DDMRP simulée (Ptak & Smith)	660.8	-179.0	Marges de sécurité, MAE élevée
Hybride 50 / 50	242.0	-20.9	Meilleur compromis

Tableau 6 - Comparaison IA, DDMRP et combinaison hybride sur 22 articles stratégiques (périmètre 80 pourcents du volume). L'hybridation à parts égales minimise simultanément la MAE hebdomadaire et le biais.

Source : reports/sprint_b_chantier3_ddmrp.json.

Cette comparaison délivre un message méthodologique central : l'IA et DDMRP ne sont pas substituables mais complémentaires. L'IA fournit une prédiction précise mais structurellement sous-estimée de la demande (biais négatif élevé), tandis que DDMRP introduit des marges de sécurité opérationnelles qui évitent la rupture mais augmentent l'erreur moyenne. Une combinaison hybride à parts égales réduit simultanément la MAE hebdomadaire (242 contre 260 pour l'IA seule) et le biais structurel (-20.9 contre -223). Le taux de rupture observé sur la simulation DDMRP (11.2 pourcents) confirme par ailleurs la valeur opérationnelle de l'approche métier classique, qui ne disparaît pas avec l'arrivée de l'IA.

2.3.5 Analyse comparative et sélection du modèle de service

La sélection d'une architecture pour le service opérationnel résulte d'un arbitrage multicritère : performance brute, interprétabilité, simplicité d'industrialisation, coût de maintenance. Le mémoire ne tranche pas en faveur d'un modèle unique mais documente trois configurations recommandées selon le profil d'usage :

- XGBoost v2 (47 features) : configuration recommandée pour un service monomodèle privilégiant simplicité opérationnelle et interprétabilité. MAE 8.42, WAPE 0.383, précision agrégée 61.7 pourcents. Modèle actif dans le dashboard livre.

- LightGBM Quantile P10 / P50 / P90 : configuration recommandée lorsque l'utilisateur métier exige des intervalles d'incertitude explicites (badge de confiance, marges de sécurité). Performances P50 comparables à XGBoost v2 et intervalles directement exploitables.
- Stacking Ridge (XGBoost v2 + LightGBM P50 + CatBoost) : configuration recommandée lorsque la métrique de dispersion (RMSE, R^2) est prioritaire et que le coût d'inférence triple est acceptable. Gain de 4 points sur le RMSE et de 4 points sur le R^2 par rapport au monomodelle.

Cette présentation neutre des trois configurations est défendue dans la model card publiée en annexe : elle expose au jury et aux praticiens la réalité d'un projet industriel où plusieurs architectures coexistent légitimement selon le profil d'usage, et où la décision de service finale est documentée, datée et susceptible d'évoluer.

2.4 Présentation du dashboard Human-in-the-loop

2.4.1 Architecture technique et choix de stack

Le dashboard livre repose sur la stack Streamlit, choisie après comparaison avec les alternatives Dash (Plotly), Panel et FastAPI + React. Trois critères ont déterminé ce choix : la rapidité de développement (un planificateur teste l'interface dès la semaine 5 du projet), l'intégration native avec l'écosystème Python scientifique déjà utilisé pour la modélisation, et la possibilité d'embarquer Plotly pour les graphiques interactifs sans pont JavaScript. La contrepartie reconnue est une scalabilité limitée à quelques utilisateurs simultanés, acceptable pour un MVP interne mais qui nécessitera une migration vers une architecture découplée (FastAPI + React) pour une mise en production à l'échelle.

L'application est structurée en une page d'accueil et six pages métier accessibles via la sidebar Streamlit native : Gestion des Données, Intelligence Artificielle, Prévisions de Ventas, Analyse, Drift Détection, Backtest 2025. Les utilitaires de chargement de données, d'inférence, de calcul du score de confiance et de simulation what-if sont centralisés dans le package dashboard/utlis/ pour éviter la duplication.

2.4.2 Page Gestion des Données

La page Gestion des Données assure deux fonctions : la consultation du jeu de données historique et l'import de nouveaux fichiers pour inférence. Le tableau consultation propose un filtrage par client, par article, par période, et un export CSV des résultats filtrés. L'import accepte un fichier CSV au format Mode A (déjà encodé avec les suffixes `_freq` et `_enc`), choix de simplification explicitement documenté dans la limite opérationnelle pour le MVP - un Mode B (encodage automatique côté serveur) est positionné en perspective.

1. Import

Fichier CSV ou Parquet (28 features encodées + qte_demandee)

Drag and drop file here
Limit 200MB per file • CSV, PARQUET, XLSX

Browse files

Aucun fichier importé — affichage du dataset enrichi de référence.

2. Validation du schéma

✓ 28 features présentes dans dataset_ml_enrichi.parquet

3. Aperçu du dataset

Lignes	Période	Articles uniques	Clients uniques
349,390	2020-09-23 → 2...	380	495

Figure 11 - Page Gestion des Données du dashboard. Le tableau filtrable consulte l'historique 2021-2025 ; le bandeau d'import en haut accepte les CSV Mode A.

2.4.3 Page Intelligence Artificielle

La page Intelligence Artificielle centralise les informations sur le modèle actif et l'historique des versions. Elle expose la version active, la date de dernier entraînement, la liste des features utilisées (lue dynamiquement depuis l'attribut `feature_names_in_` du modèle serialisé pour éviter toute divergence avec la liste hardcodée), et un tableau historique des runs avec leurs métriques principales. Un bouton Re-entraîner le modèle déclenche le script `src/retrain.py` en arrière-plan et streame le log d'exécution dans la page.




Figure 12 - Page Intelligence Artificielle. Le panneau central affiche les métriques du modèle actif, l'historique des versions et le bouton de re-entraînement.

2.4.4 Page Prévisions de Ventes et score de confiance composite

La page Prévisions de Ventes constitue le cœur fonctionnel du dashboard. Elle propose au planificateur la liste des couples client-article à horizon M+1 à M+3 avec leur quantité prédite, leur intervalle d'incertitude P10-P90 et un indicateur visuel de confiance (vert / orange / rouge) lisible en un coup d'oeil. La page intègre un filtrage par client, par famille d'article et par segment ABC, ainsi qu'un export CSV / Excel des lignes sélectionnées.

Le score de confiance affiche est calculé par une formule composite à trois facteurs documentée dans le fichier `dashboard/utls/confidence.py` : (1) familiarité du couple (article et client déjà vus ensemble en entraînement, partiellement vus, ou inconnus), (2) écart entre la prédiction et la médiane historique du couple (indicateur de surprise statistique), et (3) decile de la valeur prédite dans la distribution d'entraînement (les valeurs extrêmes sont moins fiables). Le score composite est mappe sur trois états : vert si confiance supérieure à 0.75, orange entre 0.4 et 0.75, rouge en dessous. Ce mapping est configurable depuis la page Analyse via un slider, matérialisant la matrice de gouvernance HITL (détaillée section 3.4).




Figure 13 - Page Prévisions de Ventes (vue principale). Tableau central : un couple client-article par ligne, colonnes Quantité prédite, P10-P90, Confiance (badge couleur), Action recommandée. Le panneau de filtres lateral autorise une sélection multidimensionnelle.




Figure 14 - Page Prévisions, sous-section Prédiction vs valeur réelle. Scatter plot interactif Plotly : abscisse valeur réelle, ordonnée prédiction. La couleur encode le score de confiance et la diagonale grise matérialise la prédiction parfaite.



Figure 15 - Page Prévisions, sous-section Simulation what-if. Sliders et toggles permettant au planificateur de simuler l'effet d'une variation de prix, de délai, d'IPI ou d'un passage en jour férié sur la prédiction d'une ligne sélectionnée, avec affichage de la prédiction simulée et de l'intervalle P10 - P90 associé.

2.4.5 Page Analyse - IA vs baseline et exploration des erreurs

La page Analyse centralise le travail de storytelling autour des résultats de modélisation. Elle confronte d'abord la MAE de la baseline historique à la MAE du modèle XGBoost v2 et affiche le gain relatif obtenu sur le jeu de test 2025. Elle présente ensuite le top des erreurs maximales : un tableau classe les couples client-article ou l'écart entre quantité réelle et quantité prédite est le plus élevé. Cette vue est essentielle pour la lecture critique du modèle car elle matérialise les régions de l'espace où la prédiction reste fragile et oriente les améliorations futures.

Une lecture explicite accompagne le tableau : les erreurs maximales correspondent généralement à des commandes de gros volume sur des articles ou des clients peu représentés dans le set d'entraînement, ce qui justifie l'usage du badge de confiance (orange ou rouge) pour signaler ces situations au planificateur avant validation.



Figure 16 - Page Analyse. Le tableau central liste le top des erreurs absolues du modèle XGBoost v2 sur le test 2025 ; la lecture en bas de page guide l'interprétation et le rattachement au score de confiance. Le bandeau inférieur expose la comparaison IA vs DDMRP et la décomposition par architectures avancées.

2.4.6 Page Drift Détection - monitoring de la stabilité des features

La page Drift Détection implémente un monitoring de la Population Stability Index (PSI) sur les six features les plus contributrices du modèle XGBoost v2, identifiées par importance de permutation : qte_roll_mean_7, qte_roll_mean_30_article, qte_roll_mean_30_client, prix et ipi_valeur. La distribution de référence est calculée sur le set d'entraînement (2021-2023) et confrontée soit au test 2025 par défaut, soit à une distribution courante uploadée par l'utilisateur (CSV ou Parquet).

Pour chaque feature surveillée, l'application calcule le PSI selon la formule standard $\sum (p_{cur} - p_{ref}) * \log(p_{cur} / p_{ref})$ sur dix bins définis par quantiles de la distribution de référence. Une classification à trois niveaux est appliquée : stable (PSI inférieur à 0.10), drift modéré (PSI entre 0.10 et 0.25), drift significatif (PSI supérieur à 0.25). Un bandeau

d'alerte synthèse le verdict global et conseille un re-entraînement lorsqu'au moins une feature critique passe en zone rouge. Cette mécanique est conforme aux pratiques de monitoring credit risk industriel (Karakoulas, 2011) et constitue le socle d'une mise en production responsable.




Figure 17 - Page Drift Détection. Panneau gauche : tableau PSI par feature avec code couleur (vert / orange / rouge) ; panneau droit : histogramme des PSI pour lecture visuelle rapide. Le bandeau supérieur synthèse le verdict de stabilité du modèle.

2.4.7 Page Backtest interactif - retroprojection 2025

La page Backtest 2025 propose au planificateur de retroprojeter l'usage du modèle sur l'année 2025 à l'aide d'un slider hebdomadaire ISO. Pour chaque semaine d'arrêt sélectionnée, l'application affiche la quantité réelle cumulée, la quantité prédite cumulée par chacun des modèles sélectionnés (XGBoost v2, LightGBM Quantile P50, CatBoost, Stacking Ridge, baseline historique), ainsi que des métriques rolling sur les quatre dernières semaines.

Au-delà des métriques statistiques (MAE et WAPE par fenetre), la page expose une fonction de coût business paramétrable par l'utilisateur : $\text{coût} = \alpha * \text{ruptures} + \beta * \text{sur-stock}$, ou α et β sont fixes par sliders en euros par unité. Cette fonction permet une lecture économique directe du comportement des modèles dans des contextes où la rupture coûte plus cher que le surstock (α grand), ou inversement (β grand). Le tableau des dix erreurs absolues maximales sur la semaine d'arrêt complète la lecture par une vue qualitative des cas extrêmes.




Figure 18 - Page Backtest interactif. Graphique central : cumul de la quantité réelle et des prédictions cumulées des modèles sélectionnés en abscisse semaine ISO. Panneaux secondaires : métriques rolling 4 semaines, fonction de coût business paramétrable, tableau des dix plus grandes erreurs.

2.4.8 Page d'accueil - synthèse executive et navigation

La page d'accueil du dashboard joue le rôle de tableau de bord exécutif. Elle expose en bandeau supérieur les indicateurs clés du modèle actif (MAE, R^2 , WAPE, taille du dataset), rappelle la problématique en quelques lignes et restitue visuellement le pipeline complet du projet (Data Engineering, Études statistiques, Modélisation IA, Dashboard). Le panneau de navigation à droite oriente l'utilisateur vers les quatre pages métier en fonction du besoin du moment : exploration des données, monitoring du modèle, prévisions à horizon M+1/M+3, analyse comparative.

Au-delà de la fonction navigation, cette page d'accueil constitue le premier contact visuel pour un décideur non technique. Elle permet de mesurer instantanément la valeur ajoutée du modèle par rapport à la baseline historique (badge -9.0 % vs baseline) sans avoir à entrer dans les détails statistiques de chaque page.




Figure 19 - Page d'accueil du dashboard. KPIs du modèle actif en bandeau, rappel de la problématique au centre, schéma du pipeline et navigation rapide vers les six pages métier.

Synthèse PSI mesurée sur le test 2025

Les valeurs de PSI mesurées sur le test 2025 par la page Drift Détection fournissent une calibration empirique des seuils. Le tableau ci-dessous restitué les PSI obtenus sur les six features critiques entre la référence train (2021-2023) et la distribution test (2025).

Feature surveillée	PSI test 2025	Statut
prix	0.07	Stable
qte_roll_mean_7	0.11	Drift modere
ipi_valeur	0.19	Drift modere
qte_roll_mean_30_article	0.18	Drift modere
qte_roll_mean_30_client	0.09	Stable
qte_roll_mean_30	0.14	Drift modere

Tableau 7 - PSI mesures sur les six features les plus contributrices entre train et test 2025. Aucune feature ne franchit le seuil rouge (0.25), ce qui justifie le maintien du modèle en service sans déclencher de re-entraînement immédiat.

PARTIE 3

Analyse Critique

3.1 Comparaison IA versus intuition commerciale

3.1.1 Méthodologie de comparaison

La comparaison entre la prédiction IA et le pilotage par objectifs commerciaux ne peut s'appuyer, dans le perimetre du present mémoire, que sur des données objectives disponibles dans le dataset. Faute d'accès aux objectifs commerciaux négociés par GE, l'évaluation prend pour référence la baseline historique (moyenne par couple client-article calculée sur 2021-2023), qui constitue un proxy mesurable de ce que produirait une planification non assistée par IA au-delà d'une simple moyenne glissante. Cette baseline est volontairement exigeante : un modèle qui ne la dépasse pas significativement n'apporterait aucune valeur ajoutée scientifique.

3.1.2 Gains mesures par rapport à la baseline

Sur le perimetre du test 2025 (66 174 lignes), le gain absolu du modèle XGBoost v2 par rapport à la baseline historique est de 4.62 unités en MAE (8.42 contre 13.04), soit un gain relatif de 35.4 pourcents. En précision agrégée ($1 - \text{WAPE}$), le modèle atteint 61.7 pourcents contre 38.0 pourcents pour la baseline, soit un gain absolu de 23.7 points et un dépassement de 1.7 point de l'objectif North Star declare (60 pourcents). Le modèle Stacking Ridge, qui améliore le RMSE de 4 points (97.55 contre 101.83) et le R^2 de 4 points (0.694 contre 0.666), constitue une alternative intéressante lorsque la métrique de dispersion est prioritaire.

Le test de Diebold-Mariano applique sur les residus du modèle XGBoost v2 versus la baseline historique donne une p-value très significativement inférieure à 0.01, ce qui permet d'affirmer statistiquement la supériorité du modèle sur l'ensemble du test. Cette validation statistique est essentielle pour anticiper la question - fréquemment posée en soutenance - de la significativité du gain observe.

3.1.3 Cadre d'estimation business

La traduction du gain statistique en valeur économique nécessite la connaissance de deux paramètres métier : alpha, le coût unitaire d'une rupture, et beta, le coût unitaire d'un surstock (par mois immobilisé). Ces paramètres ne sont pas fournis dans le brief de mission et ne peuvent donc pas être fixés ici sans approximation arbitraire. La page Backtest 2025 du dashboard permet à l'utilisateur métier de saisir lui-même ces deux paramètres et d'observer le coût cumulé des différents modèles sur l'année 2025 sous l'hypothèse choisie. Cette démarche évite de propager une estimation chiffrée non sourcée dans le mémoire tout en laissant à GE la possibilité de quantifier le gain sur ses propres barèmes.

3.2 Limites du modèle

3.2.1 Imprévus géopolitiques et ruptures de régime

La première limite structurelle de toute approche basée sur l'apprentissage statistique est sa difficulté intrinsèque à anticiper les ruptures de régime. La période d'entraînement 2021-2023 comprend deux contextes économiquement atypiques : la phase post-Covid (chaînes d'approvisionnement perturbées, prix volatiles) et la phase consécutive à la guerre en Ukraine déclenchée en février 2022 (envolée des prix de l'énergie, tensions sur les composants). Le modèle a donc appris des corrélations potentiellement biaisées par ces contextes ; un changement de régime aussi violent que ces deux précédents pendant la période d'inférence invaliderait localement les prédictions. Aucune technique d'apprentissage statistique ne corrige intégralement ce défaut ; la détection de dérive PSI intégrée au dashboard est un palliatif partiel qui déclenche une alerte sans pour autant fournir un nouveau modèle adapté.

3.2.2 Données manquantes et périmètres non couverts

Plusieurs sources d'information potentiellement utiles n'ont pas pu être intégrées, soit par indisponibilité, soit par contrainte de temps. Les données promotionnelles (remises tarifaires accordées ponctuellement) ne sont pas tracées dans l'export ERP exploité ; or, une remise significative déclenche typiquement un effet d'anticipation de commande qui n'est pas capté par le modèle. Les opérations de transfert inter-sites sont également absentes : un transfert de stock entre deux centres de distribution pour répondre à une rupture locale n'apparaît pas comme une commande dans le périmètre étudié. Enfin, les retours clients - faibles en volume mais structurellement biaisés vers certaines familles d'article - ne sont pas intégrés.

3.2.3 Biais identifiés

Trois catégories de biais structurels du jeu de données ont été identifiées comme points de vigilance pour une exploitation industrielle. Les ordres de grandeur associés restent qualitatifs : leur quantification précise dépasse le périmètre du présent mémoire mais est facilement instrumentable en relançant les notebooks d'EDA et de modélisation sur les colonnes concernées.

- Biais de fréquence client : les comptes à faible activité (peu de commandes par an) représentent une part importante du nombre de clients mais une part marginale du volume. Le modèle leur attribue mécaniquement une erreur plus élevée, ce qui implique un risque de rupture silencieuse sur cette population si la prédiction est utilisée sans badge de confiance.

- Biais d'article : la longue traîne du catalogue (articles à faible volume) présente une demande intermittente structurellement difficile à prédire par un modèle de régression continue. Une exploitation industrielle exigerait une approche spécialisée de type Croston / TSB / ADIDA pour ce segment.
- Biais temporel : la présence de régimes économiquement atypiques dans l'entraînement (post-Covid, choc énergétique 2022) peut conduire à sur-pondérer ces régimes lors d'une inférence dans un contexte revenu à la normale.

3.2.4 Échec relatif du LSTM time-to-event et honnêteté métrique

La précision +/-7 jours de 25.5 pourcents obtenue par l'architecture LSTM time-to-event est très inférieure à la cible opérationnelle (50 pourcents). Cet écart constitue le point faible le plus visible du mémoire et ne saurait être dissimulé. L'analyse honnête des causes (longueur de séquence insuffisante, absence d'autorégression sur le délai, absence de scaling, formulation potentiellement inadaptée) a déjà été exposée section 2.3.3. Plutôt que de retirer cette architecture du livrable, elle est explicitement signalée dans le dashboard par un badge rouge par défaut sur toute prédiction de date : la transparence sur la fiabilité limitée de ce modèle est ici un engagement méthodologique, qui prépare la reformulation par analyse de survie annoncée en perspectives.

3.2.5 Atteinte du North Star sur la quantité, échec sur la date

La cible North Star déclarée en début de projet, 60 pourcents de précision agrégée (1 - WAPE), est atteinte sur la quantité : le modèle XGBoost v2 livre une précision de 61.7 pourcents sur le test 2025, soit un dépassement de 1.7 point. La configuration Stacking Ridge atteint 60.4 pourcents avec une amélioration significative de la métrique de dispersion (R^2 0.694 contre 0.666 pour XGBoost v2). Trois architectures distinctes franchissent ainsi le seuil cible (XGBoost v2 à 61.7 pourcents, LightGBM Quantile P50 à 62.1 pourcents, Stacking Ridge à 60.4 pourcents), ce qui constitue un acquis robuste et reproductible.

L'objectif n'est en revanche pas atteint sur la prédiction de date par LSTM, qui plafonne à 25.5 pourcents +/-7 jours (cible opérationnelle : 50 pourcents). Cette dissymétrie des résultats - réussite sur la quantité, échec relatif sur la date - structure la lecture critique du mémoire : le livrable opère une transformation démontrable sur le pilotage des volumes mais ne résout pas la question du timing exact des commandes, qui devra être repris via une reformulation par analyse de survie (perspectives en section 3.5).

3.3 Conformité RGPD et éthique du traitement

Le présent mémoire mobilisant des données d'entreprise contenant indirectement des informations relatives à des personnes physiques (interlocuteurs commerciaux, demandeurs ERP, planificateurs identifiés dans certains champs metadata), une analyse de conformité au Règlement Général sur la Protection des Données (RGPD, règlement UE 2016/679, applicable depuis le 25 mai 2018) est imperative. Cette section documente cette analyse et identifie les mesures techniques et organisationnelles mises en œuvre.

3.3.1 Données personnelles potentiellement concernées

Au sens de l'article 4 du RGPD, constitue une donnée personnelle toute information se rapportant à une personne physique identifiée ou identifiable. L'examen des colonnes présentes dans le dataset effectivement utilisé (data/processed/dataset_ml_enrichi.parquet) permet d'identifier le statut des champs vis-à-vis du RGPD :

- Identifiants entreprise (codes opaques) : `code_client` et `code_article` sont des identifiants numériques internes à GE. Ils ne désignent pas directement une personne physique mais peuvent y conduire en présence d'une table de correspondance interne. Dans le pipeline d'apprentissage, ces champs sont remplacés par leur frequency encoding (`code_client_freq`, `code_article_freq`), ce qui rompt le lien direct.
- Variables descriptives clients : `famille_activite_client`, `type_activite`, `pays`, `segment`. Ces champs décrivent l'activité commerciale et le pays du client, qui peut être une personne morale ou physique. Lorsqu'un client est une personne physique (entrepreneur individuel par exemple), ces variables constituent indirectement des données personnelles.
- Variables transactionnelles : `qte_demandee`, `qte_livree`, `prix`, `dates`. Données commerciales standard non personnelles en elles-mêmes.

Le dataset utilisé pour l'entraînement ne contient en revanche aucun champ directement nominatif (nom, prénom, contact, identifiant opérateur ERP). Aucune donnée sensible au sens de l'article 9 du RGPD (santé, opinion politique, syndicale, religieuse, biométrique, sexuelle) n'est traitée dans le périmètre du projet.

3.3.2 Bases légales du traitement

Le traitement réalisé dans le cadre du présent mémoire mobilise deux bases légales principales selon l'article 6 du RGPD :

- Article 6.1.b (exécution d'un contrat) : le traitement des données client nécessaires à l'exécution des commandes (raison sociale, adresse de livraison, code interlocuteur) est légitime par l'exécution du contrat commercial entre GE et ses clients.

- Article 6.1.f (interet legitime) : le traitement statistique anonymise des historiques de commande aux fins d'amélioration de la prévision de demande est legitime par l'interet legitime de GE a optimiser sa chaîne d'approvisionnement, sous reserve que les droits et libertes des personnes concernees ne prevalent pas. Une analyse d'impact (AIPD / DPIA) formelle complementaire est recommandée avant tout deploiement en production etendu.

3.3.3 Mesures techniques et organisationnelles mises en œuvre

Trois mesures techniques et organisationnelles ont été adoptees au cours du projet pour minimiser la sensibilite des données manipulees :

- Pseudonymisation des identifiants : les champs `code_client` et `code_article` sont remplaces par leur frequency encoding (`code_client_freq`, `code_article_freq`) lors de la preparation (notebook 02bis_eda_dataset_enrichi.ipynb), ce qui rompt le lien direct entre une transaction et un identifiant commercial dans les modèles serialises.
- Minimisation : le dataset utilise pour l'apprentissage ne contient aucun champ nominatif (nom, prenom, contact, identifiant operateur), conformément au perimetre defini en 1.1.2 et à l'inspection des colonnes effectivement chargees.
- Maîtrise de la diffusion : aucune des données brutes ou enrichies n'est publiée dans le dépôt Git du projet (les fichiers Parquet sont exclus par `.gitignore`) ; seuls les rapports agrégés et les modèles serialises sont versionnes.

3.3.4 Droits des personnes concernees

Les droits prevus aux articles 15 à 22 du RGPD sont applicables aux données operateurs ERP traitees dans le projet, meme si leur volume est limite et leur exploitation indirecte. Le tableau ci-dessous synthèse le statut de ces droits dans le perimetre du projet.

Droit	Référence	Modalité d'exercice
Accès	Art. 15	Sur demande au DPO GE
Rectification	Art. 16	Mise a jour ERP source
Effacement	Art. 17	Anonymisation totale dans le dataset
Limitation	Art. 18	Suspension de l'inclusion dans le pipeline
Portabilite	Art. 20	Export structure sur demande
Opposition	Art. 21	Exclusion sur demande motivee
Décision automatisée	Art. 22	Non applicable - décision finale humaine

Tableau 9 - Droits RGPD et modalités d'exercice dans le perimetre du projet.

Le point essentiel à souligner est l'article 22 : le RGPD interdit en principe les décisions produisant des effets juridiques ou affectant significativement une personne, prises sur la seule base d'un traitement automatisé. Dans le cas présent, la décision de réapprovisionnement finale reste impérativement humaine (le planificateur valide la commande générée), ce qui place le système hors du périmètre des décisions purement automatisées. Cette caractéristique est centrale dans l'architecture Human-in-the-loop défendue en section 3.4.

3.3.5 Durée de conservation et registre des traitements

La durée de conservation des données brutes 2021-2025 reste celle définie par les politiques internes de GE - non documentées dans le périmètre du présent mémoire - et par les obligations légales applicables aux données commerciales (article L.123-22 du Code de commerce). Les artefacts produits dans le cadre du projet (jeux de données enrichis, modèles serialisés) sont conservés pour la durée du mémoire et feront l'objet d'une revue post-soutenance pour décider de leur sort. Le traitement spécifique réalisé dans le cadre du projet doit être inscrit, le cas échéant, dans le registre des activités de traitement de GE, sous une catégorie d'analyse statistique interne, avec mention explicite du périmètre temporel (2021-2025) et de la finalité (prévision de la demande client).

3.3.6 Positionnement vis-à-vis de l'AI Act européen

Au-delà du RGPD, le règlement européen sur l'intelligence artificielle (AI Act, adopté en 2024, applicable de manière échelonnée à partir de 2025) introduit une classification des systèmes d'IA par niveau de risque. Le système décrit dans ce mémoire relève de la catégorie risque limité : il ne participe pas à une décision affectant directement une personne physique au sens de l'AI Act (recrutement, crédit, éducation, infrastructures critiques), et son usage est interne à l'organisation. Les obligations applicables à cette catégorie - transparence sur l'usage d'un système IA, documentation technique, supervision humaine - sont explicitement couvertes par la model card publiée en annexe, le présent mémoire et la matrice de gouvernance HITL exposée section 3.4. Une évolution du système vers une automatisation totale du réapprovisionnement le ferait basculer en catégorie risque élevé, ce qui nécessiterait des obligations renforcées (audit indépendant, conformité ex ante) explicitement évoquées dans les perspectives de mise en production.

3.4 Importance de la validation humaine (Human-in-the-loop)

3.4.1 Principe et formalisation

Le principe Human-in-the-loop (HITL) constitue la clé de voûte de la philosophie opérationnelle du système. Plutôt que d'opposer intelligence artificielle et expertise humaine, il s'agit de les articuler : le modèle fournit une recommandation transparente assortie d'un score de confiance, le planificateur arbitre en fonction de ce score, du contexte connu de lui seul (relations commerciales, événements anticipés) et de sa propre estimation. La validation humaine demeure le dernier maillon de la chaîne de décision, conformément aux exigences de l'article 22 du RGPD et de l'AI Act européen pour les systèmes de risque limite.

3.4.2 Matrice de gouvernance à trois niveaux

La matrice de gouvernance retenue, configurable via la page Analyse du dashboard, articule trois niveaux de décision en fonction du score de confiance composite calculé pour chaque prédiction.

Niveau	Critère (score)	Action recommandée
Vert	score > 0.75	Automatisation totale - commande validée sans revue
Orange	$0.40 < \text{score} < 0.75$	Revue rapide - validation 1 clic par le planificateur
Rouge	score < 0.40	Décision humaine obligatoire et saisie d'une justification

Tableau 8 - Matrice de gouvernance Human-in-the-loop. Les seuils 0.40 et 0.75 sont configurables depuis la page Analyse du dashboard ; la répartition effective entre les trois niveaux se calcule dynamiquement sur le périmètre courant et n'est pas figée dans ce document.

3.4.3 Boucle d'amélioration continue

Au-delà de la simple validation, le HITL ouvre une boucle d'amélioration continue : chaque correction opérée par un planificateur sur une prédiction (acceptation, modification, refus avec justification libre) est tracée et constitue un signal supplémentaire d'apprentissage potentiel. Une itération ultérieure du système pourrait intégrer cette boucle de feedback dans un schéma d'apprentissage actif (active learning) ou de fine-tuning périodique. Cette piste est documentée dans les perspectives de la section 3.5 et constituerait un gain majeur d'adoption et de robustesse en production.

3.5 Perspectives d'amélioration et de mise en production

3.5.1 Améliorations méthodologiques à court terme

Trois améliorations méthodologiques ont été identifiées comme prioritaires pour une itération ultérieure du projet. Première priorité : la reformulation de la prédiction de date par analyse de survie (modèles Cox proportional hazards via lifelines, Random Survival Forests via scikit-survival, ou DeepSurv via pycox), qui devrait permettre de dépasser largement la précision actuelle de 25.5 pourcents +/-7 jours en exploitant correctement la nature time-to-event du problème. Deuxième priorité : un traitement dédié de la longue traîne via les méthodes Croston, TSB et ADIDA spécialisées dans la demande intermittente, susceptible de réduire significativement la MAE résiduelle sur la longue traîne d'articles à faible volume. Troisième priorité : l'intégration des features exogènes laggees (ipi_valeur_lag1, ipi_valeur_lag3, temperature_lag2), motivée par les résultats du test de Granger (tableau 2) et restée non implémentée pour des raisons d'agenda.

3.5.2 Architecture cible de mise en production

L'architecture cible de mise en production décrite ci-dessous demeure un livrable conceptuel du présent mémoire et n'a pas été déployée dans le périmètre du Master ; elle constitue la principale perspective industrielle du projet et formalise les briques attendues pour un usage opérationnel à l'échelle.

- API d'inférence : FastAPI avec validation de schemas par Pydantic, déployée derrière un reverse proxy Nginx. Endpoints /predict, /explain (SHAP par ligne), /health, /metrics.
- Base de données relationnelle : PostgreSQL avec schemas dédiés pour les prédictions historiques, les feedbacks planificateur (boucle HITL) et les snapshots de modèles. SQLAlchemy comme couche ORM.
- Versioning modèle : MLflow Model Registry avec stages Staging et Production, permettant un retour arrière instantané en cas de régression détectée.
- Versioning données : DVC avec remote S3 ou MinIO interne, pour reproduire toute expérience antérieure à partir de son commit Git.
- Monitoring drift : Evidently AI avec rapport HTML généré automatiquement chaque semaine, intégré au dashboard via iframe.
- Orchestration retrain : Prefect ou Airflow avec un DAG hebdomadaire de re-entraînement, déclenché soit par planification, soit par alerte de drift PSI supérieure à 0.25 sur une feature critique.
- Containerisation : Docker + docker-compose avec services app, db, mlflow, worker, monitoring.

- Observabilité : logs structures via loguru ou structlog, exporter Prometheus, dashboards Grafana, alerting Sentry sur erreurs applicatives.

3.5.3 Roadmap opérationnelle à six mois

Sur la base de cette architecture cible, une roadmap opérationnelle à six mois est proposée : mois 1 - dockerisation du dashboard actuel et exposition d'une API interne FastAPI minimaliste. Mois 2 - migration de l'inférence vers FastAPI, ajout de PostgreSQL pour l'historisation. Mois 3 - intégration MLflow Model Registry. Mois 4 - intégration DVC pour le versioning data. Mois 5 - boucle de feedback planificateur (apprentissage actif sur corrections). Mois 6 - mise en place du monitoring de drift automatisé (Evidently) et activation du retrain planifié. Cette roadmap reste indicative et nécessitera un arbitrage budgétaire dédié de la direction supply chain de GE.

3.5.4 Convergence avec DDMRP en production

Une perspective spécifique mérite d'être soulignée : l'articulation opérationnelle entre le modèle prédictif et la grille DDMRP. La comparaison conduite en section 2.3.4 a montré que l'IA et DDMRP ne sont pas substituables mais complémentaires. Une implémentation cible cohérente consisterait à utiliser la prédiction IA comme entrée du calcul du Net Flow Position de DDMRP, et à maintenir les buffers vert / jaune / rouge comme indicateurs visuels lisibles par les planificateurs. Cette hybridation IA + DDMRP constituerait une contribution méthodologique réutilisable au-delà du seul périmètre GE et mériterait une formalisation académique distincte.

3.6 Conclusion générale

Ce mémoire a entrepris de démontrer qu'une approche Demand-Driven appuyée sur l'intelligence artificielle peut produire une prédiction opérationnelle exploitable de la demande client - en quantité et en date - pour soutenir un planificateur supply chain dans son arbitrage quotidien, sans le remplacer. Au terme du parcours méthodologique qui a structuré les trois parties du document, plusieurs apports complémentaires méritent d'être récapitulés pour formaliser le bilan du travail.

3.6.1 Apports méthodologiques

Le premier apport est la mise en place d'un pipeline complet et reproductible : audit, nettoyage, enrichissement, études statistiques, modélisation, dashboard, évaluation. Une dizaine de notebooks principaux et un dossier models/ serialise documentent ce pipeline et garantissent sa reproductibilité par tout lecteur disposant des données sources. Le second apport est l'intégration d'une démarche d'évaluation honnête : définition explicite d'une baseline historique exigeante, test statistique de Diebold-Mariano pour valider la supériorité du modèle, monitoring de dérive par Population Stability Index sur les features critiques, et confrontation systématique à une baseline DDMRP de référence académique. Le troisième apport est l'articulation entre IA pure et DDMRP, qui rompt avec la dichotomie habituelle entre méthodes traditionnelles et méthodes machine learning pour proposer une hybridation opérationnelle défendable devant un jury comme devant un comité opérationnel.

3.6.2 Apports professionnels pour GE

Les livrables remis à GE comprennent : un dataset propre et enrichi de 349 390 lignes (utilisable pour d'autres analyses ultérieures), cinq modèles serialisés avec leur historique d'hyperparamètres et leurs métriques mesurées (directement re-entraînaibles via le script `src/retrain.py`), un dashboard Streamlit multipage opérationnel sur un poste planificateur standard, un document model card conforme aux standards en vigueur (Google, Hugging Face), une matrice de gouvernance HITL directement intégrée au dashboard et un document de feuille de route à six mois pour la mise en production. Cet ensemble constitue un MVP complet, immédiatement testable en interne, et structure pour préparer un déploiement plus ambitieux.

3.6.3 Apports académiques et personnels

Sur le plan académique, le mémoire propose une démonstration pas-a-pas qu'un projet machine learning industriel peut être honnête sur ses réussites comme sur ses limites. La précision agrégée de 61.7 pourcents obtenue sur la quantité par XGBoost v2 dépasse l'objectif North Star de 60 pourcents et constitue un acquis robuste, tandis que la prédiction de date par LSTM (25.5 pourcents +/-7 jours) reste un échec relatif assumé et documenté. Cette dualité assumée - réussite quantité, échec date - est paradoxalement l'un des principaux apports méthodologiques du document, dans un contexte où la littérature applicative tend à sur-promettre les performances obtenues. Sur le plan personnel, ce travail a permis de cumuler une expérience concrète sur l'ensemble de la chaîne data science (de l'ingénierie au déploiement), d'approfondir la littérature DDMRP à l'interface entre supply chain académique et machine learning appliquée, et de prendre la mesure des compromis nécessaires entre performance brute, interprétabilité et gouvernance humaine.

3.6.4 Limites du travail et ouverture

Les limites du travail ont été listées au fil du document et ne seront pas reprises exhaustivement ici. Quatre points appellent néanmoins une mention finale. Premièrement, le périmètre temporel d'entraînement (2021-2023) contient deux régimes atypiques (Covid puis crise énergétique 2022) dont l'effet résiduel sur le modèle ne sera entièrement quantifiable qu'a posteriori, après plusieurs années de régime normalisé. Deuxièmement, l'absence de données promotionnelles dans le jeu source constitue une limite informationnelle structurelle, dont la levée passerait par une évolution du système ERP source. Troisièmement, le périmètre purement quantitatif du projet n'intègre pas la dimension qualitative des relations commerciales (verbatim client, signaux faibles d'évolution de stratégie), dimension qui constitue pourtant une part importante de l'expertise réelle d'un planificateur. Quatrièmement, le déploiement en production reste un livrable conceptuel ; la traduction opérationnelle complète du système passera par les six mois de roadmap détaillés section 3.5.3, qui ne relèvent plus du Master mais d'un projet professionnel ultérieur.

Au-delà de ces limites, et de l'humilité que doit conserver tout praticien d'un domaine où les modèles vieillissent plus vite que les pratiques métier, le projet démontre qu'une approche scientifique rigoureuse peut être conjuguée à une exigence opérationnelle sans renoncer à la honnêteté intellectuelle qui doit caractériser un travail académique. La trajectoire ainsi tracée - de la donnée brute à la recommandation explicable, du score statistique à la matrice de gouvernance, du tableau de métriques au dashboard interactif - vaut, espère-t-on, comme contribution modeste mais reproductible au champ encore jeune de l'IA appliquée à la chaîne d'approvisionnement industrielle.

Bibliographie

Bai, S., Kolter, J. Z., & Koltun, V. (2018). An Empirical Évaluation of Generic Convolutional and Récurrent Networks for Séquence Modeling. arXiv:1803.01271.

Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 785-794.

Croston, J. D. (1972). Forecasting and stock control for intermittent demands. Operational Research Quarterly, 23(3), 289-303.

Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. Neural Computation, 9(8), 1735-1780.

Hyndman, R. J., & Athanasopoulos, G. (2018). Forecasting: Principles and Practice (2nd ed.). OTexts.

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A Highly Efficient Gradient Boosting Décision Tree. Advances in Neural Information Processing Systems, 30.

Koenker, R., & Bassett, G. (1978). Régression Quantiles. Econometrica, 46(1), 33-50.

Lim, B., Arik, S. O., Loeff, N., & Pfister, T. (2021). Temporal Fusion Transformers for interprétable multi-horizon time series forecasting. International Journal of Forecasting, 37(4), 1748-1764.

Lundberg, S. M., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Prédictions. Advances in Neural Information Processing Systems, 30.

Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2022). The M5 competition: Background, organization, and implémentation. International Journal of Forecasting, 38(4), 1325-1336.

Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B., Spitzer, E., Raji, I. D., & Gebru, T. (2019). Model Cards for Model Reporting. Proceedings of the Conference on Fairness, Accountability, and Transparency, 220-229.

Parlement européen et Conseil de l'Union européenne (2016). Règlement (UE) 2016/679 du 27 avril 2016 relatif à la protection des personnes physiques à l'égard du traitement des données a caractère personnel (RGPD).

Parlement européen et Conseil de l'Union européenne (2024). Règlement établissant des règles harmonisees concernant l'intelligence artificielle (AI Act).

Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: unbiased boosting with categorical features. *Advances in Neural Information Processing Systems*, 31.

Ptak, C., & Smith, C. (2016). *Demand Driven Material Requirements Planning (DDMRP)*. Industrial Press.

Wu, X., Xiao, L., Sun, Y., Zhang, J., Ma, T., & He, L. (2022). A survey of human-in-the-loop for machine learning. *Future Génération Computer Systems*, 135, 364-381.

Zhou, H., Zhang, S., Peng, J., Zhang, S., Li, J., Xiong, H., & Zhang, W. (2021). Informer: Beyond Efficient Transformer for Long Séquence Time-Series Forecasting. *Proceedings of the AAAI Conference on Artificial Intelligence*, 35(12), 11106-11115.

Annexes

Annexe A - Liste des notebooks et livrables

- notebooks/01_data_cleaning.ipynb - Pipeline de nettoyage des données brutes
- notebooks/02_statistical_study.ipynb - Études statistiques et enrichissement exogène
- notebooks/02bis_eda_dataset_enrichi.ipynb - EDA pre-modélisation
- notebooks/03_model_training.ipynb - Entraînement de la première génération de modèles (XGBoost, LightGBM, LSTM)
- notebooks/04_feature_engineering_lags.ipynb - Enrichissement autorégressif (lags, rolling, target encoding) et XGBoost v2
- notebooks/09_baseline_ddmrp.ipynb - Baseline DDMRP
- notebooks/10_catboost_stacking.ipynb - CatBoost v2 et Stacking Ridge
- notebooks/11_backtest_2025_precompute.ipynb - Precomputation du backtest hebdomadaire
- dashboard/app.py + dashboard/pages/*.py - Dashboard Streamlit
- src/retrain.py - Script de re-entraînement
- reports/rapport_phase1_data_engineering.pdf, reports/rapport_phase2.md
- reports/rapport_modelisation.json, reports/sprint_a_chantier1_metrics.json, reports/sprint_b_chantier1_stacking.json, reports/sprint_b_chantier3_ddmrp.json
- docs/MODEL_CARD.md - Model card complete

Annexe B - Extrait Model Card (synthèse)

Identification : XGBoost v2 - models/xgboost_optuna_v2.pkl (configuration de service principale). Architecture alternative : Stacking Ridge - models/stacking_ridge.pkl. Auteur : rédacteur du mémoire - date : mai 2026.

Usage prévu : prédiction de la quantité demandée par couple client-article-mois, horizon M+1 à M+3, en appui d'un planificateur supply chain.

Usage non recommandé : articles jamais vus en entraînement (couples totalement inconnus), ruptures de régime géopolitique brutales, premières commandes de nouveaux clients.

Données d'entraînement : 210 641 lignes, périmètre 2021-2023, 47 features (28 statiques + 19 autorégressives).

Métriques globales (test 2025) : MAE 8.42, RMSE 101.83, R^2 0.666, WAPE 0.383, précision agrégée 61.7 pourcents. Configuration Stacking Ridge alternative : MAE 8.70,

RMSE 97.55, R^2 0.694. Voir tableau 5.

Limites identifiées : précision LSTM date faible (a remplacer par survival analysis), longue traîne sous-performante (a traiter par Croston / TSB).

Biais éthiques : sous-performance sur les petits clients et les articles rares (cf. section 3.2.3).

Date de prochaine revue : décembre 2026, ou plus tot si une alerte de drift PSI supérieure à 0.25 est levée sur une feature critique.

Responsable : a designer parmi les planificateurs senior et la direction supply chain GE.