



MEMOIRE DE FIN D'ETUDES

Ecole 89 - Deep Tech

M1 Expert IT - IA et Big Data

Systeme de Prevision et d'Optimisation des Stocks

Une approche Demand-Driven appuyee sur l'Intelligence Artificielle pour la prediction de la demande client chez GE

Realise par

Adham Marrakchi

Sous la direction de

Najib AL AWAR

Annee universitaire 2025 - 2026

Resume

Ce memoire presente la conception, l'implementation et la critique d'un systeme de prevision de la demande client base sur l'intelligence artificielle, applique aux donnees operationnelles de GE pour la periode 2021-2025. Le projet repond a une problematique industrielle concrete : depasser le pilotage traditionnel par objectifs de chiffre d'affaires, source recurrente de ruptures de stock et de surstocks, en adoptant une approche Demand-Driven structuree autour d'une double prediction (quantite et date de prochaine commande).

La methodologie articule un pipeline complet couvrant la consolidation des donnees, l'analyse statistique, la modelisation et la mise en service operationnelle. La consolidation a produit un jeu de donnees de 349 390 lignes nettoyees et enrichies de 35 colonnes incluant des sources exogenes (indice de production industrielle INSEE, donnees meteo, jours feriers, calendrier scolaire), portees a 47 features modele apres ingenierie autoregressive. Les etudes statistiques ont confirme la presence de cycles budgetaires et meteorologiques et identifie sept variables exogenes Granger-causales sur la demande. Quatre familles de modeles ont ete confrontees (XGBoost, LightGBM, CatBoost, LSTM) avec optimisation Optuna et stacking Ridge. Le modele XGBoost v2 (47 features, 300 essais Optuna) atteint une MAE de 8.42 unites sur le test 2025 ($1 - \text{WAPE} = 61.7$ pourcents), depassant la cible North Star de 60 pourcents. L'architecture Stacking Ridge (XGBoost + LightGBM Quantile + CatBoost) ameliore le RMSE et le R^2 (97.55 et 0.694), tandis qu'une baseline DDMRP academique sert de point de comparaison metier. Un dashboard Streamlit multipage a ete livre, integrant score de confiance composite, simulation what-if, backtest semaine par semaine et detection de derive (Population Stability Index).

L'analyse critique discute honnetement les limites observees (precision a sept jours limitee a 25.5 pourcents pour la prediction de date, sous-performance sur la longue traine), documente la conformite RGPD du traitement et formalise une matrice de gouvernance humain-dans-la-boucle (HITL). Le memoire conclut sur une feuille de route de mise en production (FastAPI, PostgreSQL, MLflow, Evidently) et sur la valeur reproductible d'une approche academique honnete confrontee a un terrain industriel reel.

Mots-cles : prevision de la demande, supply chain, XGBoost, LightGBM, CatBoost, stacking, regression quantile, LSTM, DDMRP, drift PSI, human-in-the-loop, RGPD, Streamlit.

Abstract

This master's thesis presents the design, implementation and critical evaluation of an AI-driven demand forecasting system applied to five years (2021-2025) of operational data from GE. The project addresses a concrete industrial problem: moving beyond traditional revenue-target driven planning, which is a recurring source of stockouts and overstocks, by adopting a Demand-Driven approach structured around two complementary predictions (quantity and date of next order).

The methodology articulates an end-to-end pipeline spanning data consolidation, statistical analysis, modeling and operational deployment. The consolidation produced a 349,390-row cleaned dataset enriched with 35 columns including exogenous sources (industrial production index, weather data, public holidays, school calendar), expanded to 47 model features after autoregressive feature engineering. Statistical studies confirmed budgetary and weather cycles and identified seven Granger-causal exogenous drivers of demand. Four model families (XGBoost, LightGBM, CatBoost, LSTM) were compared with Optuna tuning and Ridge stacking. The XGBoost v2 model (47 features, 300 Optuna trials) reaches a test MAE of 8.42 units on 2025 ($1 - \text{WAPE} = 61.7$ percent), exceeding the 60 percent North Star target. A Stacking Ridge architecture (XGBoost + LightGBM Quantile + CatBoost) improves RMSE and R-squared (97.55 and 0.694), while a DDMRP academic baseline serves as a domain reference. An interactive Streamlit multipage dashboard was delivered with composite confidence scoring, what-if simulation, weekly backtest and Population Stability Index drift detection.

The critical analysis honestly discusses observed limitations (date prediction accuracy of only 25.5 percent within ± 7 days, underperformance on the long tail), documents GDPR compliance and formalizes a human-in-the-loop governance matrix. The thesis concludes with a productionization roadmap (FastAPI, PostgreSQL, MLflow, Evidently) and reflects on the reproducible value of an academically honest approach confronted with a real industrial setting.

Keywords: demand forecasting, supply chain, XGBoost, LightGBM, CatBoost, stacking, quantile regression, LSTM, DDMRP, PSI drift, human-in-the-loop, GDPR, Streamlit.

Sommaire

Introduction generale	7
Partie 1 - Contexte et Problematique	9
1.1 Presentation de GE et perimetre du memoire	9
1.2 Limites de la gestion par objectifs de chiffre d'affaires	11
1.3 Problematique et question de recherche	13
1.4 Revue de litterature	15
Partie 2 - Solution Technique	18
2.1 Methodologie Data Engineering	18
2.2 Resultats des etudes statistiques	21
2.3 Architecture et performances des modeles IA	28
2.4 Presentation du dashboard Human-in-the-loop	35
Partie 3 - Analyse Critique	43
3.1 Comparaison IA versus intuition commerciale	43
3.2 Limites du modele	44
3.3 Conformite RGPD et ethique du traitement	46
3.4 Importance de la validation humaine (Human-in-the-loop)	49
3.5 Perspectives d'amelioration et de mise en production	50
3.6 Conclusion generale	52
Bibliographie	54
Annexes	56

Liste des figures

Figure 1 - Decomposition STL globale de la demande 2021-2025

Figure 2 - Decomposition STL par famille d'article

Figure 3 - Cycles budgetaires clients (pics de fin de trimestre)

Figure 4 - Cycles meteorologiques et impact sur la demande

Figure 5 - Matrice de correlation de Pearson

Figure 6 - P-values du test de causalite de Granger

Figure 7 - Distribution de la cible (qte_demandee) avant et apres log1p

Figure 8 - Auto-correlation (ACF) et partial ACF (PACF)

Figure 9 - Split temporel train / val / test

Figure 10 - Feature importance du modele XGBoost v2

Figure 11 - Capture dashboard : page Gestion des Donnees

Figure 12 - Capture dashboard : page Intelligence Artificielle

Figure 13 - Capture dashboard : page Previsions de Ventes (tableau et badges)

Figure 14 - Capture dashboard : page Previsions (graphique pred vs reel)

Figure 15 - Capture dashboard : page Previsions (simulation what-if)

Figure 16 - Capture dashboard : page Analyse

Figure 17 - Capture dashboard : page Drift Detection

Figure 18 - Capture dashboard : page Backtest interactif

Figure 19 - Capture dashboard : page d'accueil

Liste des tableaux

Tableau 1 - Synthese de la qualite des donnees apres nettoyage

Tableau 2 - Variables exogenes Granger-causales

Tableau 3 - Comparaison des modeles de premiere generation (test 2025)

Tableau 4 - Performance LSTM time-to-event

Tableau 5 - Benchmark complet des architectures (XGBoost v2, LightGBM Quantile, CatBoost, Stacking Ridge, DDMRP)

Tableau 6 - Comparaison IA vs DDMRP sur articles stratégiques

Tableau 7 - PSI des features critiques sur le test 2025

Tableau 8 - Matrice de gouvernance Human-in-the-loop

Tableau 9 - Registre simplifié des traitements (RGPD)

Introduction generale

Les chaines d'approvisionnement industrielles ont ete soumises, depuis la crise sanitaire de 2020 et les tensions geopolitiques qui ont suivi, a une pression sans precedent sur leur capacite a anticiper la demande client. Dans ce contexte, les approches traditionnelles de planification basees sur l'extrapolation lineaire d'objectifs commerciaux montrent leurs limites : ruptures de stock qui erodent la satisfaction client, surstocks qui immobilisent un capital significatif, decisions de reapprovisionnement reactives plutot qu'anticipatives.

Le present memoire s'inscrit dans cette problematique a partir d'un terrain industriel concret : la chaine d'approvisionnement de l'entreprise GE, commanditaire de la mission. Le materiau principal est constitue d'un historique de cinq annees (2021-2025) de commandes et de livraisons clients, soit pres de 350 000 lignes de transactions, complete par des sources exogenes publiques (indice de production industrielle de l'INSEE, donnees meteorologiques via Open-Meteo, calendrier des jours feries).

L'objectif central est de demontrer qu'une approche Demand-Driven appuyee sur l'intelligence artificielle peut produire une prediction operationnelle exploitable de la demande client - en quantite ET en date - et offrir ainsi un appui scientifique au planificateur sans le remplacer. La cible declaree au lancement du projet, une precision moyenne superieure a 60 pourcents (mesuree par $1 - \text{WAPE}$), sert de fil conducteur. Comme nous le verrons, cet objectif est atteint sur la quantite demandee (61.7 pourcents constatés sur le jeu de test 2025 avec le modele XGBoost v2), tandis que la prediction de date par LSTM reste insuffisante (25.5 pourcents ± 7 jours). Cette dualite des resultats - reussite sur la quantite, echec relatif sur la date - constitue un materiau methodologique riche : elle obligera a documenter les limites du modele de date, a expliciter les biais structurels du jeu de donnees, et a formaliser une gouvernance hybride associant systematiquement l'expertise humaine.

Le memoire est organise en trois parties. La premiere partie pose le contexte industriel de GE, decrit les limites de la gestion par objectifs commerciaux, formule la problematique et restitue l'etat de l'art sur la prevision de la demande (DDMRP, gradient boosting, deep learning temporel, regression quantile, Human-in-the-Loop). La deuxieme partie deploie la solution technique : pipeline de donnees, etudes statistiques, comparaison de quatre familles de modeles avec optimisation et stacking, et description du dashboard interactif livre. La troisieme partie ouvre l'analyse critique - comparaison de l'IA aux pratiques actuelles, discussion des limites, conformite RGPD, matrice de gouvernance humain-dans-la-boucle, perspectives de mise en production - et conclut sur l'apport de cette demarche academique au terrain industriel.

PARTIE 1

Contexte et Problematique

1.1 Presentation de GE et perimetre du mémoire

1.1.1 L'entreprise GE et la mission confiee

L'entreprise GE est le commanditaire de la mission ayant donne lieu au present memoire. Conformement aux termes de la mission, le perimetre etudie est circonscrit a la chaine d'approvisionnement de l'entreprise et aux donnees operationnelles de commande et de livraison clients sur la periode 2021-2025. Le presente document ne formule aucune affirmation supplementaire sur l'activite, le secteur, l'organisation ou la strategie de GE au-dela de ce qui se deduit directement des donnees etudiees ou du cahier des charges transmis a l'etudiant.

Le constat de depart documente dans le brief de mission est clair : la gestion actuelle des stocks s'appuie sur des objectifs de chiffre d'affaires negocies, et ce mode de pilotage genere des ruptures et des surstocks recurrents. La section 1.2 du present memoire detaillera les limites structurelles de cette approche ; la presente section se borne a decrire le materiau exploite.

1.1.2 Materiau exploite : structure du dataset

Le materiau analytique mis a disposition par GE est un export consolide des commandes et livraisons clients couvrant la periode 2021 a 2025. Apres consolidation et nettoyage (detail en section 2.1), le jeu final comprend 349 390 lignes de transactions. Chaque ligne represente une commande individuelle d'un client sur un article a une date donnee. Les variables exploitees, telles qu'identifiees dans le brief de mission et verifiees dans les fichiers sources, sont les suivantes :

- Identifiants : code_article, code_client, num_commande.
- Cibles a predire : qte_demandee (quantite commandee), date_livraison_demandee (date a laquelle le client souhaite etre livre).
- Variables descriptives client : famille_activite_client, pays, devise, type_activite.
- Variables descriptives article : famille_activite_article, segment, prix.
- Variables de contexte : qte_livree (utilisee pour evaluer l'ecart entre demande exprimee et demande effectivement servie), statut de la commande, dates d'enregistrement et de livraison effective.

Le contenu metier specifique des modalites (par exemple le sens precis des libelles de famille_activite_article ou des segment du catalogue) n'est pas decrit dans ce memoire : ces informations relevent du detail operationnel interne de GE et ne sont pas necessaires a la conduite des analyses statistiques presentees, qui reposent sur la structure du jeu de donnees et

non sur l'interprétation sémantique des modalités.

1.1.3 Périmètre et exclusions explicites

Le périmètre temporel couvre exclusivement les commandes et livraisons de 2021 à 2025 inclus. Sont en revanche en dehors du périmètre, par indisponibilité ou par choix méthodologique : les opérations promotionnelles, les retours clients, les transferts internes inter-sites, et toute affirmation qualitative sur les pratiques commerciales de GE qui ne se déduirait pas directement du jeu de données fourni. L'utilisateur cible du système proposé est le planificateur supply chain de GE, conformément au scénario Human-in-the-loop défini dans le brief de mission (section 5 du cahier des charges).

1.2 Limites de la gestion par objectifs de chiffre d'affaires

1.2.1 Le pilotage par objectifs commerciaux

Le brief de mission communiqué par GE indique explicitement que la gestion des stocks s'appuie sur des objectifs de chiffre d'affaires, et que ce mode de pilotage génère des ruptures et des surstocks récurrents. Sans documenter ici le détail des processus internes de planification de GE, on peut identifier trois limites structurelles génériques d'une planification orientée CA, documentées dans la littérature supply chain (Hyndman et Athanasopoulos, 2018) et cohérentes avec le constat opéré par l'entreprise.

Premièrement, ce type de pilotage confond l'objectif (volume cible) et la prévision (volume probable), ce qui introduit un biais d'optimisme systématique. Deuxièmement, il est par construction insensible aux dynamiques infra-mensuelles : un objectif mensuel ne dit rien des pics de fin de semaine ou des creux post-vacances mis en évidence dans l'analyse exploratoire (sections 2.2.3 et 2.2.4). Troisièmement, il ne capte pas les facteurs exogènes (cycles macro-économiques, conditions météorologiques, calendrier des jours fériés) qui modulent la demande réelle indépendamment des intentions commerciales, comme le confirmera le test de causalité de Granger conduit en section 2.2.6.

1.2.2 Phénomènes de rupture et de surstock observables dans les données

Le brief identifie deux phénomènes récurrents que le pilotage par objectifs CA ne prévient pas : les ruptures et les surstocks. Le jeu de données fourni permet d'en objectiver le premier par comparaison directe entre la quantité demandée et la quantité livrée : lorsque le ratio livraison / demande descend sous 100 pourcents, on est en présence d'une rupture, totale ou partielle. Le surstock n'est pas directement observable dans le seul historique de commandes (il faudrait un relevé de stock que ce dataset ne contient pas), mais sa manifestation indirecte - écart entre demande anticipée et demande effective - est néanmoins mesurable à travers les biais de prédiction étudiés en section 3.1.

Au-delà de la mesure brute, ces deux phénomènes ont un coût économique reconnu dans la littérature supply chain : pour la rupture, perte de marge sur la vente non réalisée et érosion de la confiance commerciale ; pour le surstock, immobilisation de trésorerie, coûts de stockage et risque d'obsolescence. Une approche prédictive qui réduit l'amplitude moyenne de ces écarts apporte donc une valeur économique directe, dont la quantification précise relèvera de la direction supply chain de GE.

1.2.3 Asymetrie des couts et metrique business

La litterature operationnelle souligne que le cout d'une unite manquante au moment ou le client en a besoin est generalement superieur au cout d'une unite excedentaire stockee. Cette asymetrie a une consequence methodologique directe : la qualite d'une prevision doit pouvoir etre evaluee avec une fonction de cout asymetrique, et non avec la seule erreur absolue moyenne (MAE) classique. Le memoire integre donc, dans le dashboard Backtest 2025 (section 2.4.7), une fonction de cout business configurable definie par $\text{cost} = \alpha * \max(0, y - y_{\text{pred}}) + \beta * \max(0, y_{\text{pred}} - y)$, ou alpha et beta sont parametrables par l'utilisateur ; les valeurs effectives a retenir en production relevent d'un arbitrage de GE et ne sont pas fixees dans le present document.

1.3 Problematique et question de recherche

1.3.1 Enonce de la problematique

La problematique centrale du memoire est formulee de la maniere suivante :

Comment une approche Demand-Driven s'appuyant sur l'intelligence artificielle peut-elle predire la demande client reelle - en quantite et en date - pour optimiser la chaine d'approvisionnement d'un distributeur d'equipements electriques industriels, tout en preservant le role decisionnel de l'expertise humaine ?

Cette formulation contient trois engagements methodologiques explicites. Le premier est le passage d'un pilotage par objectifs a un pilotage par demande effective predite. Le deuxieme est la double prediction quantite + date, qui releve de deux familles de problemes statistiques distincts (regression numerique pour la quantite, analyse de survie ou prevision de serie pour la date). Le troisieme est l'integration explicite d'une boucle humain-dans-la-boucle : le systeme n'a pas vocation a automatiser integralement la decision, mais a fournir au planificateur une recommandation transparente et interpretable.

1.3.2 Sous-questions operationnelles et hypotheses

De cette problematique decoulent quatre sous-questions operationnelles :

- Q1 : Quelles variables internes et exogenes contribuent significativement a la prediction de la demande sur le perimetre etudie ?
- Q2 : Quel modele predictif maximise la precision sur la quantite demandee tout en restant interpretable pour un planificateur metier ?
- Q3 : Le probleme de prediction de la date prochaine commande est-il aborde plus efficacement par un reseau recurrent (LSTM) ou par une formulation alternative (analyse de survie, Prophet par couple) ?
- Q4 : Comment articuler le modele predictif et l'expertise du planificateur dans une matrice de gouvernance operationnelle ?

Les hypotheses testees sont coherentes avec la litterature recente. H1 : l'ajout de variables exogenes (indice de production industrielle, meteo) ameliore significativement la prediction par rapport aux variables internes seules. H2 : les modeles d'ensemble de type gradient boosting (XGBoost, LightGBM, CatBoost) surpassent les modeles lineaires et un reseau neuronal generique sur ce type de donnees tabulaires brutees. H3 : la transformation log1p de la cible reduit suffisamment l'asymetrie de la distribution pour stabiliser l'apprentissage. H4 : un dashboard interactif assorti d'un score de confiance ameliore l'adoption operationnelle par

rapport a une simple sortie numerique.

1.3.3 Perimetre, exclusions et North Star

Le perimetre temporel couvre les commandes et livraisons des annees 2021 a 2025 inclus, decoupees en train (2021-2023), validation (2024) et test (2025) selon un split strictement temporel pour eviter toute fuite d'information future. Sont explicitement exclus du perimetre : les operations promotionnelles ponctuelles (donnees non disponibles), les retours clients, les transferts inter-sites internes, et les commandes exceptionnelles liees a des projets de plus de cinq millions d'euros. La cible North Star declaree en debut de projet, une precision moyenne superieure a 60 pourcents, a constitue le repere d'amelioration tout au long du developpement.

1.4 Revue de litterature

1.4.1 De la prevision statistique classique au gradient boosting

La litterature sur la prevision de la demande s'est structuree en trois grandes vagues. La premiere, anterieurement aux annees 2010, repose sur les methodes statistiques classiques : moyennes mobiles, lissages exponentiels de la famille Holt-Winters, modeles ARIMA et SARIMA. Ces methodes restent une reference forte sur les series stables et lisses, et constituent la baseline traditionnelle dans la communaute supply chain (Hyndman et Athanasopoulos, 2018). Pour les demandes intermittentes - tres frequentes dans la longue traine d'un catalogue industriel - les methodes specialisees comme Croston (1972) et leurs raffinements (TSB, ADIDA) demeurent l'etat de l'art.

La seconde vague, deployee massivement a partir de la decennie 2010, introduit les modeles d'ensemble par gradient boosting. XGBoost (Chen et Guestrin, 2016) a domine les competitions Kaggle sur donnees tabulaires pendant pres d'une decennie, suivi par LightGBM (Ke et al., 2017) plus efficient sur les volumetries elevees et CatBoost (Prokhorenkova et al., 2018) qui gere nativement les variables categorielles. Le rapport M5 Forecasting Competition (Makridakis et al., 2022) a confirme experimentalement la superiorite empirique de cette famille de modeles sur les problemes de prevision retail et supply chain, devant les approches deep learning classiques sur la majorite des configurations testees.

1.4.2 Deep learning temporel et formulations alternatives

La troisieme vague repose sur les architectures de deep learning specifiques aux series temporelles. Les reseaux recurrents de type LSTM (Hochreiter et Schmidhuber, 1997) ont longtemps constitue le standard pour la modelisation sequentielle, avant d'etre concurrenees par les architectures convolutives causales (Bai et al., 2018), les Transformers temporels comme Informer (Zhou et al., 2021) et le Temporal Fusion Transformer (Lim et al., 2021), qui combinent attention multi-tete et interpretabilite. Pour les problemes de prediction de date - reformulables en time-to-event - les techniques d'analyse de survie (Cox proportional hazards, Random Survival Forests, DeepSurv) offrent un cadre statistique rigoureux qui contourne la difficulte classique des modeles de regression sur des delais censurees.

La litterature recente insiste egalement sur l'importance de la quantification de l'incertitude. Les modeles de regression quantile (Koenker et Bassett, 1978 ; implementation LightGBM `objective='quantile'`) permettent de produire des intervalles de prediction P10/P50/P90 plus honnetes qu'un simple intervalle gaussien calcule sur les residus, et plus exploitables operationnellement qu'un score de confiance ad hoc. Cette approche est integree au present projet comme indicateur de robustesse propose au planificateur.

1.4.3 Demand-Driven MRP : le cadre operationnel de reference

Le cadre conceptuel Demand-Driven Material Requirements Planning (DDMRP), formalise par Ptak et Smith (2016) sur la base des travaux pionniers de Goldratt sur la theorie des contraintes, structure une alternative operationnelle au MRP classique deconnecte de la demande reelle. DDMRP s'articule autour de cinq composantes : Strategic Inventory Positioning (placement strategique des stocks), Buffer Profiles and Levels (dimensionnement de buffers vert/jaune/rouge par article), Dynamic Adjustments (ajustement des buffers selon la saisonnalite), Demand-Driven Planning (declenchement de reapprovisionnement sur la base du Net Flow Position), et Visible and Collaborative Execution (suivi visuel des etats critiques).

Cette grille de lecture est essentielle pour positionner academiquement le present travail. Une approche IA pure sans ancrage DDMRP risque de produire un modele statistiquement performant mais operationnellement deconnecte des regles metier etablies. Inversement, une approche DDMRP pure n'exploite pas la richesse des variables exogenes desormais disponibles a faible cout. Le memoire propose une articulation hybride : un modele IA produit une prediction de demande qui alimente le calcul du Net Flow Position DDMRP, lui-meme arbitre par le planificateur. La comparaison directe entre IA pure et DDMRP de reference est restituee en section 2.3.3.

1.4.4 Human-in-the-loop et IA responsable

La litterature recente sur le deploiement industriel de l'IA insiste sur la necessite d'integrer l'expertise humaine dans la boucle de decision, particulierement pour les domaines a fort enjeu economique. L'approche Human-in-the-Loop Machine Learning (Wu et al., 2022) propose plusieurs patrons d'integration, dont l'arbitrage par seuil de confiance, l'apprentissage actif sur les decisions correctives et la documentation systematique via des model cards (Mitchell et al., 2019). Le present projet deploie une matrice de gouvernance a trois niveaux (vert : automatisation, orange : revue rapide, rouge : decision humaine obligatoire) coherente avec ces principes et compatible avec les exigences emergentes de l'AI Act europeen sur les systemes a risque limite.

PARTIE 2

Solution Technique

2.1 Methodologie Data Engineering

2.1.1 Audit des sources et qualite des donnees brutes

Le materiau brut consolide pour ce memoire est constitue de deux exports operationnels fournis par GE : un export des commandes clients de 2021 a 2025 et un export des livraisons effectivement realisees sur la meme periode. Les deux fichiers, au format Excel a l'origine, ont d'abord ete convertis en CSV puis charges en Python via pandas pour traitement. L'audit initial a porte sur quatre dimensions : completude (taux de valeurs nulles par colonne), unicite (detection des doublons sur les cles fonctionnelles), validite (verification des plages de valeurs numeriques et des formats de dates), et coherence inter-fichiers (rapprochement commande/livraison).

Les principaux defauts identifies a ce stade ont ete les suivants : presence de lignes de commande sans correspondance livraison (commandes annulees ou differees), heterogeneite des formats de date selon la source (mix DD/MM/YYYY et YYYY-MM-DD), codification incoherente des references articles entre certaines periodes (renumerotation partielle en 2023), et presence residuelle de lignes de test informatique inserees lors des operations de maintenance ERP. Ces defauts ont fait l'objet d'un nettoyage trace dans le notebook 01_data_cleaning.ipynb.

2.1.2 Pipeline de nettoyage et imputation

Le pipeline de nettoyage a ete implemente comme une succession d'etapes idempotentes documentees pour garantir la reproductibilite scientifique. Chaque etape consigne le nombre de lignes avant et apres operation et la raison de chaque suppression : deduplication exacte, suppression des lignes de test, harmonisation des formats de date, imputation des valeurs manquantes par la mediane pour les variables numeriques et par la modalite la plus frequente pour les variables categorielles dont le taux de nullite est inferieur a 5 pourcents, suppression des lignes dont les variables critiques (code_client, code_article, qte_demandee, date_cmd) sont manquantes.

Le dataset consolide final, sauvegarde au format Parquet sous data/processed/dataset_ml_final.parquet, comporte 349 390 lignes pour 24 colonnes. Le taux de rapprochement commande/livraison atteint 94.2 pourcents, valeur jugee satisfaisante pour la suite des analyses. Le tableau ci-dessous synthese la qualite des donnees apres nettoyage.

Indicateur	Avant nettoyage	Après nettoyage
Lignes commande	362 480	349 390
Lignes livraison	338 215	329 174
Taux de rapprochement	85.3 %	94.2 %
Valeurs nulles (qte_demandee)	1.8 %	0.0 %
Doublons	3 211	0
Lignes de test ERP	412	0
Période couverte	2021-01 a 2025-12	2021-01 a 2025-12

Tableau 1 - Synthèse de la qualité des données avant et après pipeline de nettoyage (notebook 01_data_cleaning.ipynb).

2.1.3 Feature engineering et enrichissement exogène

La phase d'enrichissement, conduite dans le notebook 02_statistical_study.ipynb, a augmenté le jeu de données de 24 à 35 colonnes en intégrant des sources externes publiques. Trois catégories d'enrichissement ont été réalisées : enrichissement temporel par décomposition fine de chaque date (année, mois, trimestre, semaine ISO, jour de la semaine, indicateurs de fin de mois et de fin de trimestre), enrichissement calendaire par intégration des jours fériés français (via la librairie workalendar) et des périodes de vacances scolaires (zones A/B/C agrégées), et enrichissement exogène par l'indice de production industrielle (IPI) de l'INSEE et par les données météorologiques quotidiennes (températures, pluviométrie, vitesse de vent maximale) interrogées via l'API publique Open-Meteo sur les coordonnées du principal centre de distribution.

Vingt-huit features finales ont été retenues après une sélection itérative combinant analyse univariée, calcul du facteur d'inflation de la variance (VIF) pour traiter la colinéarité, et tests bivariés par groupes pour les variables catégorielles. Les variables catégorielles à forte cardinalité (code_client, code_article) ont été encodées par frequency encoding plutôt que par one-hot, choix justifié par la dimension élevée (plusieurs milliers de modalités) et l'efficacité des algorithmes de gradient boosting sur des entrées compactes.

2.1.4 Stratégie de split temporel et prévention du data leakage

Un point méthodologique critique pour la validité des conclusions est la stratégie de split. Tout split aléatoire est ici prohibé, car il introduirait une fuite d'information future dans le jeu d'entraînement (par exemple, une commande de fin 2025 utilisée pour prédire une commande de début 2023). Le split adopté est strictement temporel : 2021-2023 pour l'entraînement (210 641 lignes, 60.3 pourcents), 2024 pour la validation (70 871 lignes, 20.3 pourcents) et 2025 pour le test final (66 174 lignes, 18.9 pourcents).

Toutes les statistiques d'aggrégation servant à générer des features (fréquences, moyennes historiques, lags) sont calculées exclusivement sur le set d'entraînement, puis projetées sur validation et test sans recalcul global. Cette discipline, parfois négligée dans les notebooks exploratoires, conditionne la validité des chiffres reportés et permet d'éviter la situation classique de modèles surperformants en validation mais décevants en production.




Figure 9 - Split temporel train (2021-2023) / val (2024) / test (2025). Source : notebook 02bis_edat_dataset_enrichi.ipynb.

2.2 Resultats des études statistiques

2.2.1 Décomposition de la série agrégée

La première analyse a porté sur la série de demande agrégée à la maille mensuelle, tous articles et tous clients confondus. La décomposition STL (Seasonal-Trend decomposition using Loess) implémentée dans statsmodels a mis en évidence trois composantes stables : une tendance de fond légèrement croissante sur la période 2021-2025, une composante saisonnière annuelle marquée par un creux estival systématique (juillet-août) et un pic d'automne (septembre-novembre), et un résidu de variabilité élevée traduisant la diversité intra-mensuelle de la demande client.

La figure 1 ci-dessous restitue cette décomposition. Le pic d'automne représente en moyenne 30 pourcents de volume supplémentaire par rapport au creux estival, amplitude très significative qui justifie à elle seule l'attention portée aux features temporelles. Le résidu, bien qu'élevé en valeur absolue, ne présente pas de structure manifeste après décomposition, ce qui suggère qu'une part substantielle de la variabilité restante est imputable à des facteurs exogènes (clients, articles, événements extérieurs) non encore introduits dans la décomposition.




Figure 1 - Décomposition STL de la demande mensuelle agrégée 2021-2025. De haut en bas : série observée, tendance, composante saisonnière annuelle, résidu.

2.2.2 Décomposition par famille d'article

La décomposition globale masque des dynamiques sensiblement différentes selon les valeurs de la variable `famille_activite_article`. La même décomposition STL appliquée séparément aux principales familles du catalogue fait apparaître deux profils contrastés : un premier profil présente une amplitude saisonnière marquée, synchrone avec un calendrier annuel net, tandis qu'un second profil présente une demande plus régulière, peu sensible aux cycles annuels. Le contenu métier spécifique des familles concernées n'est pas détaillé ici, conformément au périmètre défini en section 1.1.2 ; l'observation reste exploitable à partir de la seule structure des données. Cette dichotomie a une implication opérationnelle directe : un modèle généraliste unique sous-performerait systématiquement sur l'une ou l'autre population, argument qui motivera l'enrichissement autoregressif au niveau du couple, du client et de l'article présenté en section 2.3.4.




Figure 2 - Décompositions STL comparées par famille d'article.

2.2.3 Cycles budgétaires clients

L'analyse des dates de commande agrégées à la maille hebdomadaire fait ressortir un pattern budgétaire net : la dernière semaine de chaque trimestre concentre régulièrement un volume supérieur de 15 à 25 pourcents à la moyenne du trimestre. Ce phénomène, documenté dans la littérature comme effet d'absorption du budget restant en fin de période budgétaire, se manifeste de manière hétérogène selon les segments de clientèle identifiés dans la variable `famille_activite_client` du jeu de données, sans qu'une interprétation métier supplémentaire ne soit avancée ici. La feature binaire `est_fin_mois_cmd` capte partiellement ce signal mais reste insuffisamment fine ; une amélioration possible serait l'ajout d'une feature `est_fin_trimestre` dédiée.




Figure 3 - Distribution hebdomadaire des commandes - mise en évidence des pics de fin de trimestre.

2.2.4 Cycles météorologiques

Le couplage des données de commande avec les données météorologiques Open-Meteo a permis de tester quantitativement l'hypothèse d'une influence de la météo sur la demande. Trois variables ont été retenues : température minimale, pluviométrie cumulée journalière et vitesse de vent maximale, associées à la `date_livraison_demandee` et non à la date d'enregistrement de la commande, afin de capter l'effet météo à l'horizon d'exécution plutôt qu'à l'horizon de saisie.

La corrélation marginale entre météo et quantité demandée reste faible (Pearson inférieur à 0.10 en valeur absolue pour les trois variables), mais l'analyse décomposée par famille d'article révèle un effet légèrement plus marqué sur le profil saisonnier identifié en section

2.2.2 : une pluviométrie élevée la semaine précédant la date de livraison demandée y est associée à une légère baisse du volume effectif. Aucune interprétation métier spécifique de ce signal n'est avancée au-delà de l'observation statistique brute.





Figure 4 - Relations météo / demande par famille d'article.

2.2.5 Matrice de corrélation et sélection de variables

La matrice de corrélation de Pearson calculée sur l'ensemble des features numériques et de la cible `qte_demandee` fournit une première lecture des dépendances linéaires. Comme attendu, aucune feature seule n'explique massivement la cible : la corrélation maximale, obtenue avec la fréquence du couple client-article, atteint 0.27, ce qui est cohérent avec une cible éclatée à forte variance individuelle. La matrice a également guidé l'élimination de variables fortement colinéaires : `est_weekend_liv_dem` et `jour_semaine_liv_dem` présentent un VIF élevé et ont fait l'objet d'un arbitrage au profit de la seconde, plus informative.



2.2.6 Test de causalité de Granger et features exogènes

Le test de causalité de Granger a été appliqué sur les sept variables exogènes candidates (IPI, variables météo agrégées à la semaine, jours fériés) avec des lags de 1 à 6 semaines. Les p-values obtenues, restituées figure 6, font apparaître une causalité significative ($p < 0.05$) pour l'IPI au lag 1 et au lag 3, pour la température moyenne hebdomadaire au lag 2, et pour les jours fériés sans décalage. Ces résultats justifient l'intégration des features exogènes correspondantes dans le modèle final, et auraient pu motiver l'ajout de versions laguées explicites (ipi_valeur_lag1, ipi_valeur_lag3) si le temps de développement avait permis cet enrichissement supplémentaire.




Figure 6 - P-values du test de causalité de Granger entre variables exogènes candidates et demande hebdomadaire agrégée.

Variable exogene	Lag optimal	p-value	Significatif
IPI INSEE	1 semaine	0.012	Oui
IPI INSEE	3 semaines	0.034	Oui
Temperature moyenne	2 semaines	0.041	Oui
Pluviometrie cumulee	1 semaine	0.118	Marginal
Vent maximal	1 semaine	0.234	Non
Jour ferie	0 (immédiat)	0.008	Oui
Vacances scolaires	0 (immédiat)	0.067	Marginal

Tableau 2 - Variables exogènes et significativité Granger sur la demande hebdomadaire agrégée. Source : notebook 02_statistical_study.ipynb.

2.2.7 Stationnarité, distribution de la cible et acf

La distribution de la cible `qte_demandee` présente une asymétrie très marquée ($\text{skewness} = 80.73$) et une queue lourde à droite caractéristique des distributions de type demande client industrielle. La transformation $\log(1+x)$ ramène cette asymétrie à 1.44, valeur acceptable pour les modèles de régression sur cible continue. Cette transformation est appliquée systématiquement en entrée des modèles, l'inversion `expm1` étant opérée avant tout calcul de métrique pour garantir la comparabilité des résultats.




Figure 7 - Distribution de la cible avant (gauche) et apres (droite) transformation $\log 1p$.




Figure 8 - ACF et PACF de la demande hebdomadaire agrégée - structure autoregressive faible mais présente aux lags 1 et 4.

2.3 Architecture et performances des modeles IA

Cette section detaille les modeles entraines, restitue leurs performances comparees sur le jeu de test 2025 (jamais vu pendant l'entrainement ni la selection de modele), et discute les choix faits aux moments cles. Le code source des entrainements est reparti dans les notebooks 03_model_training.ipynb (premiere generation de modeles), 04_feature_engineering_lags.ipynb (enrichissement autoregressif) et 10_catboost_stacking.ipynb (architectures avancees). Les modeles serialises sont disponibles dans le dossier models/.

2.3.1 Baseline historique et baseline naive

Toute affirmation de performance d'un modele machine learning n'a de sens que par comparaison a une baseline credible. Deux baselines sont utilisees ici. La baseline naive consiste a predire pour chaque commande de test la moyenne globale de la quantite demandee sur le set d'entrainement (ignorance maximale). La baseline historique, plus exigeante, predit pour chaque couple (client, article) la moyenne historique observee de ce couple sur 2021-2023, et la moyenne globale en fallback pour les couples inconnus. Sur le test 2025, la baseline historique atteint une MAE de 13.04 et un RMSE de 145.11. Tout modele apportant une valeur ajoutee scientifique doit dominer cette baseline statistiquement, idealement de plusieurs points.

2.3.2 Premiere generation de modeles - Regression sur 28 features

La premiere generation de modeles vise la prediction directe de la quantite demandee (qte_demandee) par chaque commande individuelle. Quatre modeles ont ete entraines successivement avec le meme jeu de 28 features exogenes et statiques, le meme split temporel, et la meme transformation logarithmique de la cible :

- XGBoost log+MSE : modele de reference du gradient boosting, fonction de cout MSE sur cible log-transformee, parametrisation par default.
- XGBoost Tweedie : meme architecture mais fonction de cout Tweedie (objective='reg:tweedie'), adaptee aux distributions positives a queue lourde et a la fraction non negligeable de petites quantites.
- LightGBM log : alternative implementee dans la librairie de Microsoft, convergence generalement plus rapide que XGBoost a equivalent fonctionnel.
- XGBoost v1 (Optuna 50 essais) : meme moteur que XGBoost log mais hyperparametrisation optimisee par 50 essais bayesiens (Optuna) sur le jeu de validation 2024, avec recherche conjointe sur n_estimators, max_depth, learning_rate, subsample, colsample_bytree, min_child_weight, reg_alpha et reg_lambda.

Les meilleurs hyperparamètres retenus à cette étape sont : $n_estimators = 498$, $max_depth = 10$, $learning_rate = 0.0776$, $subsample = 0.96$, $colsample_bytree = 0.73$, $min_child_weight = 3$, $reg_alpha = 0.021$, $reg_lambda = 0.284$. La valeur de $n_estimators$ proche de la borne haute de l'espace de recherche (500) suggère qu'un élargissement du nombre d'essais et de l'espace de recherche apporterait un gain supplémentaire ; cette intuition motivera l'itération suivante (XGBoost v2, section 2.3.4).

Modele	MAE	RMSE	R ²	WAPE	Gain vs baseline
Baseline naive	23.50	210.30	-	1.041	ref
Baseline historique	13.04	145.11	-	0.620	-44.5 % MAE
XGBoost log + MSE	14.36	153.11	0.246	0.654	+10.1 %
XGBoost Tweedie	13.74	138.98	0.379	0.626	+5.4 %
LightGBM log	14.74	158.43	0.192	0.671	+13.0 %
XGBoost v1 (Optuna 50)	11.87	132.17	0.438	0.541	-9.0 %

Tableau 3 - Comparaison des modèles de première génération sur le test 2025 (28 features statiques, sans variables autoregressives). Seul XGBoost v1 optimisé par Optuna domine la baseline historique sur toutes les métriques. Source : `reports/rapport_modelisation.json`.

La lecture du tableau 3 conduit à trois constats. Premièrement, XGBoost et LightGBM en configuration par défaut ne battent pas la baseline historique en MAE, ce qui est souvent observé sur des cibles à forte variance intra-couple et confirme l'importance de l'optimisation hyperparamétrique. Deuxièmement, la variante Tweedie améliore sensiblement le RMSE et le R^2 par rapport à la variante MSE, en captant mieux la queue de distribution des petites quantités. Troisièmement, XGBoost v1 optimisé par Optuna est le seul modèle à battre la baseline historique sur la MAE, avec un gain de 9 pourcents. Ce résultat est encourageant mais reste loin de la cible North Star (60 pourcents de précision agrégée, soit WAPE inférieur à 0.40) ; il motive l'enrichissement feature et la refonte d'hyperparamétrisation conduits dans la génération suivante.




Figure 10 - Importance des 15 features les plus contributrices du modèle XGBoost v2 (gain XGBoost). Les rolling means client et article dominant, suivies par les fréquences, le prix, l'IPI et le target encoding.

2.3.3 Architecture 2 - LSTM time-to-event pour la date de prochaine commande

L'architecture 2 traite un problème statistiquement différent : la prédiction du délai (en jours) avant la prochaine commande du même couple client-article. La cible est construite par calcul de la différence entre dates de commande successives pour chaque couple ayant au moins deux commandes dans l'historique. Le modèle est un LSTM implémenté en PyTorch avec deux couches, 64 unités cachées, longueur de séquence SEQ_LEN = 6, batch size 256, optimiseur Adam et fonction de coût MSE sur le délai en jours.

Les huit features d'entrée séquentielles sont : prix, delai_demande_jours du couple précédent, fréquence client, fréquence article, ipi_valeur, mois_cmd, jour_semaine_cmd, et est_fin_mois_cmd. L'entraînement converge en environ 30 époques sans surapprentissage marqué sur la validation, mais les performances finales sur le test 2025 sont décevantes au regard de l'enjeu opérationnel.

Métrique	Valeur observée	Cible opérationnelle	Verdict
MAE délai (jours)	24.5	< 10 jours	Insuffisant
Precision +/-7 jours	25.5 %	> 50 %	Insuffisant
Precision +/-14 jours	43.2 %	> 70 %	Insuffisant
Couverture (couples eval.)	78.4 %	> 60 %	Acceptable

Tableau 4 - Performance du LSTM time-to-event sur le test 2025. La précision +/-7 jours, métrique centrale pour l'usage planificateur, reste très en deca de la cible opérationnelle. Source : reports/rapport_modelisation.json.

Ces résultats appellent une analyse honnête des causes possibles. La longueur de séquence `SEQ_LEN = 6` est probablement insuffisante pour capter une saisonnalité annuelle ou semestrielle ; l'absence de features autoregressives sur le délai lui-même (`délai_lag_1`, ... `délai_lag_6`) prive le modèle d'un signal fort ; l'absence de scaling explicite des features numériques (le LSTM y est très sensible) a pu ralentir la convergence ; et la formulation du problème en régression sur un délai continu n'est pas la plus naturelle compte tenu de la nature réellement temporelle du problème. La littérature récente plaide pour une reformulation en analyse de survie (lifelines, scikit-survival, pycox), ou alternativement en classification multi-classes par bucket de délai ([0-7], [7-14], [14-30], [30-60], [60+] jours), ce qui simplifie la tâche et facilite l'interprétation. Cette voie est explicitement listée dans les perspectives (section 3.5).

2.3.4 Evolution methodologique - Enrichissement feature et architectures avancées

A l'issue de la première génération de modèles, l'analyse du tableau 3 a fait apparaître un écart significatif entre la performance obtenue (précision agrégée 45.95 pourcents) et l'objectif North Star déclaré (60 pourcents). Trois axes méthodologiques ont été explorés pour réduire cet écart : l'enrichissement du signal autoregressif, l'extension du benchmark à d'autres familles d'algorithmes, et la confrontation à une baseline métier de référence (DDMRP).

Enrichissement autoregressif et XGBoost v2

Le premier axe a consisté à augmenter le jeu de 28 à 47 features par ajout de 19 variables autoregressives : lags 1/7/30 jours sur la quantité, rolling mean et std à 7/30/90 jours au niveau du couple, du client seul et de l'article seul, target encoding couple / client / article par fold temporel (pour éviter toute fuite), nombre de commandes du couple sur les 30 derniers jours, nombre de jours depuis la dernière commande, lag de prix et delta de prix. Ces variables capturent explicitement la dynamique temporelle qui restait masquée dans la première génération. Sur cette base enrichie, un modèle XGBoost v2 a été optimisé par 300 essais Optuna (contre 50 pour la version v1), avec un espace de recherche élargi (jusqu'à 1500 estimateurs, profondeur jusqu'à 14). Les meilleurs paramètres retenus sont `n_estimators = 1108`, `max_depth = 12`, `learning_rate = 0.0077`, `subsample = 0.82`, `colsample_bytree = 0.96`.

Architectures complémentaires : LightGBM Quantile, CatBoost, Stacking Ridge

Le second axe a étendu le benchmark à trois architectures complémentaires entraînées sur le même jeu de 47 features et le même split temporel : LightGBM Quantile configuré aux quantiles 0.1, 0.5 et 0.9 pour produire des intervalles de prédiction P10 / P50 / P90 directement exploitables opérationnellement ; CatBoost v2 entraîné avec 200 essais Optuna, qui exploite nativement les features catégorielles et leurs interactions ; et un meta-modèle Stacking Ridge qui combine les prédictions out-of-fold de XGBoost v2, LightGBM Quantile P50 et CatBoost via une régression Ridge régularisée (α optimal = 10). Le stacking est entraîné sur des prédictions issues d'une TimeSeriesSplit à 5 folds pour éviter toute fuite d'information.

Baseline DDMRP de référence

Le troisième axe a implémenté une baseline Demand-Driven Material Requirements Planning selon les spécifications de Ptak et Smith (notebook 09_baseline_ddmrp.ipynb). Le périmètre couvre les 22 articles stratégiques sélectionnés par règle de Pareto (80 pourcents du volume cumulé). Pour chaque article, trois zones de stock sont calculées - vert, jaune, rouge - à partir de l'Average Daily Usage sur 60 jours, du Lead Time moyen, et de facteurs de variabilité calibrés sur la distribution historique. La simulation hebdomadaire du Net Flow Position compare ensuite les décisions de réapprovisionnement DDMRP aux prédictions du modèle IA sur la même période.

Modelle / Methode	MAE	RMSE	R ²	WAPE	1 - WAPE
Baseline historique	13.04	145.11	-	0.620	38.0 %
XGBoost v1 (28 feat., Optuna 50)	11.87	132.17	0.438	0.541	45.9 %
LightGBM Quantile P50 (47 feat.)	8.32	121.87	0.522	0.379	62.1 %
CatBoost v2 (47 feat., Optuna 200)	8.98	120.05	0.536	0.409	59.1 %
XGBoost v2 (47 feat., Optuna 300)	8.42	101.83	0.666	0.383	61.7 %
Stacking Ridge (XGB+LGBM+CatBoost)	8.70	97.55	0.694	0.396	60.4 %

Tableau 5 - Benchmark complet des architectures testées sur le test 2025. Trois architectures dépassent l'objectif North Star de 60 pourcents (1 - WAPE) : LightGBM Quantile P50, XGBoost v2 et Stacking Ridge. XGBoost v2 domine sur la MAE, Stacking Ridge sur RMSE et R². Sources : reports/sprint_a_chantier1_metrics.json et reports/sprint_b_chantier1_stacking.json.

Le tableau 5 invite à une lecture comparative qui évite la tentation du modèle gagnant unique. Trois architectures répondent au cahier des charges global : LightGBM Quantile P50 offre la meilleure MAE pure (8.32) et fournit nativement des intervalles de prédiction ; XGBoost v2 propose le meilleur compromis MAE / WAPE / interprétabilité et constitue une base éprouvée

; Stacking Ridge domine sur les métriques de dispersion (RMSE 97.55, R^2 0.694) en corrigeant les grandes erreurs grâce à la complémentarité des composants. Le choix d'une architecture de production relève donc d'un arbitrage explicite entre critères opérationnels (coût d'inférence, simplicité de maintenance, disponibilité des intervalles d'incertitude) plutôt que d'un classement statistique unidimensionnel.

Confrontation IA vs DDMRP sur articles stratégiques

La comparaison directe entre les prédictions IA et la simulation DDMRP, restreinte au périmètre des 22 articles stratégiques sélectionnés par règle de Pareto, livre les résultats suivants sur le test 2025 agrégé en semaines.

Méthode	MAE hebdo	Biais hebdo	Lecture
IA seule (XGBoost v2)	260.1	-223.0	Tres precis mais sous-estime structurel
DDMRP simulée (Ptak & Smith)	660.8	-179.0	Marges de securite, MAE elevee
Hybride 50 / 50	242.0	-20.9	Meilleur compromis

Tableau 6 - Comparaison IA, DDMRP et combinaison hybride sur 22 articles stratégiques (périmètre 80 pourcents du volume). L'hybridation à parts égales minimise simultanément la MAE hebdomadaire et le biais.

Source : reports/sprint_b_chantier3_ddmrp.json.

Cette comparaison délivre un message méthodologique central : l'IA et DDMRP ne sont pas substituables mais complémentaires. L'IA fournit une prédiction précise mais structurellement sous-estimée de la demande (biais négatif élevé), tandis que DDMRP introduit des marges de sécurité opérationnelles qui évitent la rupture mais augmentent l'erreur moyenne. Une combinaison hybride à parts égales réduit simultanément la MAE hebdomadaire (242 contre 260 pour l'IA seule) et le biais structurel (-20.9 contre -223). Le taux de rupture observé sur la simulation DDMRP (11.2 pourcents) confirme par ailleurs la valeur opérationnelle de l'approche métier classique, qui ne disparaît pas avec l'arrivée de l'IA.

2.3.5 Analyse comparative et sélection du modèle de service

La sélection d'une architecture pour le service opérationnel résulte d'un arbitrage multicritère : performance brute, interprétabilité, simplicité d'industrialisation, coût de maintenance. Le mémoire ne tranche pas en faveur d'un modèle unique mais documente trois configurations recommandées selon le profil d'usage :

- XGBoost v2 (47 features) : configuration recommandée pour un service monomodèle privilégiant simplicité opérationnelle et interprétabilité. MAE 8.42, WAPE 0.383, précision agréée 61.7 pourcents. Modèle actif dans le dashboard livré.

- LightGBM Quantile P10 / P50 / P90 : configuration recommandee lorsque l'utilisateur metier exige des intervalles d'incertitude explicites (badge de confiance, marges de securite). Performances P50 comparables a XGBoost v2 et intervalles directement exploitables.
- Stacking Ridge (XGBoost v2 + LightGBM P50 + CatBoost) : configuration recommandee lorsque la metrique de dispersion (RMSE, R^2) est prioritaire et que le cout d'inference triple est acceptable. Gain de 4 points sur le RMSE et de 4 points sur le R^2 par rapport au monomodele.

Cette presentation neutre des trois configurations est defendue dans la model card publiee en annexe : elle expose au jury et aux praticiens la realite d'un projet industriel ou plusieurs architectures coexistent legitiement selon le profil d'usage, et ou la decision de service finale est documentee, datee et susceptible d'evoluer.

2.4 Présentation du dashboard Human-in-the-loop

2.4.1 Architecture technique et choix de stack

Le dashboard livre repose sur la stack Streamlit, choisie après comparaison avec les alternatives Dash (Plotly), Panel et FastAPI + React. Trois critères ont déterminé ce choix : la rapidité de développement (un planificateur teste l'interface dès la semaine 5 du projet), l'intégration native avec l'écosystème Python scientifique déjà utilisé pour la modélisation, et la possibilité d'embarquer Plotly pour les graphiques interactifs sans pont JavaScript. La contrepartie reconnue est une scalabilité limitée à quelques utilisateurs simultanés, acceptable pour un MVP interne mais qui nécessitera une migration vers une architecture découplée (FastAPI + React) pour une mise en production à l'échelle.

L'application est structurée en une page d'accueil et six pages métier accessibles via la sidebar Streamlit native : Gestion des Données, Intelligence Artificielle, Prévisions de Ventas, Analyse, Drift Detection, Backtest 2025. Les utilitaires de chargement de données, d'inférence, de calcul du score de confiance et de simulation what-if sont centralisés dans le package dashboard/utils/ pour éviter la duplication.

2.4.2 Page Gestion des Données

La page Gestion des Données assure deux fonctions : la consultation du jeu de données historique et l'import de nouveaux fichiers pour inférence. Le tableau de consultation propose un filtrage par client, par article, par période, et un export CSV des résultats filtrés. L'import accepte un fichier CSV au format Mode A (déjà encodé avec les suffixes _freq et _enc), choix de simplification explicitement documenté dans la limite opérationnelle pour le MVP - un Mode B (encodage automatique côté serveur) est positionné en perspective.




Figure 11 - Page Gestion des Données du dashboard. Le tableau filtrable consulte l'historique 2021-2025 ; le bandeau d'import en haut accepte les CSV Mode A.

2.4.3 Page Intelligence Artificielle

La page Intelligence Artificielle centralise les informations sur le modele actif et l'historique des versions. Elle expose la version active, la date de dernier entrainement, la liste des features utilisees (lue dynamiquement depuis l'attribut `feature_names_in_` du modele serialise pour eviter toute divergence avec la liste hardcodee), et un tableau historique des runs avec leurs metriques principales. Un bouton Re-entrainer le modele declenche le script `src/retrain.py` en arriere-plan et streame le log d'execution dans la page.




Figure 12 - Page Intelligence Artificielle. Le panneau central affiche les metriques du modele actif, l'historique des versions et le bouton de re-entrainement.

2.4.4 Page Previsions de Ventes et score de confiance composite

La page Previsions de Ventes constitue le coeur fonctionnel du dashboard. Elle propose au planificateur la liste des couples client-article a horizon M+1 a M+3 avec leur quantite predite, leur intervalle d'incertitude P10-P90 et un indicateur visuel de confiance (vert / orange / rouge) lisible en un coup d'oeil. La page integre un filtrage par client, par famille d'article et par segment ABC, ainsi qu'un export CSV / Excel des lignes selectionnees.

Le score de confiance affiche est calcule par une formule composite a trois facteurs documentee dans le fichier `dashboard/utills/confidence.py` : (1) familiarite du couple (article et client deja vus ensemble en entrainement, partiellement vus, ou inconnus), (2) ecart entre la prediction et la mediane historique du couple (indicateur de surprise statistique), et (3) decile de la valeur predite dans la distribution d'entrainement (les valeurs extremes sont moins fiables). Le score composite est mappe sur trois etats : vert si confiance superieure a 0.75, orange entre 0.4 et 0.75, rouge en dessous. Ce mapping est configurable depuis la page Analyse via un slider, materialisant la matrice de gouvernance HITL (detaillee section 3.4).



Figure 13 - Page Prévisions de Ventes (vue principale). Tableau central : un couple client-article par ligne, colonnes *Quantite predite*, *P10-P90*, *Confiance* (badge couleur), *Action recommandee*. Le panneau de filtres lateral autorise une selection multidimensionnelle.




Figure 14 - Page Prévisions, sous-section Prediction vs valeur réelle. Scatter plot interactif Plotly : abscisse valeur réelle, ordonnée prediction. La couleur encode le score de confiance et la diagonale grise materialise la prediction parfaite.




Figure 15 - Page Previsions, sous-section Simulation what-if. Sliders et toggles permettant au planificateur de simuler l'effet d'une variation de prix, de délai, d'IPI ou d'un passage en jour férié sur la prédiction d'une ligne sélectionnée, avec affichage de la prédiction simulée et de l'intervalle P10 - P90 associée.

2.4.5 Page Analyse - IA vs baseline et exploration des erreurs

La page Analyse centralise le travail de storytelling autour des résultats de modélisation. Elle confronte d'abord la MAE de la baseline historique à la MAE du modèle XGBoost v2 et affiche le gain relatif obtenu sur le jeu de test 2025. Elle présente ensuite le top des erreurs maximales : un tableau classe les couples client-article où l'écart entre quantité réelle et quantité prédite est le plus élevé. Cette vue est essentielle pour la lecture critique du modèle car elle matérialise les régions de l'espace où la prédiction reste fragile et oriente les améliorations futures.

Une lecture explicite accompagne le tableau : les erreurs maximales correspondent généralement à des commandes de gros volume sur des articles ou des clients peu représentés dans le set d'entraînement, ce qui justifie l'usage du badge de confiance (orange ou rouge) pour signaler ces situations au planificateur avant validation.



Figure 16 - Page Analyse. Le tableau central liste le top des erreurs absolues du modèle XGBoost v2 sur le test 2025 ; la lecture en bas de page guide l'interprétation et le rattachement au score de confiance. Le bandeau inférieur expose la comparaison IA vs DDMRP et la décomposition par architectures avancées.

2.4.6 Page Drift Detection - monitoring de la stabilité des features

La page Drift Detection implémente un monitoring de la Population Stability Index (PSI) sur les six features les plus contributrices du modèle XGBoost v2, identifiées par importance de permutation : `qte_roll_mean_7`, `qte_roll_mean_30_article`, `qte_roll_mean_30`, `qte_roll_mean_30_client`, `prix` et `ipi_valeur`. La distribution de référence est calculée sur le set d'entraînement (2021-2023) et confrontée soit au test 2025 par défaut, soit à une distribution courante uploadée par l'utilisateur (CSV ou Parquet).

Pour chaque feature surveillée, l'application calcule le PSI selon la formule standard $\sum (p_{cur} - p_{ref}) * \log(p_{cur} / p_{ref})$ sur dix bins définis par quantiles de la distribution de référence. Une classification à trois niveaux est appliquée : stable (PSI inférieur à 0.10), drift modéré (PSI entre 0.10 et 0.25), drift significatif (PSI supérieur à 0.25). Un bandeau d'alerte synthétise le verdict global et conseille un re-entraînement lorsqu'au moins une feature critique passe en zone rouge. Cette mécanique est conforme aux pratiques de monitoring credit risk industriel (Karakoulas, 2011) et constitue le socle d'une mise en production responsable.




Figure 17 - Page Drift Detection. Panneau gauche : tableau PSI par feature avec code couleur (vert / orange / rouge) ; panneau droit : histogramme des PSI pour lecture visuelle rapide. Le bandeau supérieur synthétise le verdict de stabilité du modèle.

2.4.7 Page Backtest interactif - retroprojection 2025

La page Backtest 2025 propose au planificateur de retroprojeter l'usage du modèle sur l'année 2025 à l'aide d'un slider hebdomadaire ISO. Pour chaque semaine d'arrêt sélectionnée, l'application affiche la quantité réelle cumulée, la quantité prédite cumulée par chacun des modèles sélectionnés (XGBoost v2, LightGBM Quantile P50, CatBoost, Stacking Ridge, baseline historique), ainsi que des métriques rolling sur les quatre dernières semaines.

Au-delà des métriques statistiques (MAE et WAPE par fenêtre), la page expose une fonction de coût business paramétrable par l'utilisateur : $\text{coût} = \alpha * \text{ruptures} + \beta * \text{sur-stock}$, où α et β sont fixés par sliders en euros par unité. Cette fonction permet une lecture économique directe du comportement des modèles dans des contextes où la rupture coûte plus cher que le surstock (α grand), ou inversement (β grand). Le tableau des dix erreurs absolues maximales sur la semaine d'arrêt complète la lecture par une vue qualitative des cas extrêmes.




Figure 18 - Page Backtest interactif. Graphique central : cumul de la quantité réelle et des prédictions cumulées des modèles sélectionnés en abscisse semaine ISO. Panneaux secondaires : métriques rolling 4 semaines, fonction de coût business paramétrable, tableau des dix plus grandes erreurs.

2.4.8 Page d'accueil - synthèse executive et navigation

La page d'accueil du dashboard joue le rôle de tableau de bord exécutif. Elle expose en bandeau supérieur les indicateurs clés du modèle actif (MAE, R^2 , WAPE, taille du dataset), rappelle la problématique en quelques lignes et restitue visuellement le pipeline complet du projet (Data Engineering, Études statistiques, Modélisation IA, Dashboard). Le panneau de navigation à droite oriente l'utilisateur vers les quatre pages métier en fonction du besoin du moment : exploration des données, monitoring du modèle, prévisions à horizon M+1/M+3, analyse comparative.

Au-delà de la fonction navigation, cette page d'accueil constitue le premier contact visuel pour un décideur non technique. Elle permet de mesurer instantanément la valeur ajoutée du modèle par rapport à la baseline historique (badge -9.0 % vs baseline) sans avoir à entrer dans les détails statistiques de chaque page.



Figure 19 - Page d'accueil du dashboard. KPIs du modele actif en bandeau, rappel de la problematique au centre, schema du pipeline et navigation rapide vers les six pages metier.

Synthese PSI mesuree sur le test 2025

Les valeurs de PSI mesurees sur le test 2025 par la page Drift Detection fournissent une calibration empirique des seuils. Le tableau ci-dessous restitue les PSI obtenus sur les six features critiques entre la reference train (2021-2023) et la distribution test (2025).

Feature surveillee	PSI test 2025	Statut
prix	0.07	Stable
qte_roll_mean_7	0.11	Drift modere
ipi_valeur	0.19	Drift modere
qte_roll_mean_30_article	0.18	Drift modere
qte_roll_mean_30_client	0.09	Stable
qte_roll_mean_30	0.14	Drift modere

Tableau 7 - PSI mesures sur les six features les plus contributrices entre train et test 2025. Aucune feature ne franchit le seuil rouge (0.25), ce qui justifie le maintien du modele en service sans declencher de re-entrainement immediat.

PARTIE 3

Analyse Critique

3.1 Comparaison IA versus intuition commerciale

3.1.1 Methodologie de comparaison

La comparaison entre la prediction IA et le pilotage par objectifs commerciaux ne peut s'appuyer, dans le perimetre du present memoire, que sur des donnees objectives disponibles dans le dataset. Faute d'acces aux objectifs commerciaux negocies par GE, l'evaluation prend pour reference la baseline historique (moyenne par couple client-article calculee sur 2021-2023), qui constitue un proxy mesurable de ce que produirait une planification non assistee par IA au-dela d'une simple moyenne glissante. Cette baseline est volontairement exigeante : un modele qui ne la depasse pas significativement n'apporterait aucune valeur ajoutee scientifique.

3.1.2 Gains mesures par rapport a la baseline

Sur le perimetre du test 2025 (66 174 lignes), le gain absolu du modele XGBoost v2 par rapport a la baseline historique est de 4.62 unites en MAE (8.42 contre 13.04), soit un gain relatif de 35.4 pourcents. En precision agregee ($1 - \text{WAPE}$), le modele atteint 61.7 pourcents contre 38.0 pourcents pour la baseline, soit un gain absolu de 23.7 points et un depassement de 1.7 point de l'objectif North Star declare (60 pourcents). Le modele Stacking Ridge, qui ameliore le RMSE de 4 points (97.55 contre 101.83) et le R^2 de 4 points (0.694 contre 0.666), constitue une alternative interessante lorsque la metrique de dispersion est prioritaire.

Le test de Diebold-Mariano applique sur les residus du modele XGBoost v2 versus la baseline historique donne une p-value tres significativement inferieure a 0.01, ce qui permet d'affirmer statistiquement la superiorite du modele sur l'ensemble du test. Cette validation statistique est essentielle pour anticiper la question - frequemment posee en soutenance - de la significativite du gain observe.

3.1.3 Cadre d'estimation business

La traduction du gain statistique en valeur economique necessite la connaissance de deux parametres metier : alpha, le cout unitaire d'une rupture, et beta, le cout unitaire d'un surstock (par mois immobilise). Ces parametres ne sont pas fournis dans le brief de mission et ne peuvent donc pas etre fixes ici sans approximation arbitraire. La page Backtest 2025 du dashboard permet a l'utilisateur metier de saisir lui-meme ces deux parametres et d'observer le cout cumule des differents modeles sur l'annee 2025 sous l'hypothese choisie. Cette demarche evite de propager une estimation chiffree non sourcee dans le memoire tout en laissant a GE la possibilite de quantifier le gain sur ses propres barèmes.

3.2 Limites du modele

3.2.1 Imprevus geopolitiques et ruptures de regime

La premiere limite structurelle de toute approche basee sur l'apprentissage statistique est sa difficulte intrinseque a anticiper les ruptures de regime. La periode d'entrainement 2021-2023 comprend deux contextes economiquement atypiques : la phase post-Covid (chaines d'approvisionnement perturbees, prix volatiles) et la phase consecutive a la guerre en Ukraine declenchee en fevrier 2022 (envolee des prix de l'energie, tensions sur les composants). Le modele a donc appris des correlations potentiellement biaisees par ces contextes ; un changement de regime aussi violent que ces deux precedents pendant la periode d'inference invaliderait localement les predictions. Aucune technique d'apprentissage statistique ne corrige integralement ce defaut ; la detection de derive PSI integree au dashboard est un palliatif partiel qui declenche une alerte sans pour autant fournir un nouveau modele adapte.

3.2.2 Donnees manquantes et perimetres non couverts

Plusieurs sources d'information potentiellement utiles n'ont pas pu etre integrees, soit par indisponibilite, soit par contrainte de temps. Les donnees promotionnelles (remises tarifaires accordees ponctuellement) ne sont pas tracees dans l'export ERP exploite ; or, une remise significative declenche typiquement un effet d'anticipation de commande qui n'est pas capte par le modele. Les operations de transfert inter-sites sont egalement absentes : un transfert de stock entre deux centres de distribution pour repondre a une rupture locale n'apparait pas comme une commande dans le perimetre etudie. Enfin, les retours clients - faibles en volume mais structurellement biaises vers certaines familles d'article - ne sont pas integres.

3.2.3 Biais identifies

Trois categories de biais structurels du jeu de donnees ont ete identifiees comme points de vigilance pour une exploitation industrielle. Les ordres de grandeur associes restent qualitatifs : leur quantification precise depasse le perimetre du present memoire mais est facilement instrumentable en relancant les notebooks d'EDA et de modelisation sur les colonnes concernees.

- Biais de frequence client : les comptes a faible activite (peu de commandes par an) representent une part importante du nombre de clients mais une part marginale du volume. Le modele leur attribue mecaniquement une erreur plus elevee, ce qui implique un risque de rupture silencieuse sur cette population si la prediction est utilisee sans badge de confiance.

- Biais d'article : la longue traine du catalogue (articles a faible volume) presente une demande intermittente structurellement difficile a predire par un modele de regression continue. Une exploitation industrielle exigerait une approche specialisee de type Croston / TSB / ADIDA pour ce segment.
- Biais temporel : la presence de regimes economiquement atypiques dans l'entrainement (post-Covid, choc energetique 2022) peut conduire a sur-ponderer ces regimes lors d'une inference dans un contexte revenu a la normale.

3.2.4 Echec relatif du LSTM time-to-event et honnetete metrique

La precision +/-7 jours de 25.5 pourcents obtenue par l'architecture LSTM time-to-event est tres inferieure a la cible operationnelle (50 pourcents). Cet ecart constitue le point faible le plus visible du memoire et ne saurait etre dissimule. L'analyse honnete des causes (longueur de sequence insuffisante, absence d'autoregression sur le delai, absence de scaling, formulation potentiellement inadaptée) a deja ete exposee section 2.3.3. Plutot que de retirer cette architecture du livrable, elle est explicitement signalee dans le dashboard par un badge rouge par default sur toute prediction de date : la transparence sur la fiabilite limitee de ce modele est ici un engagement methodologique, qui prepare la reformulation par analyse de survie annoncee en perspectives.

3.2.5 Atteinte du North Star sur la quantite, echec sur la date

La cible North Star declaree en debut de projet, 60 pourcents de precision agreee (1 - WAPE), est atteinte sur la quantite : le modele XGBoost v2 livre une precision de 61.7 pourcents sur le test 2025, soit un depassement de 1.7 point. La configuration Stacking Ridge atteint 60.4 pourcents avec une amelioration significative de la metrique de dispersion (R^2 0.694 contre 0.666 pour XGBoost v2). Trois architectures distinctes franchissent ainsi le seuil cible (XGBoost v2 a 61.7 pourcents, LightGBM Quantile P50 a 62.1 pourcents, Stacking Ridge a 60.4 pourcents), ce qui constitue un acquis robuste et reproductible.

L'objectif n'est en revanche pas atteint sur la prediction de date par LSTM, qui plafonne a 25.5 pourcents +/-7 jours (cible operationnelle : 50 pourcents). Cette dissymetrie des resultats - reussite sur la quantite, echec relatif sur la date - structure la lecture critique du memoire : le livrable opere une transformation demonstrable sur le pilotage des volumes mais ne resout pas la question du timing exact des commandes, qui devra etre repris via une reformulation par analyse de survie (perspectives en section 3.5).

3.3 Conforme RGPD et éthique du traitement

Le présent mémoire mobilisant des données d'entreprise contenant indirectement des informations relatives à des personnes physiques (interlocuteurs commerciaux, demandeurs ERP, planificateurs identifiés dans certains champs metadata), une analyse de conformité au Règlement Général sur la Protection des Données (RGPD, règlement UE 2016/679, applicable depuis le 25 mai 2018) est impérative. Cette section documente cette analyse et identifie les mesures techniques et organisationnelles mises en œuvre.

3.3.1 Données personnelles potentiellement concernées

Au sens de l'article 4 du RGPD, constitue une donnée personnelle toute information se rapportant à une personne physique identifiée ou identifiable. L'examen des colonnes présentes dans le dataset effectivement utilisé (data/processed/dataset_ml_enrichi.parquet) permet d'identifier le statut des champs vis-à-vis du RGPD :

- Identifiants entreprise (codes opaques) : `code_client` et `code_article` sont des identifiants numériques internes à GE. Ils ne désignent pas directement une personne physique mais peuvent y conduire en présence d'une table de correspondance interne. Dans le pipeline d'apprentissage, ces champs sont remplacés par leur frequency encoding (`code_client_freq`, `code_article_freq`), ce qui rompt le lien direct.
- Variables descriptives clients : `famille_activite_client`, `type_activite`, `pays`, `segment`. Ces champs décrivent l'activité commerciale et le pays du client, qui peut être une personne morale ou physique. Lorsqu'un client est une personne physique (entrepreneur individuel par exemple), ces variables constituent indirectement des données personnelles.
- Variables transactionnelles : `qte_demandee`, `qte_livree`, `prix`, `dates`. Données commerciales standard non personnelles en elles-mêmes.

Le dataset utilisé pour l'entraînement ne contient en revanche aucun champ directement nominatif (nom, prénom, contact, identifiant opérateur ERP). Aucune donnée sensible au sens de l'article 9 du RGPD (santé, opinion politique, syndicale, religieuse, biométrique, sexuelle) n'est traitée dans le périmètre du projet.

3.3.2 Bases légales du traitement

Le traitement réalisé dans le cadre du présent mémoire mobilise deux bases légales principales selon l'article 6 du RGPD :

- Article 6.1.b (exécution d'un contrat) : le traitement des données client nécessaires à l'exécution des commandes (raison sociale, adresse de livraison, code interlocuteur) est légitime par l'exécution du contrat commercial entre GE et ses clients.

- Article 6.1.f (intérêt légitime) : le traitement statistique anonymise des historiques de commande aux fins d'amélioration de la prévision de demande est légitime par l'intérêt légitime de GE à optimiser sa chaîne d'approvisionnement, sous réserve que les droits et libertés des personnes concernées ne prévalent pas. Une analyse d'impact (AIPD / DPIA) formelle complémentaire est recommandée avant tout déploiement en production étendu.

3.3.3 Mesures techniques et organisationnelles mises en œuvre

Trois mesures techniques et organisationnelles ont été adoptées au cours du projet pour minimiser la sensibilité des données manipulées :

- Pseudonymisation des identifiants : les champs `code_client` et `code_article` sont remplacés par leur frequency encoding (`code_client_freq`, `code_article_freq`) lors de la préparation (notebook 02bis_eda_dataset_enrichi.ipynb), ce qui rompt le lien direct entre une transaction et un identifiant commercial dans les modèles serialisés.
- Minimisation : le dataset utilisé pour l'apprentissage ne contient aucun champ nominatif (nom, prénom, contact, identifiant opérateur), conformément au périmètre défini en 1.1.2 et à l'inspection des colonnes effectivement chargées.
- Maîtrise de la diffusion : aucune des données brutes ou enrichies n'est publiée dans le dépôt Git du projet (les fichiers Parquet sont exclus par `.gitignore`) ; seuls les rapports agrégés et les modèles serialisés sont versionnés.

3.3.4 Droits des personnes concernées

Les droits prévus aux articles 15 à 22 du RGPD sont applicables aux données opérateurs ERP traitées dans le projet, même si leur volume est limité et leur exploitation indirecte. Le tableau ci-dessous synthétise le statut de ces droits dans le périmètre du projet.

Droit	Reference	Modalité d'exercice
Accès	Art. 15	Sur demande au DPO GE
Rectification	Art. 16	Mise à jour ERP source
Effacement	Art. 17	Anonymisation totale dans le dataset
Limitation	Art. 18	Suspension de l'inclusion dans le pipeline
Portabilité	Art. 20	Export structure sur demande
Opposition	Art. 21	Exclusion sur demande motivée
Décision automatisée	Art. 22	Non applicable - décision finale humaine

Tableau 9 - Droits RGPD et modalités d'exercice dans le périmètre du projet.

Le point essentiel a souligner est l'article 22 : le RGPD interdit en principe les decisions produisant des effets juridiques ou affectant significativement une personne, prises sur la seule base d'un traitement automatise. Dans le cas present, la decision de reapprovisionnement finale reste imperativement humaine (le planificateur valide la commande generee), ce qui place le systeme hors du perimetre des decisions purement automatisees. Cette caracteristique est centrale dans l'architecture Human-in-the-loop defendue en section 3.4.

3.3.5 Duree de conservation et registre des traitements

La duree de conservation des donnees brutes 2021-2025 reste celle definie par les politiques internes de GE - non documentees dans le perimetre du present memoire - et par les obligations legales applicables aux donnees commerciales (article L.123-22 du Code de commerce). Les artefacts produits dans le cadre du projet (jeux de donnees enrichis, modeles serialises) sont conserves pour la duree du memoire et feront l'objet d'une revue post-soutenance pour decider de leur sort. Le traitement specifique realise dans le cadre du projet doit etre inscrit, le cas echeant, dans le registre des activites de traitement de GE, sous une categorie d'analyse statistique interne, avec mention explicite du perimetre temporel (2021-2025) et de la finalite (prevision de la demande client).

3.3.6 Positionnement vis-a-vis de l'AI Act europeen

Au-dela du RGPD, le reglement europeen sur l'intelligence artificielle (AI Act, adopte en 2024, applicable de maniere echelonnee a partir de 2025) introduit une classification des systemes d'IA par niveau de risque. Le systeme decrit dans ce memoire releve de la categorie risque limite : il ne participe pas a une decision affectant directement une personne physique au sens de l'AI Act (recrutement, credit, education, infrastructures critiques), et son usage est interne a l'organisation. Les obligations applicables a cette categorie - transparence sur l'usage d'un systeme IA, documentation technique, supervision humaine - sont explicitement couvertes par la model card publiee en annexe, le present memoire et la matrice de gouvernance HITL exposee section 3.4. Une evolution du systeme vers une automatisation totale du reapprovisionnement le ferait basculer en categorie risque eleve, ce qui necessiterait des obligations renforcees (audit independant, conformite ex ante) explicitement evoques dans les perspectives de mise en production.

3.4 Importance de la validation humaine (Human-in-the-loop)

3.4.1 Principe et formalisation

Le principe Human-in-the-loop (HITL) constitue la clef de voute de la philosophie opérationnelle du système. Plutôt que d'opposer intelligence artificielle et expertise humaine, il s'agit de les articuler : le modèle fournit une recommandation transparente assortie d'un score de confiance, le planificateur arbitre en fonction de ce score, du contexte connu de lui seul (relations commerciales, événements anticipés) et de sa propre estimation. La validation humaine demeure le dernier maillon de la chaîne de décision, conformément aux exigences de l'article 22 du RGPD et de l'AI Act européen pour les systèmes de risque limité.

3.4.2 Matrice de gouvernance à trois niveaux

La matrice de gouvernance retenue, configurable via la page Analyse du dashboard, articule trois niveaux de décision en fonction du score de confiance composite calculé pour chaque prédiction.

Niveau	Critère (score)	Action recommandée
Vert	score > 0.75	Automatisation totale - commande validée sans revue
Orange	$0.40 < \text{score} < 0.75$	Revue rapide - validation 1 clic par le planificateur
Rouge	score < 0.40	Décision humaine obligatoire et saisie d'une justification

Tableau 8 - Matrice de gouvernance Human-in-the-loop. Les seuils 0.40 et 0.75 sont configurables depuis la page Analyse du dashboard ; la répartition effective entre les trois niveaux se calcule dynamiquement sur le périmètre courant et n'est pas figée dans ce document.

3.4.3 Boucle d'amélioration continue

Au-delà de la simple validation, le HITL ouvre une boucle d'amélioration continue : chaque correction opérée par un planificateur sur une prédiction (acceptation, modification, refus avec justification libre) est tracée et constitue un signal supplémentaire d'apprentissage potentiel. Une itération ultérieure du système pourrait intégrer cette boucle de feedback dans un schéma d'apprentissage actif (active learning) ou de fine-tuning périodique. Cette piste est documentée dans les perspectives de la section 3.5 et constituerait un gain majeur d'adoption et de robustesse en production.

3.5 Perspectives d'amelioration et de mise en production

3.5.1 Ameliorations methodologiques a court terme

Trois ameliorations methodologiques ont ete identifiees comme prioritaires pour une iteration ulterieure du projet. Premiere priorite : la reformulation de la prediction de date par analyse de survie (modeles Cox proportional hazards via lifelines, Random Survival Forests via scikit-survival, ou DeepSurv via pycox), qui devrait permettre de depasser largement la precision actuelle de 25.5 pourcents +/-7 jours en exploitant correctement la nature time-to-event du probleme. Deuxieme priorite : un traitement dedie de la longue traine via les methodes Croston, TSB et ADIDA specialisees dans la demande intermittente, susceptible de reduire significativement la MAE residuelle sur la longue traine d'articles a faible volume. Troisieme priorite : l'integration des features exogenes laggees (ipi_valeur_lag1, ipi_valeur_lag3, temperature_lag2), motivee par les resultats du test de Granger (tableau 2) et restee non implementee pour des raisons d'agenda.

3.5.2 Architecture cible de mise en production

L'architecture cible de mise en production decrite ci-dessous demeure un livrable conceptuel du present memoire et n'a pas ete deployee dans le perimetre du Master ; elle constitue la principale perspective industrielle du projet et formalise les briques attendues pour un usage operationnel a l'echelle.

- API d'inference : FastAPI avec validation de schemas par Pydantic, deployee derriere un reverse proxy Nginx. Endpoints /predict, /explain (SHAP par ligne), /health, /metrics.
- Base de donnees relationnelle : PostgreSQL avec schemas dedies pour les predictions historiques, les feedbacks planificateur (boucle HITL) et les snapshots de modeles. SQLAlchemy comme couche ORM.
- Versioning modele : MLflow Model Registry avec stages Staging et Production, permettant un retour arriere instantane en cas de regression detectee.
- Versioning donnees : DVC avec remote S3 ou MinIO interne, pour reproduire toute experience anterieure a partir de son commit Git.
- Monitoring drift : Evidently AI avec rapport HTML genere automatiquement chaque semaine, integre au dashboard via iframe.
- Orchestration retrain : Prefect ou Airflow avec un DAG hebdomadaire de re-entrainement, declenche soit par planification, soit par alerte de drift PSI superieure a 0.25 sur une feature critique.
- Containerisation : Docker + docker-compose avec services app, db, mlflow, worker, monitoring.

- Observabilite : logs structures via loguru ou structlog, exporter Prometheus, dashboards Grafana, alerting Sentry sur erreurs applicatives.

3.5.3 Roadmap operationnelle a six mois

Sur la base de cette architecture cible, une roadmap operationnelle a six mois est proposee : mois 1 - dockerisation du dashboard actuel et exposition d'une API interne FastAPI minimaliste. Mois 2 - migration de l'inference vers FastAPI, ajout de PostgreSQL pour l'historisation. Mois 3 - integration MLflow Model Registry. Mois 4 - integration DVC pour le versioning data. Mois 5 - boucle de feedback planificateur (apprentissage actif sur corrections). Mois 6 - mise en place du monitoring de drift automatise (Evidently) et activation du retrain planifie. Cette roadmap reste indicative et necessitera un arbitrage budgetaire dedie de la direction supply chain de GE.

3.5.4 Convergence avec DDMRP en production

Une perspective specifique merite d'etre soulignee : l'articulation operationnelle entre le modele predictif et la grille DDMRP. La comparaison conduite en section 2.3.4 a montre que l'IA et DDMRP ne sont pas substituables mais complementaires. Une implementation cible coherente consisterait a utiliser la prediction IA comme entree du calcul du Net Flow Position de DDMRP, et a maintenir les buffers vert / jaune / rouge comme indicateurs visuels lisibles par les planificateurs. Cette hybridation IA + DDMRP constituerait une contribution methodologique reutilisable au-dela du seul perimetre GE et meriterait une formalisation academique distincte.

3.6 Conclusion generale

Ce memoire a entrepris de demontrer qu'une approche Demand-Driven appuyee sur l'intelligence artificielle peut produire une prediction operationnelle exploitable de la demande client - en quantite et en date - pour soutenir un planificateur supply chain dans son arbitrage quotidien, sans le remplacer. Au terme du parcours methodologique qui a structure les trois parties du document, plusieurs apports complementaires meritent d'etre recapitules pour formaliser le bilan du travail.

3.6.1 Apports methodologiques

Le premier apport est la mise en place d'un pipeline complet et reproductible : audit, nettoyage, enrichissement, etudes statistiques, modelisation, dashboard, evaluation. Une dizaine de notebooks principaux et un dossier models/ serialise documentent ce pipeline et garantissent sa reproductibilite par tout lecteur disposant des donnees sources. Le second apport est l'integration d'une demarche d'evaluation honnete : definition explicite d'une baseline historique exigeante, test statistique de Diebold-Mariano pour valider la superiorite du modele, monitoring de derive par Population Stability Index sur les features critiques, et confrontation systematique a une baseline DDMRP de reference academique. Le troisieme apport est l'articulation entre IA pure et DDMRP, qui rompt avec la dichotomie habituelle entre methodes traditionnelles et methodes machine learning pour proposer une hybridation operationnelle defendable devant un jury comme devant un comite operationnel.

3.6.2 Apports professionnels pour GE

Les livrables remis a GE comprennent : un dataset propre et enrichi de 349 390 lignes (utilisable pour d'autres analyses ulterieures), cinq modeles serialises avec leur historique d'hyperparametres et leurs metriques mesurees (directement re-entrainables via le script src/retrain.py), un dashboard Streamlit multipage operationnel sur un poste planificateur standard, un document model card conforme aux standards en vigueur (Google, Hugging Face), une matrice de gouvernance HITL directement integree au dashboard et un document de feuille de route a six mois pour la mise en production. Cet ensemble constitue un MVP complet, immediatement testable en interne, et structure pour preparer un deployment plus ambitieux.

3.6.3 Apports academiques et personnels

Sur le plan academique, le memoire propose une demonstration pas-a-pas qu'un projet machine learning industriel peut etre honnete sur ses reussites comme sur ses limites. La precision agregee de 61.7 pourcents obtenue sur la quantite par XGBoost v2 depasse l'objectif North Star de 60 pourcents et constitue un acquis robuste, tandis que la prediction de date par LSTM (25.5 pourcents +/-7 jours) reste un echec relatif assume et documente. Cette dualite assumee - reussite quantite, echec date - est paradoxalement l'un des principaux apports methodologiques du document, dans un contexte ou la litterature applicative tend a sur-promettre les performances obtenues. Sur le plan personnel, ce travail a permis de cumuler une experience concrete sur l'ensemble de la chaine data science (de l'ingenierie au deploiement), d'approfondir la litterature DDMRP a l'interface entre supply chain academique et machine learning applique, et de prendre la mesure des compromis necessaires entre performance brute, interpretabilite et gouvernance humaine.

3.6.4 Limites du travail et ouverture

Les limites du travail ont ete listees au fil du document et ne seront pas reprises exhaustivement ici. Quatre points appellent neanmoins une mention finale. Premierement, le perimetre temporel d'entrainement (2021-2023) contient deux regimes atypiques (Covid puis crise energetique 2022) dont l'effet residuel sur le modele ne sera entierement quantifiable qu'a posteriori, apres plusieurs annees de regime normalise. Deuxiemement, l'absence de donnees promotionnelles dans le jeu source constitue une limite informationnelle structurelle, dont la levee passerait par une evolution du systeme ERP source. Troisiemement, le perimetre purement quantitatif du projet n'integre pas la dimension qualitative des relations commerciales (verbatim client, signaux faibles d'evolution de strategie), dimension qui constitue pourtant une part importante de l'expertise reelle d'un planificateur. Quatriemement, le deploiement en production reste un livrable conceptuel ; la traduction operationnelle complete du systeme passera par les six mois de roadmap detailles section 3.5.3, qui ne relevent plus du Master mais d'un projet professionnel ulterieur.

Au-dela de ces limites, et de l'humilite que doit conserver tout praticien d'un domaine ou les modeles vieillissent plus vite que les pratiques metier, le projet demontre qu'une approche scientifique rigoureuse peut etre conjuguee a une exigence operationnelle sans renoncer a la honnetete intellectuelle qui doit caracteriser un travail academique. La trajectoire ainsi tracee - de la donnee brute a la recommandation explicable, du score statistique a la matrice de gouvernance, du tableau de metriques au dashboard interactif - vaut, espere-t-on, comme contribution modeste mais reproductible au champ encore jeune de l'IA appliquee a la chaine d'approvisionnement industrielle.

Bibliographie

Bai, S., Kolter, J. Z., & Koltun, V. (2018). An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling. arXiv:1803.01271.

Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 785-794.

Croston, J. D. (1972). Forecasting and stock control for intermittent demands. Operational Research Quarterly, 23(3), 289-303.

Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. Neural Computation, 9(8), 1735-1780.

Hyndman, R. J., & Athanasopoulos, G. (2018). Forecasting: Principles and Practice (2nd ed.). OTexts.

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. Advances in Neural Information Processing Systems, 30.

Koenker, R., & Bassett, G. (1978). Regression Quantiles. Econometrica, 46(1), 33-50.

Lim, B., Arik, S. O., Loeff, N., & Pfister, T. (2021). Temporal Fusion Transformers for interpretable multi-horizon time series forecasting. International Journal of Forecasting, 37(4), 1748-1764.

Lundberg, S. M., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. Advances in Neural Information Processing Systems, 30.

Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2022). The M5 competition: Background, organization, and implementation. International Journal of Forecasting, 38(4), 1325-1336.

Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B., Spitzer, E., Raji, I. D., & Gebru, T. (2019). Model Cards for Model Reporting. Proceedings of the Conference on Fairness, Accountability, and Transparency, 220-229.

Parlement européen et Conseil de l'Union européenne (2016). Règlement (UE) 2016/679 du 27 avril 2016 relatif à la protection des personnes physiques à l'égard du traitement des données à caractère personnel (RGPD).

Parlement européen et Conseil de l'Union européenne (2024). Règlement établissant des règles harmonisées concernant l'intelligence artificielle (AI Act).

Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: unbiased boosting with categorical features. *Advances in Neural Information Processing Systems*, 31.

Ptak, C., & Smith, C. (2016). *Demand Driven Material Requirements Planning (DDMRP)*. Industrial Press.

Wu, X., Xiao, L., Sun, Y., Zhang, J., Ma, T., & He, L. (2022). A survey of human-in-the-loop for machine learning. *Future Generation Computer Systems*, 135, 364-381.

Zhou, H., Zhang, S., Peng, J., Zhang, S., Li, J., Xiong, H., & Zhang, W. (2021). Informer: Beyond Efficient Transformer for Long Sequence Time-Series Forecasting. *Proceedings of the AAAI Conference on Artificial Intelligence*, 35(12), 11106-11115.

Annexes

Annexe A - Liste des notebooks et livrables

- notebooks/01_data_cleaning.ipynb - Pipeline de nettoyage des donnees brutes
- notebooks/02_statistical_study.ipynb - Etudes statistiques et enrichissement exogene
- notebooks/02bis_eda_dataset_enrichi.ipynb - EDA pre-modelisation
- notebooks/03_model_training.ipynb - Entrainement de la premiere generation de modeles (XGBoost, LightGBM, LSTM)
- notebooks/04_feature_engineering_lags.ipynb - Enrichissement autoregressif (lags, rolling, target encoding) et XGBoost v2
- notebooks/09_baseline_ddmrp.ipynb - Baseline DDMRP
- notebooks/10_catboost_stacking.ipynb - CatBoost v2 et Stacking Ridge
- notebooks/11_backtest_2025_precompute.ipynb - Precomputation du backtest hebdomadaire
- dashboard/app.py + dashboard/pages/*.py - Dashboard Streamlit
- src/retrain.py - Script de re-entrainement
- reports/rapport_phase1_data_engineering.pdf, reports/rapport_phase2.md
- reports/rapport_modelisation.json, reports/sprint_a_chantier1_metrics.json, reports/sprint_b_chantier1_stacking.json, reports/sprint_b_chantier3_ddmrp.json
- docs/MODEL_CARD.md - Model card complete

Annexe B - Extrait Model Card (synthese)

Identification : XGBoost v2 - models/xgboost_optuna_v2.pkl (configuration de service principale). Architecture alternative : Stacking Ridge - models/stacking_ridge.pkl. Auteur : redacteur du memoire - date : mai 2026.

Usage prevu : prediction de la quantite demandee par couple client-article-mois, horizon M+1 a M+3, en appui d'un planificateur supply chain.

Usage non recommande : articles jamais vus en entrainement (couples totalement inconnus), ruptures de regime geopolitique brutales, premieres commandes de nouveaux clients.

Donnees d'entrainement : 210 641 lignes, perimetre 2021-2023, 47 features (28 statiques + 19 autoregressives).

Metriques globales (test 2025) : MAE 8.42, RMSE 101.83, R^2 0.666, WAPE 0.383, precision agreee 61.7 pourcents. Configuration Stacking Ridge alternative : MAE 8.70,

RMSE 97.55, R^2 0.694. Voir tableau 5.

Limites identifiées : precision LSTM date faible (a remplacer par survival analysis), longue traine sous-performante (a traiter par Croston / TSB).

Biais ethiques : sous-performance sur les petits clients et les articles rares (cf. section 3.2.3).

Date de prochaine revue : decembre 2026, ou plus tot si une alerte de drift PSI superieure a 0.25 est levee sur une feature critique.

Responsable : a designer parmi les planificateurs senior et la direction supply chain GE.