

Systeme de Pr vision des Livraisons Client

Phase 1 - Data Engineering

Rapport technique d taill  - P riode 2021-2025

Auteur	Ada Makchi
Formation	Master - Supply Chain & Intelligence Artificielle
Entreprise	GE - Groupe industriel
P�riode	2021 - 2025
Date du rapport	Avril 2026
Statut	Phase 1 termin�e - Phase 2 en pr�paration

R sultat de la Phase 1

  partir de deux fichiers CSV bruts (352 549 commandes / 353 325 livraisons), le pipeline produit dataset_ml_final.parquet : 349 390 lignes x 24 colonnes (23 features + 1 variable cible binaire en_retard). Taux de retard : 19,2 %.

Table des matières

1.	Contexte et problématique	3
2.	Sources de données	3
3.	Architecture du pipeline	4
4.	Étape 1 - Chargement et renommage	5
5.	Étape 2 - Valeurs manquantes	6
6.	Étape 3 - Normalisation des dates	8
7.	Étape 4 - Jointure commandes x livraisons	9
8.	Étape 5 - Feature engineering temporel	11
9.	Étape 6 - Encodage des catégorielles	13
10.	Étape 7 - Dataset ML final	14
11.	Décisions techniques	16
12.	Bilan et prochaines étapes	17

1. Contexte et probl matique

L'entreprise GE op re dans le secteur industriel et traite chaque ann e plusieurs dizaines de milliers de commandes client impliquant des articles vari s ( levage, construction, outillage...). La gestion de la cha ne d'approvisionnement repose aujourd'hui sur des objectifs de chiffre d'affaires, sans m canisme pr dictif pour anticiper les retards de livraison.

Ce projet de m moire vise   construire un syst me de pr diction bas  sur l'Intelligence Artificielle, r pondant   la probl matique suivante :

Comment une approche IA peut-elle pr dire si une livraison sera en retard, afin d'optimiser la cha ne d'approvisionnement ?

La Phase 1 - objet du pr sent rapport - constitue le socle de donn es de ce projet. Elle transforme les extractions brutes du syst me ERP en un dataset structur , propre, et exploitable directement par les algorithmes de Machine Learning.

Objectif de performance

L'objectif quantitatif fix  pour la Phase 2 est :

- Pr cision de pr diction > 60 % (F1-score sur la classe 'retard')

2. Sources de donn es

Deux fichiers CSV sont fournis par le syst me ERP de GE, couvrant la p riode septembre 2020 - d cembre 2025.

Fichier	Lignes	Colonnes	Description
Extraction commande client 2021-2025.csv	352 549	14	Commandes pass�es par les clients
Extraction livraison client 2021-2025.csv	353 325	13	Livraisons effectives correspondantes

Colonnes brutes - Commandes (CMD)

Colonne brute	Renomm�e en	Type	R�le
#	row_id	int	Identifiant de ligne (ignor�)
Num commande	num_commande	int	Identifiant de commande
Num�ro d'article	code_article	str	Code article command�
Quantit�	qte_demandee	int	Quantit� demand�e
Date d'enregistrement	date_enregistrement	str->date	Date de saisie commande
Date de livraison demand�e	date_livraison_demandee	str->date	Livraison souhait�e
Code client/fournisseur	code_client	str	Identifiant client
Activit� strat�gique client	famille_activite_client	str	Secteur d'activit� client
Activit� strat�gique article	famille_activite_article	str	Famille article
S�gment strat�gique	segment	str	Segment commercial (S accentu�)
Type activit�	type_activite	str	Type de produit


Pays/région	pays	str	Pays du client
Prix de vente	prix	float	Prix unitaire
Devise du prix	devise	str	Devise (EUR, USD, CNY)

Colonnes brutes - Livraisons (LIV)

Colonne brute	Renommée en	Type	Rôle
#	row_id	int	Identifiant de ligne (ignoré)
Num commande	num_commande	int	Clé de jointure avec CMD
Numéro d'article	code_article	str	Clé de jointure avec CMD
Qté	qte_livree	int	Quantité effectivement livrée
Date de livraison réelle	date_livraison_reelle	str->date	Date réelle de livraison
Code client/fournisseur	code_client	str	Identifiant client
Activité stratégique client	famille_activite_client	str	Redondant avec CMD
Activité stratégique article	famille_activite_article	str	Redondant avec CMD
Ségment stratégique	segment	str	Redondant avec CMD
Type activité	type_activite	str	Redondant avec CMD
Pays/région	pays	str	Redondant avec CMD
Prix de vente	prix	float	Redondant avec CMD
Devise du prix	devise	str	Redondant avec CMD

3. Architecture du pipeline de traitement

Le pipeline est compos  de 7  tapes s quentielles. Chaque  tape produit un fichier interm diaire en CSV et/ou Parquet, permettant la reprise   n'importe quel point sans relancer l'int gralit  du traitement.



Chiffres cl s du dataset final

349 390	23	19,2 %	3 465	1 068
Lignes	Features ML	Taux de retard	Clients uniques	Articles uniques

4. Étape 1 - Chargement, encodage et renommage

4.1 - Diagnostic préliminaire des fichiers

Avant tout chargement via pandas, une inspection binaire des premières lignes des fichiers CSV a été réalisée pour identifier sans ambiguïté l'encodage et le séparateur.

Paramètre	Valeur détectée	Méthode de détection
Encodage	UTF-8	Octets 0xC3 0xA9 = é en UTF-8 (pas latin-1)
Séparateur	Virgule ,	Comptage des virgules vs points-virgules
Colonne segment	Ségment stratégique (S accen	Lecture directe avec encodage UTF-8

Attention : le nom de colonne 'Ségment stratégique' comporte un accent sur le S, contrairement à 'Activité stratégique' qui n'en a pas sur le A. Ce détail a nécessité un traitement spécifique lors du renommage.

4.2 - Renommage en snake_case

Les noms de colonnes bruts contiennent des caractères accentués, des espaces et des apostrophes, incompatibles avec les conventions Python et les API de Machine Learning. Un renommage complet en snake_case est appliqué sur les deux DataFrames.

Code - chargement et renommage

```
df_cmd = pd.read_csv('Extraction commande client 2021-2025.csv',
                    encoding='utf-8', sep=',')
df_cmd = df_cmd.rename(columns={
    'Ségment stratégique' : 'segment',
    "Numéro d'article"    : 'code_article',
    'Quantité'           : 'qte_demandee', ...
})
```

4.3 - État après l'Étape 1

Dataset	Lignes	Colonnes	Valeurs nulles (résumé)
CMD (commandes)	352 549	14	code_article:31 pays:99 devise:1987 famille_act:17 segment:19
LIV (livraisons)	353 325	13	code_article:30 pays:100 devise:1977 famille_act:17 segment:19

5.  tape 2 - Traitement des valeurs manquantes

Cinq colonnes pr sentent des valeurs manquantes. Une strat gie diff renci e est appliqu e selon la nature de chaque colonne et son r le dans le mod le pr dictif.

Colonne	Nulls CMD	Nulls LIV	Strat�gie	R�sultat
code_article	31	30	Suppression des lignes	0 null - 31/30 lignes perdues
segment	19	19	R�solu par le point ci-dessus	0 null (100% overlap)
pays	99	100	Mode par code_client, sinon UNKNOWN	0 null
devise	1 987	1 977	Mode par pays, sinon EUR	0 null
famille_activite_client	17	17	Mode par code_client, sinon AUTRE	0 null

5.1 - code_article : suppression cibl e

Le mod le pr dit au niveau de la paire (code_client, code_article). Une ligne sans article est structurellement inutilisable - elle ne peut  tre jointe, encod e ni utilis e pour l'entra nement. La suppression est retenue.

Perte de donn es : $31 / 352\,549 = 0,009\%$ pour CMD, n gligeable. Les autres lignes de la m me commande sont conserv es (elles sont ind pendantes).

5.2 - pays : imputation par mode du client

98 % des 99 clients ayant un pays manquant disposent d'autres commandes avec un pays connu. L'imputation utilise le pays le plus fr quent observ  pour ce client dans le dataset. Pour le client C12663 (cas extr me : 2 commandes, toutes sans pays), la valeur UNKNOWN est assign e.

Code - imputation pays

```
mode_pays = df.dropna(subset=['pays'])
               .groupby('code_client')['pays']
               .agg(lambda x: x.mode()[0])

df['pays'] = df.apply(
    lambda row: mode_pays.get(row['code_client'], 'UNKNOWN')
    if pd.isna(row['pays']) else row['pays'], axis=1)
```

5.3 - devise : imputation par devise majoritaire du pays

La devise est fortement corr l e au pays du client. La distribution observ e est la suivante :

Pays	Devise majoritaire	Couverture
FR (France)	EUR	99,8 %
US (�tats-Unis)	USD	100 %
CA (Canada)	USD	100 %
GB (Royaume-Uni)	EUR	97 %
CN (Chine)	CNY / USD	mixte
Autres	EUR (fallback)	-

5.4 - famille_activite_client : mode par client

L'activité stratégique client est un attribut stable par client (ELEVAGE, CONSTRUCTION, RETRACTION ou AUTRE). L'imputation par mode sur le code_client est donc fiable. Aucun client ne présente plus de 17 lignes concernées.

5.5 - Résultat final Étape 2

352 518

CMD - lignes finales

353 295

LIV - lignes finales

0

Nulls restants

31

Lignes supprimées CMD

6.  tape 3 - Normalisation et validation des dates

Les trois colonnes de dates sont stock es sous forme de cha nes de caract res au format dd/mm/yyyy dans les fichiers sources. Elles sont converties en objets datetime64 pour permettre les calculs temporels (d lais, extraction de composantes).

Colonne	Source	Format brut	Apr�s conversion	NaT
date_enregistrement	CMD	dd/mm/yyyy	datetime64[us]	0
date_livraison_demandee	CMD	dd/mm/yyyy	datetime64[us]	0
date_livraison_reelle	LIV	dd/mm/yyyy	datetime64[us]	0

6.1 - Distribution temporelle des donn es

Ann�e	Commandes enregistr�es	Livraisons r�elles
2020	1 718	0 (hors p�rim�tre livraison)
2021	75 683	76 161
2022	67 569	66 548
2023	69 129	70 078
2024	71 637	72 004
2025	66 782	68 504

La r partition est homog ne sur toutes les ann es, sans pic d'anomalie. Les donn es de 2020 correspondent   des commandes enregistr es en fin d'ann e mais livr es en 2021.

6.2 - Anomalies temporelles d tect es et trait es

Une v rification de coh rence est effectu e : toute ligne v rifiant `date_livraison_reelle < date_enregistrement` constitue une anomalie physiquement impossible (livraison avant la commande).

num_commande	code_article	date_enregistrement	date_livraison_reelle	�cart
152881	A0858	2021-09-01	2021-07-02	-61 jours
152881	A0989	2021-09-01	2021-07-02	-61 jours
152881	A0592	2021-09-01	2021-07-02	-61 jours

Diagnostic : la commande 152881 a  t  saisie dans l'ERP le 1er septembre 2021, mais la livraison (juillet 2021) est ant rieure. Il s'agit d'une saisie tardive dans le syst me. D cision : suppression des 3 lignes (0,0008 % des donn es LIV). Conserver ces lignes produirait un delai_jours n gatif qui polluerait l'apprentissage.

6.3 - R sultat final  tape 3

23/09/2020->23/12/2020 | **01/01/2021->23/12/2021**

Plage CMD

Plage LIV

3 lignes

Anomalies supprim es

0

NaT apr s conversion

7.  tape 4 - Jointure commandes x livraisons

La jointure est la transformation centrale du pipeline. Elle relie chaque ligne de commande   sa ou ses livraisons correspondantes, cr ant le dataset analytique unifi .

7.1 - Probl matique des paires dupliqu es

La cl  de jointure naturelle est (num_commande, code_article). Or les deux tables pr sentent des paires non uniques pour des raisons distinctes :

Table	Cause du doublon	Paires dupliqu�es	Agr�gation retenue
CMD	R�-ouvertures de commandes dans l'ERP	3 128	sum(qte_demandee), max(prix)
LIV	Livraisons fractionn�es (plusieurs envois par	4 201	sum(qte_livree), max(date_livraison_reelle)

La quantit  command e est somm e car les r -ouvertures repr sentent des ajouts r els. La date de livraison r elle retient le maximum (derni re livraison) car c'est elle qui d termine si la commande est en retard au sens contractuel.

7.2 - Choix du type de jointure

Deux types de jointure  taient envisageables :

Type	Commandes conserv�es	Avantage	Inconv�nient
INNER JOIN	Uniquement livr�es	Cible toujours connue	Perte des 332 commandes en attente
LEFT JOIN (retenu)	Toutes (livr�es + en_attente)	Dataset complet pour production	332 NaN dans en_retard

La jointure LEFT est retenue. Les 332 commandes en attente (statut='en_attente') sont exclues de l'entra nement via un filtre sur en_retard.notna(), mais restent disponibles pour les pr dictions en production future.

7.3 - M triques d riv es calcul es

Trois colonnes analytiques sont calcul es apr s la jointure. Elles servent   l'analyse exploratoire mais sont exclues des features ML pour  viter le data leakage.

Colonne	Formule	Interpr�tation	Exclue du ML
taux_satisfaction	qte_livree / qte_demandee (clip 0-1)	Taux de service (0,999 en moyen	Oui (post-livraison)
livraison_excedentaire	qte_livree > qte_demandee	55 sur-livraisons d�tect�es	Oui (post-livraison)
delai_jours	date_liv_reelle - date_liv_demandee	Retard (>0) ou avance (<0)	Oui (post-livraison)

7.4 - R sultat final  tape 4

349 390 x 19 349 058 (99,9 %) Shape	332 (0,1 %) Livr�es	0 jour En attente	0 jour D�lai m�dian	+139 jours D�lai max
---	-------------------------------	-----------------------------	-------------------------------	--------------------------------

8. Étape 5 - Feature engineering temporel

L'objectif est d'extraire des variables prédictives à partir des trois colonnes de dates, afin de capturer la saisonnalité, les cycles budgétaires clients et le délai contractuel. Ces features sont connues au moment de la commande - elles ne constituent pas un data leakage.

8.1 - Features issues de date_enregistrement

Feature	Formule	Plage	Justification métier
annee_cmd	dt.year	2020-2025	Tendance temporelle / drift
mois_cmd	dt.month	1-12	Saisonnalité mensuelle
trimestre_cmd	dt.quarter	1-4	Cycles budgétaires trimestriels
semaine_cmd	dt.isocalendar().week	1-53	Granularité hebdomadaire
jour_semaine_cmd	dt.dayofweek	0=Lun ... 6=Dim	Comportement lié au jour ouvré
est_fin_mois_cmd	day >= 25 -> 0/1	0 ou 1	Pic de commandes fin de mois

8.2 - Features issues de date_livraison_demandee

Feature	Formule	Plage	Justification métier
annee_liv_dem	dt.year	2021-2025	Tendance de la demande future
mois_liv_dem	dt.month	1-12	Saisonnalité de la demande
trimestre_liv_dem	dt.quarter	1-4	Pression de fin de trimestre
jour_semaine_liv_dem	dt.dayofweek	0-6	Jour de livraison souhaité
est_weekend_liv_dem	dayofweek >= 5 -> 0/1	0 ou 1	504 livraisons demandées un weekend (0,1 %)

8.3 - Délai contractuel

La feature `delai_demande_jours` mesure le délai accordé par le client entre la date de commande et la date de livraison souhaitée. C'est une information disponible dès la prise de commande - sans leakage.

Statistique	Valeur
Minimum	-61 jours (livraison souhaitée avant la commande - 96 cas)
Médiane	5 jours
Maximum	388 jours

Les 96 cas de délai négatif correspondent à des commandes avec une date de livraison demandée antérieure à la date d'enregistrement - vraisemblablement des saisies de régularisation. Ces lignes sont conservées.

8.4 - Variable cible : en_retard

La variable cible est une classification binaire dérivée de `delai_jours` :

Valeur	Condition	Interprétation	Effectif
0	<code>delai_jours <= 0</code>	Livraison à temps ou en avance	281 975 (80,8 %)
1	<code>delai_jours > 0</code>	Livraison en retard	67 083 (19,2 %)
NaN	<code>statut = en_attente</code>	Cible inconnue - exclue de l'entraînement	332 (0,1 %)

Déséquilibre de classes : 80,8 % / 19,2 %. Ce déséquilibre modéré sera traité en Phase 2 via `class_weight='balanced'` (Random Forest / XGBoost) ou SMOTE. La métrique principale sera le F1-score sur la classe '1' (retard), plus pertinente que l'accuracy en contexte déséquilibré.

8.5 - Résultat final Étape 5**32**

Colonnes total

13

Nouvelles features

19,2 %

Taux de retard

332 NaN

Cibles inconnues

9.  tape 6 - Encodage des variables cat gorielles

Les algorithmes de Machine Learning op rent sur des valeurs num riques. Les neuf colonnes cat gorielles du dataset sont encod es selon leur cardinalit .

9.1 - Strat gie par colonne

Colonne	Cardinalit�	M�thode	Colonne cr��e
statut	2	Binaire (livre=1, en_attente=0)	statut_enc
devise	3	Label Encoding	devise_enc
pays	79	Label Encoding	pays_enc
famille_activite_client	4	Label Encoding	famille_activite_client_enc
famille_activite_article	3	Label Encoding	famille_activite_article_enc
segment	9	Label Encoding	segment_enc
type_activite	12	Label Encoding	type_activite_enc
code_client	3 465	Frequency Encoding	code_client_freq
code_article	1 068	Frequency Encoding	code_article_freq

9.2 - Justification du Frequency Encoding

Pour code_client (3 465 valeurs uniques) et code_article (1 068 valeurs), un One-Hot Encoding cr erait plus de 4 500 colonnes suppl mentaires, rendant le dataset extr mement sparse et co teux en m moire.

Le Frequency Encoding remplace chaque valeur par son nombre d'occurrences dans le dataset. Cette approche capture une information m tier utile : un client tr s actif (fr quence  lev e) est diff rent d'un client occasionnel - cette distinction peut  tre pr dictive du risque de retard.

Feature	Min	Max	M�diane	Top client
code_client_freq	1	4 578	365	C12289 (4 578 commandes)
code_article_freq	1	11 553	2 573	Article le plus command�

9.3 - Exemple d'encodage Label

Valeur brute	Valeur encod�e
devise : CNY -> 0, EUR -> 1, USD -> 2	
famille_activite_client : AUTRE=0, CONSTRUCTION=1, ELEVAGE=2, RETRACTION=3	
segment : BITUME=0, CONNECTIQUE=1, CONTENTION=2, COUVERTURE=3...	

9.4 - R sultat final  tape 6

41 Colonnes total	9 Colonnes encod�es	0 Nulls dans _enc	int64 Type de toutes les _enc
-----------------------------	-------------------------------	-----------------------------	---

10.  tape 7 - Dataset ML final

La derni re  tape s lectionne uniquement les colonnes utilisables par un mod le pr dictif au moment de la prise de commande. Le crit re de s lection est strict : toute information connue seulement apr s la livraison est exclue.

10.1 - Colonnes exclues et justification

Colonne exclue	Raison de l'exclusion
delai_jours	Data leakage : connu seulement apr�s livraison r�elle
taux_satisfaction	Data leakage : connu seulement apr�s livraison r�elle
livraison_excedentaire	Data leakage : connu seulement apr�s livraison r�elle
qte_livree	Data leakage : inconnue au moment de la commande
date_livraison_reelle	Data leakage : inconnue au moment de la commande
date_enregistrement	D�compos�e en annee_cmd, mois_cmd, etc.
date_livraison_demandee	D�compos�e en annee_liv_dem, mois_liv_dem, etc.
code_client (texte)	Remplac� par code_client_freq (num�rique)
code_article (texte)	Remplac� par code_article_freq (num�rique)
num_commande	Identifiant technique sans pouvoir pr�dictif
statut, devise, pays...	Remplac�s par colonnes _enc correspondantes

10.2 - Les 23 features retenues

#	Feature	Type	Description
1	qte_demandee	int64	Quantit� command�e
2	prix	float64	Prix unitaire de vente
3	annee_cmd	int32	Ann�e d'enregistrement de la commande
4	mois_cmd	int32	Mois d'enregistrement (1-12)
5	trimestre_cmd	int32	Trimestre d'enregistrement (1-4)
6	semaine_cmd	int64	Semaine ISO (1-53)
7	jour_semaine_cmd	int32	Jour de la semaine (0=Lun ... 6=Dim)
8	est_fin_mois_cmd	int64	Commande en fin de mois (0/1)
9	annee_liv_dem	int32	Ann�e de livraison demand�e
10	mois_liv_dem	int32	Mois de livraison demand�e
11	trimestre_liv_dem	int32	Trimestre de livraison demand�e
12	jour_semaine_liv_dem	int32	Jour semaine livraison demand�e
13	est_weekend_liv_dem	int64	Livraison demand�e un weekend (0/1)
14	delai_demande_jours	int64	D�lai accord� par le client (jours)
15	statut_enc	int64	Statut encod� (0=en_attente, 1=livre)
16	devise_enc	int64	Devise encod�e (0=CNY, 1=EUR, 2=USD)
17	pays_enc	int64	Pays encod� (Label Encoding, 79 classes)
18	famille_activite_client_enc	int64	Activit� client encod�e (4 classes)

19	famille_activite_article_enc	int64	Activit� article encod�e (3 classes)
20	segment_enc	int64	Segment commercial encod� (9 classes)
21	type_activite_enc	int64	Type d'activit� encod� (12 classes)
22	code_client_freq	int64	Fr�quence client dans le dataset
23	code_article_freq	int64	Fr�quence article dans le dataset

10.3 - Statistiques descriptives du dataset final

Statistique	Valeur
Shape	349 390 lignes x 24 colonnes (23 features + 1 cible)
Nulls dans les features	0 (aucun null dans X)
Nulls dans la cible (en_retard)	332 (commandes en_attente, exclues de l'entra�nement)
Taux de retard (classe 1)	19,2 % (67 083 / 349 058 commandes livr�es)
Taux � temps (classe 0)	80,8 % (281 975 / 349 058)
Taille fichier Parquet	~2,1 MB (vs 23 MB pour le CSV �quivalent)

11. R capitulatif des d cisions techniques

Cette section consolide l'ensemble des choix techniques r alis s au cours du pipeline, avec leur justification et les alternatives  cart es.

D cision 1 : Encodage UTF-8 (pas latin-1)

Justification : Les octets 0xC3 0xA9 indiquent un   UTF-8. Charger en latin-1 aurait produit des caract res corrompus dans les noms de colonnes accentu s.

Impact : Lecture binaire des premiers octets des fichiers CSV.

D cision 2 : Suppression (et non imputation) pour code_article null

Justification : Une ligne sans article ne peut pas  tre jointe, encod e ni utilis e pour la pr diction. L'imputation d'un code article fictif n'aurait aucun sens m tier.

Impact : 31 CMD + 30 LIV = 61 lignes supprim es (0,009 %).

D cision 3 : Jointure LEFT (pas INNER)

Justification : Les 332 commandes en attente sont des donn es de production futures. Les exclure via INNER JOIN appauvrirait inutilement le dataset et rendrait le pipeline inutilisable pour la pr diction en temps r el.

Impact : 332 NaN dans en_retard, filtr s   l'entra nement via `df[df.en_retard.notna()]`.

D cision 4 : Agr gation LIV : `sum(qte_livree) + max(date_livraison_reelle)`

Justification : Une commande avec 3 livraisons fractionn es est consid r e comme livr e   la date de la derni re livraison. La quantit  totale est la somme des fractions.

Impact : Alternative  cart e : garder toutes les lignes aurait cr   des faux doublons.

D cision 5 : Frequency Encoding pour code_client / code_article

Justification : Cardinalit  de 3 465 et 1 068 valeurs respectivement. Le One-Hot cr erait >4 500 colonnes, rendant le dataset extr mement sparse et les for ts al atoires peu efficaces.

Impact : Capture l'importance relative d'un client/article sans explosion dimensionnelle.

D cision 6 : Exclusion de delai_jours, taux_satisfaction, livraison_excedentaire

Justification : Ces trois colonnes sont inconnues au moment de la prise de commande. Les inclure constituerait un data leakage : le mod le apprendrait   pr dire le retard en connaissant d j  le retard.

Impact : Garde-fou fondamental pour la validit  de l' valuation en production.

D cision 7 : Variable cible binaire en_retard plut t que r gression sur delai_jours

Justification : La r gression sur delai_jours est un probl me plus difficile avec distribution tr s asym trique (m diane = 0 jour). La classification binaire (retard / pas retard) correspond mieux au besoin op rationnel : savoir si une commande risque d' tre en retard.

Impact : D s quilibre 80/19 plus g rable que la distribution continue de delai_jours.

D cision 8 : Suppression des 3 anomalies date_livraison_reelle < date_enregistrement

Justification : Ces lignes (commande 152881) ont une date de livraison ant rieure   l'enregistrement, ce qui est physiquement impossible. Il s'agit d'une erreur de saisie ERP.

Impact : Perte : 3 lignes sur 353 295 = 0,0008 %.

12. Bilan et prochaines  tapes

12.1 - Bilan de la Phase 1

�tape	Action principale	Donn�es en entr�e	Donn�es en sortie
1	Chargement + renommage snake_case	352 549 CMD / 353 325 LIV	Colonnes normalis�es
2	Traitement valeurs manquantes	Divers nulls	0 null restant
3	Normalisation dates + anomalies	Cha�nes dd/mm/yyyy	datetime64 - 3 anomalies supprim�es
4	Jointure LEFT CMD x LIV	2 tables s�par�es	349 390 x 19
5	Feature engineering temporel + cible	349 390 x 19	349 390 x 32
6	Encodage cat�gorielles	9 colonnes texte	9 colonnes num�riques ajout�es
7	S�lection features + export	349 390 x 41	dataset_ml_final.parquet (x 24)

12.2 - Fichiers produits

Fichier	Localisation	Taille	Usage
cmd_step1/2/3.csv	data/processed/	~39 MB chacun	Interm�diaires CMD
liv_step1/2/3.csv	data/processed/	~35 MB chacun	Interm�diaires LIV
dataset_step4.parquet	data/processed/	3,4 MB	Post-jointure
dataset_step5.parquet	data/processed/	3,7 MB	Post-feature-eng.
dataset_step6.parquet	data/processed/	4,7 MB	Post-encodage
dataset_ml_final.parquet	data/processed/	2,2 MB	Entr�e Phase 2 (ML)
dataset_ml_final.csv	data/processed/	23 MB	R�f�rence lisible

12.3 - Phase 2 : Mod lisation (  venir)

Le dataset_ml_final.parquet sera utilis  pour entra ner et  valuer trois mod les :

1. Train/test split stratifi  80/20

Stratification sur en_retard pour respecter le ratio 80/19 dans les deux splits

2. Gestion du d s quilibre

Option A : class_weight='balanced' (Random Forest / XGBoost)

Option B : SMOTE (Synthetic Minority Oversampling Technique)

3. Mod les entra n s

R gression Logistique (baseline)

Random Forest (interpr tabilit )

XGBoost (performance)

4. M triques d' valuation

F1-score (classe 1), AUC-ROC, matrice de confusion, pr cision/rappel

5. Interpr tabilit 

Feature importance (Random Forest / XGBoost), SHAP values

12.4 - Calendrier pr visionnel

Phase	P�riode	Livrable
Phase 1 - Data Engineering	10-18 Avril 2026	dataset_ml_final.parquet (termin�)
Phase 2 - Mod�lisation	18 Avril - 1er Mai 2026	notebooks/02_modelisation.ipynb
Phase 3 - Dashboard	1-15 Mai 2026	Application Streamlit
Phase 4 - R�daction m�moire	1-28 Mai 2026	M�moire complet (40-50 pages)
D�p�t final	28 Mai 2026	M�moire + Code + Rapport

Phase 1 - Data Engineering

Termin e avec succ s

349 390 lignes x 24 colonnes | Taux de retard : 19,2 %

Fichier : data/processed/dataset_ml_final.parquet